人工神经网络及其应用



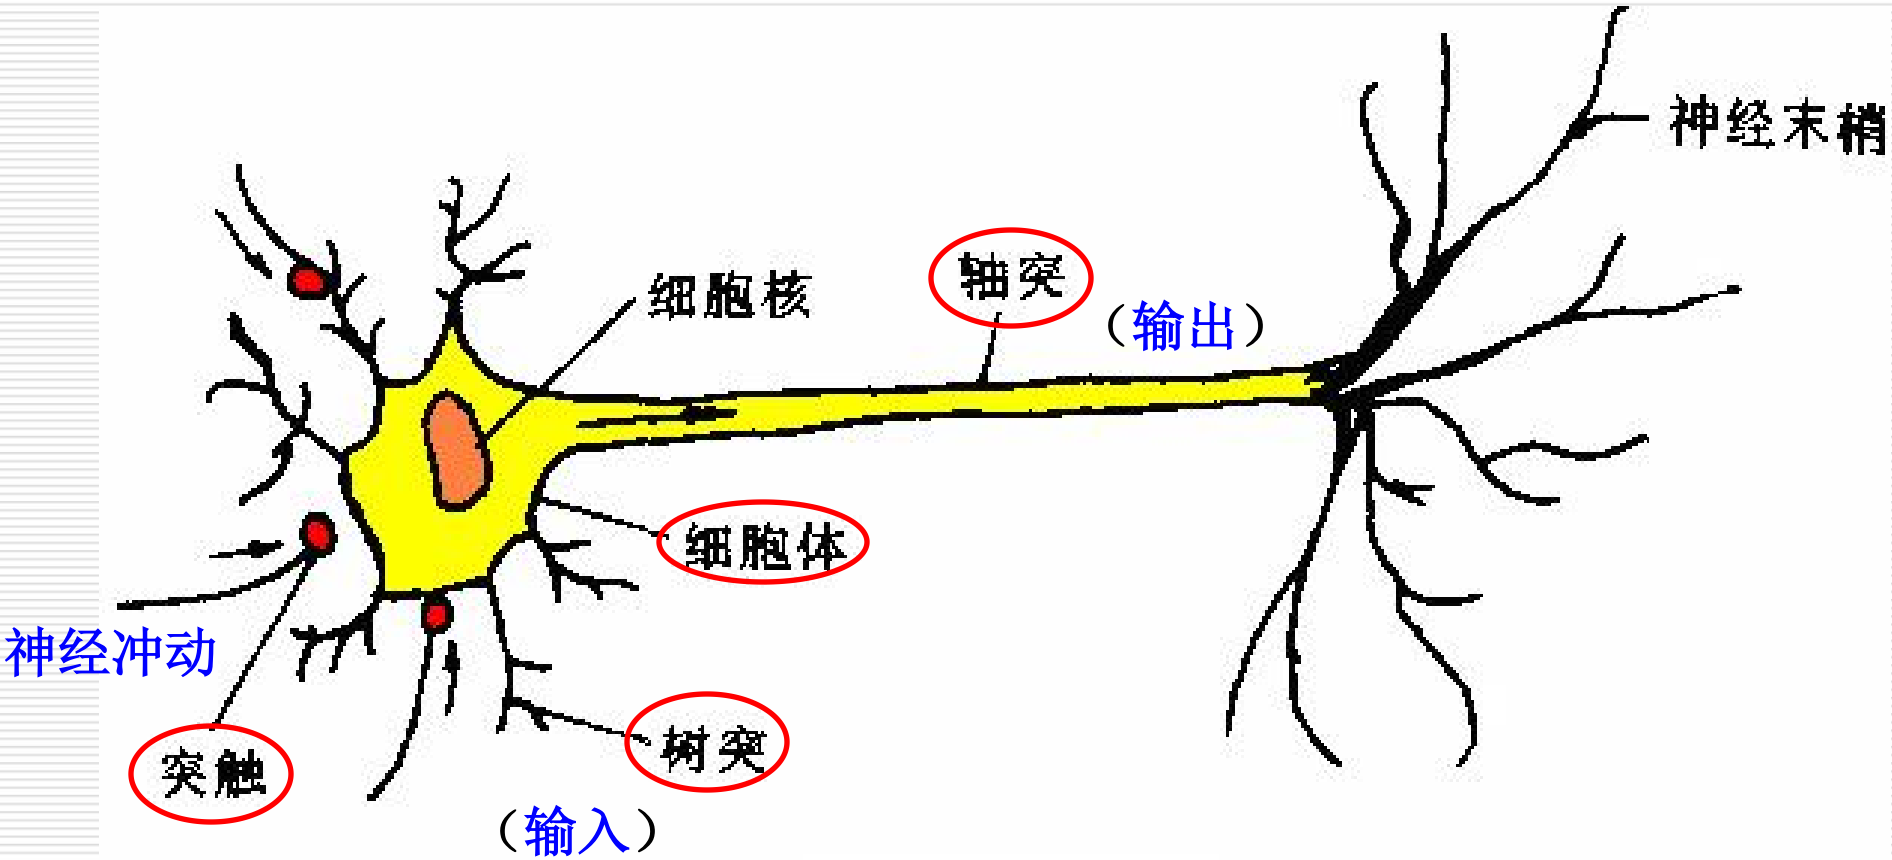
人工神经网络及其应用

- 神经元与神经网络结构
- 神经网络及其学习算法
- 卷积神经网络
- 生成对抗网络及其应用

生物神经元的结构

- 人脑由一千多亿（1011亿－ 1014 亿）个神经细胞（神经元）交织在一起的网状结构组成，其中大脑皮层约140亿个神经元，小脑皮层约1000亿个神经元。
- 神经元约有1000种类型，每个神经元大约与10^3— 10^4个其他神经元相连接，形成极为错综复杂而又灵活多变的神经网络。
- 人的智能行为就是由如此高度复杂的组织产生的。浩瀚的宇宙中，也许只有包含数千忆颗星球的银河系的复杂性能够与大脑相比。

生物神经元的结构

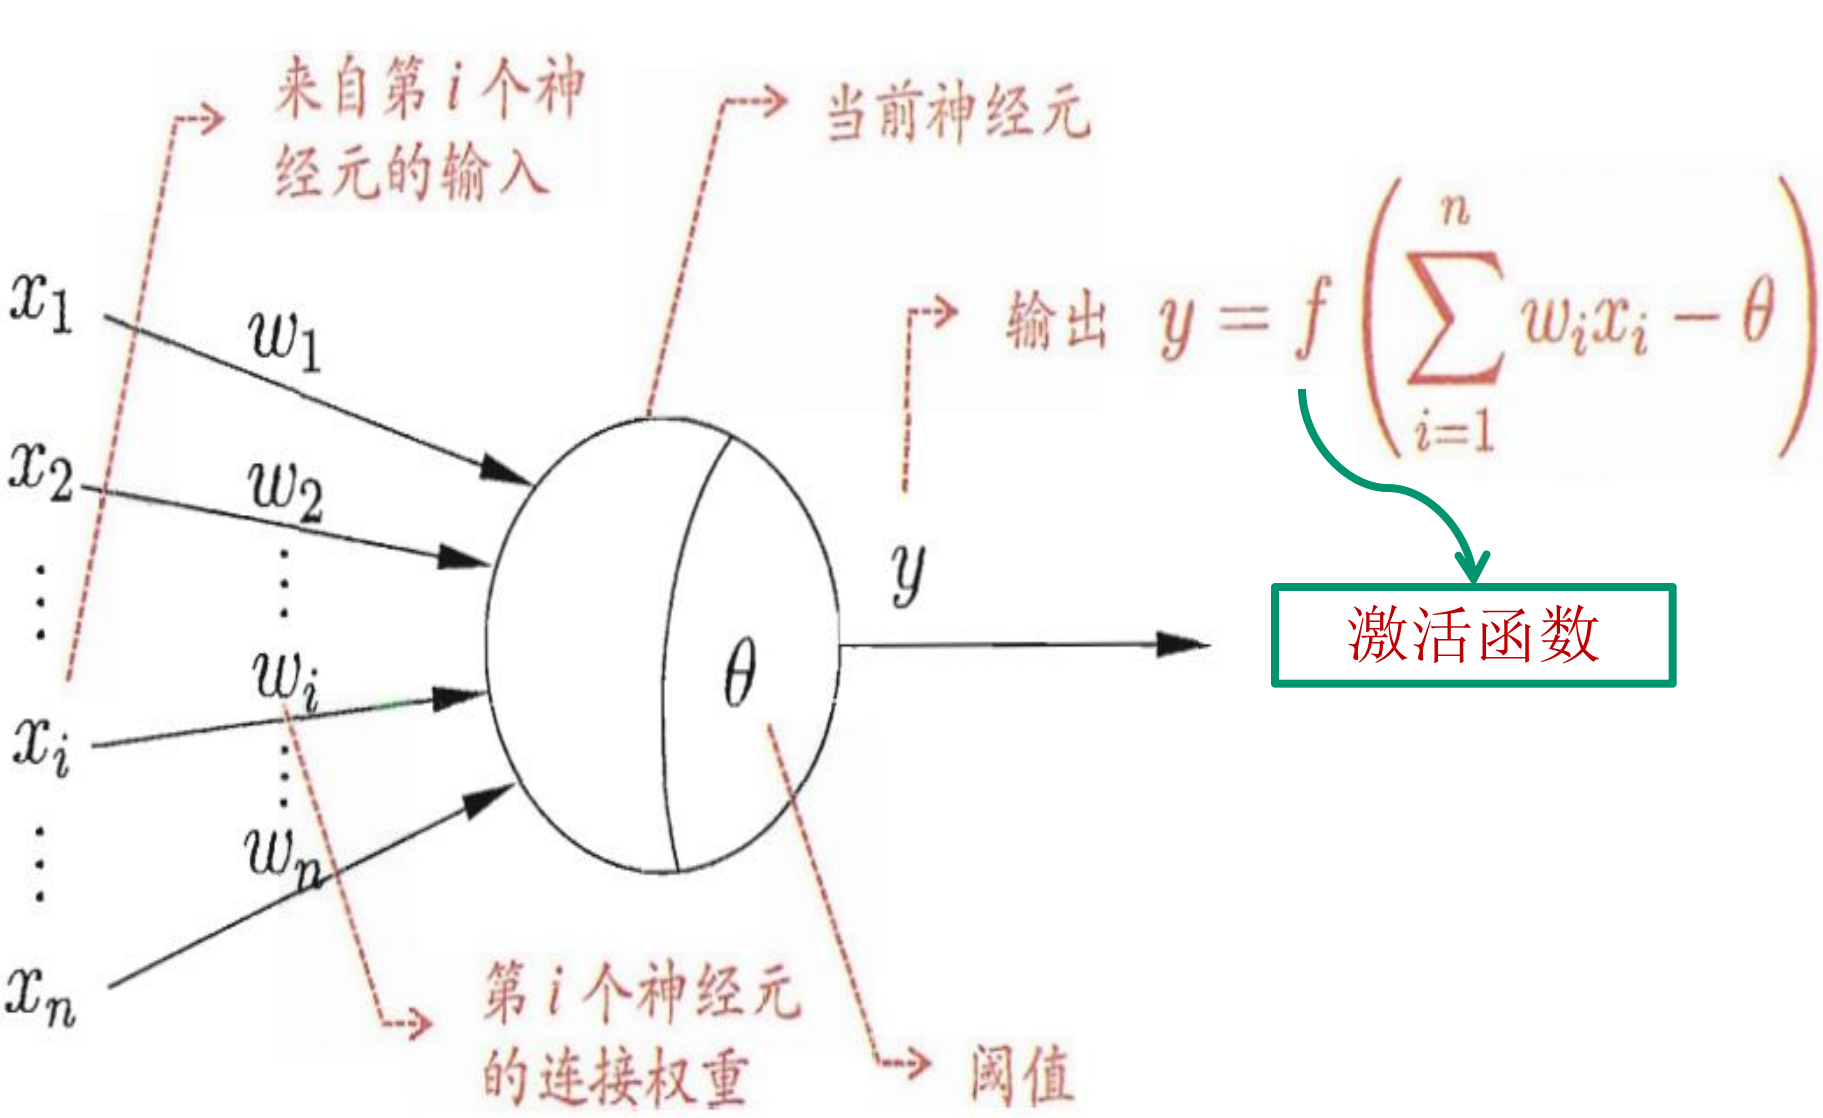


生物神经元结构

生物神经元的结构

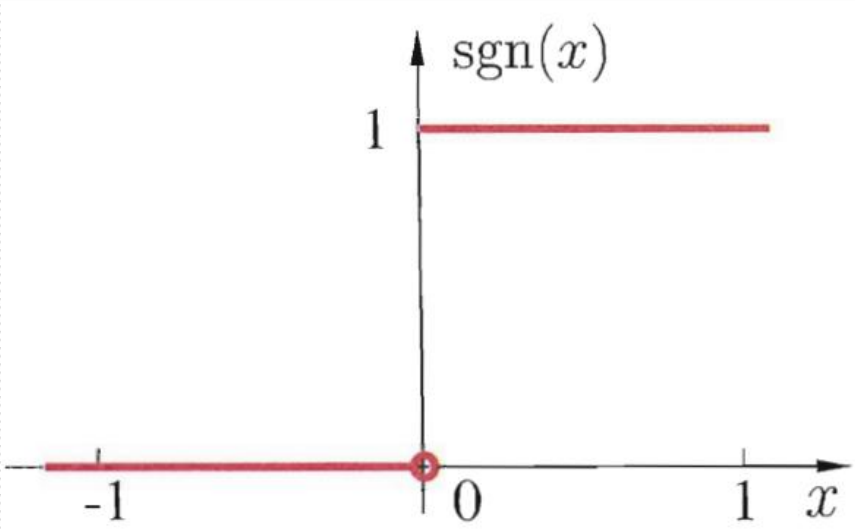
- 工作状态：
- 兴奋状态：细胞膜电位 > 动作电位的阈值 → 神经冲动
- 抑制状态：细胞膜电位 < 动作电位的阈值
- 学习与遗忘：由于神经元结构的可塑性，突触的传递作用可增强和减弱 。

神经元模型


来自第 i 个神经元的输入
当前神经元
输出 $y = f\left(\sum_{i=1}^{n} w_i x_i - \theta\right)$
x_1
x_2
x_i
x_n
w_1
w_2
w_i
w_n
θ
y
激活函数
第 i 个神经元的连接权重
阈值

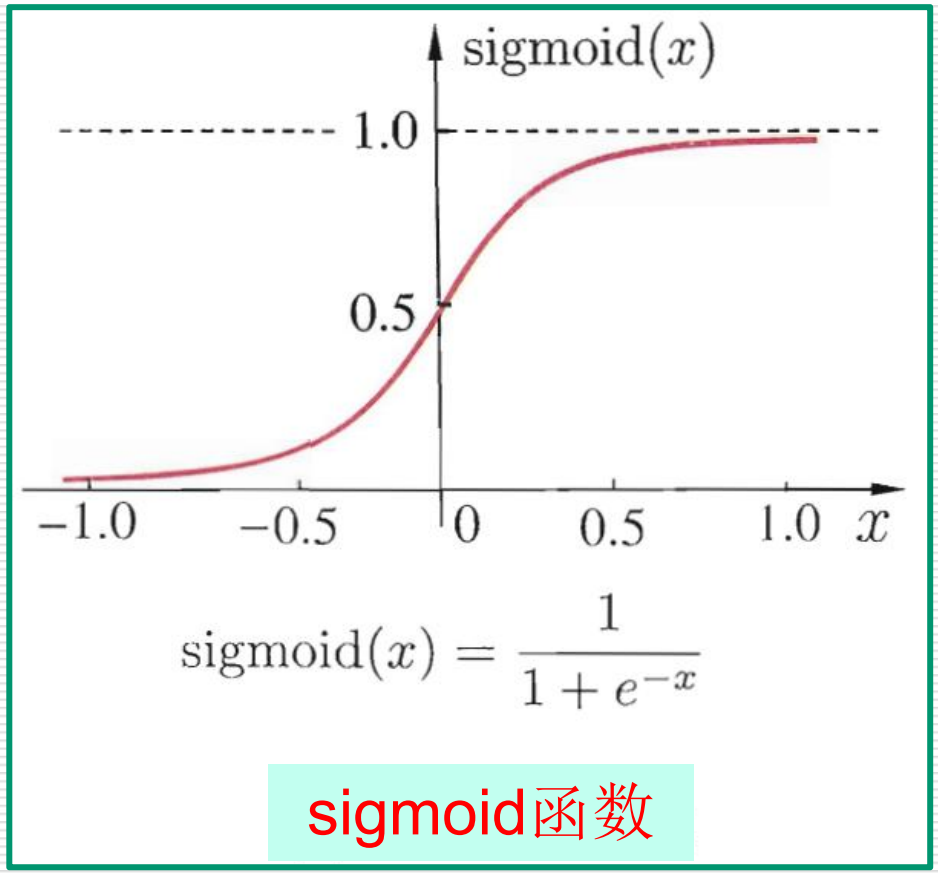
神经元模型

激活函数



$$\mathrm{sgn}(x) = \begin{cases} 1, & x \geqslant 0; \\ 0, & x < 0. \end{cases}$$

阶跃函数

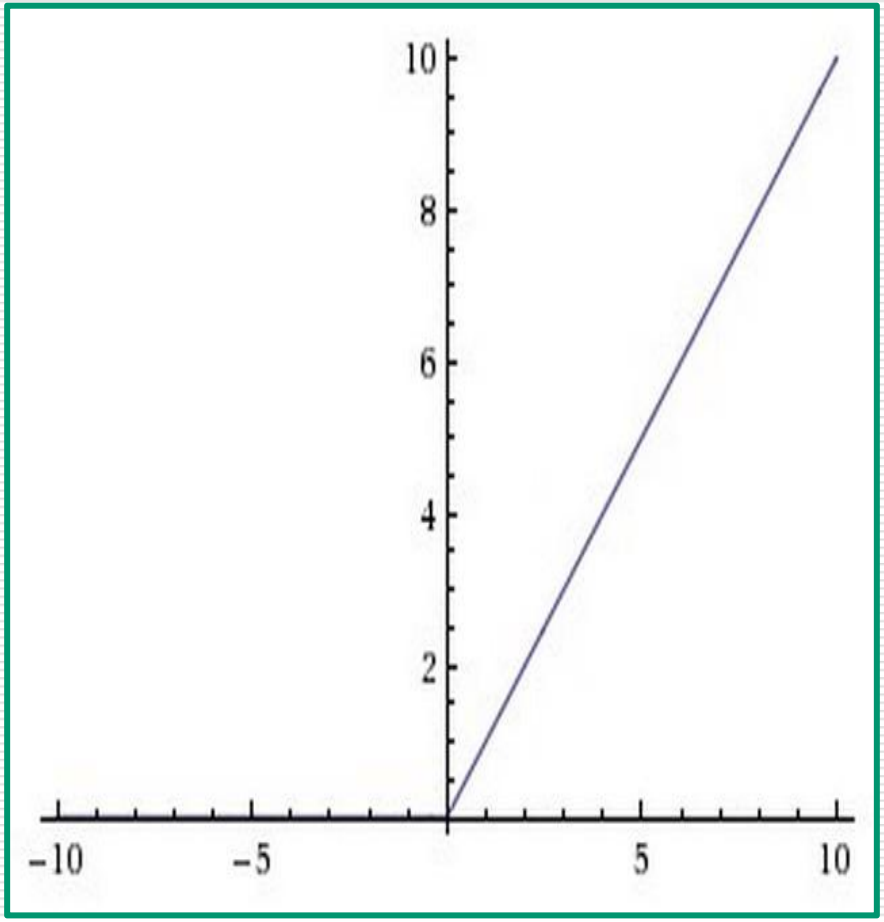


$$\mathrm{sigmoid}(x) = \frac{1}{1+e^{-x}}$$

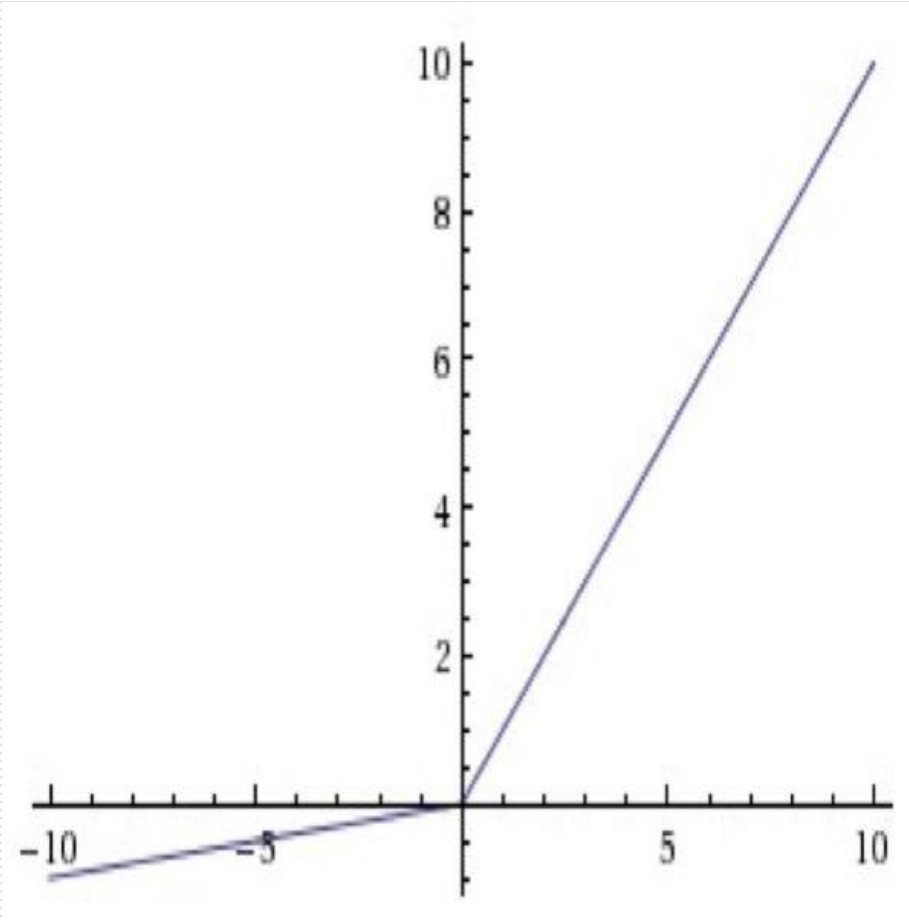
sigmoid函数

神经元模型

激活函数



Rectified Linear Unit
(ReLU)



Leaky ReLU

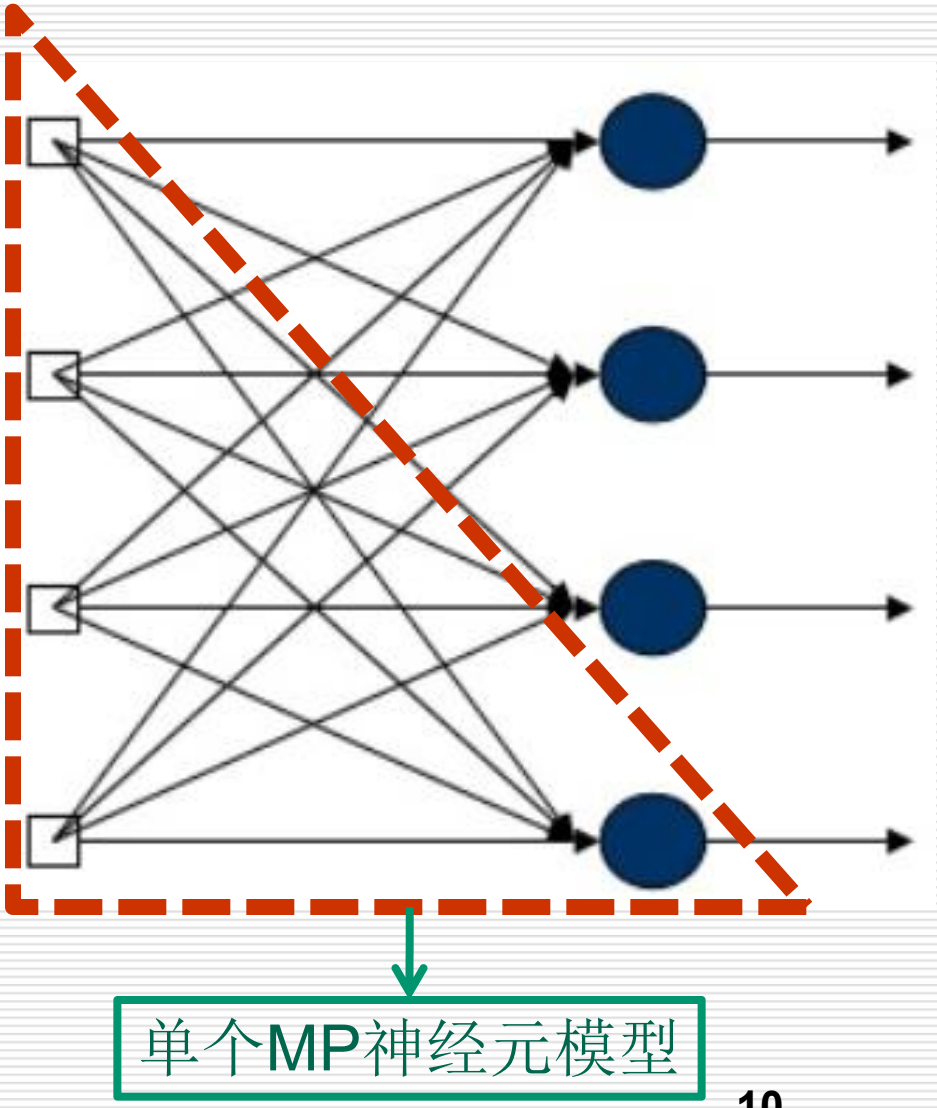
神经网络的结构与工作方式

- 决定人工神经网络性能的三大要素：

  - 神经元的特性。
  - 神经元之间相互连接的形式——拓扑结构。
  - 为适应环境而改善性能的学习规则。

神经网络的结构与工作方式

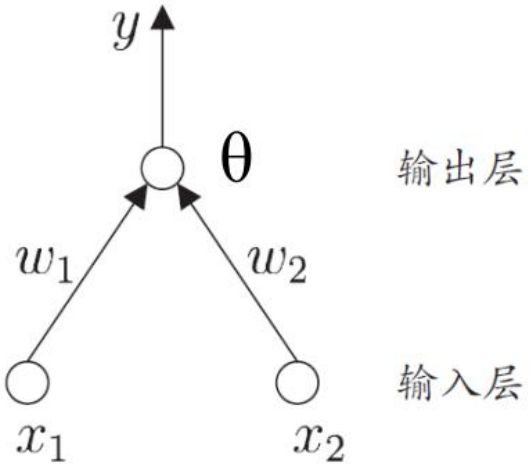
- 感知机模型
  - 多个MP神经元的连接
  - 具有一层神经元
  - 感知机引入了学习的概念

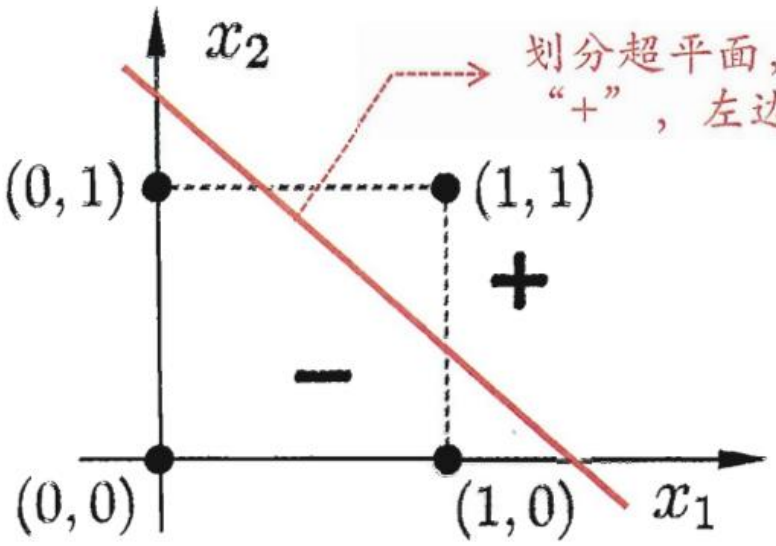


神经网络的结构与工作方式

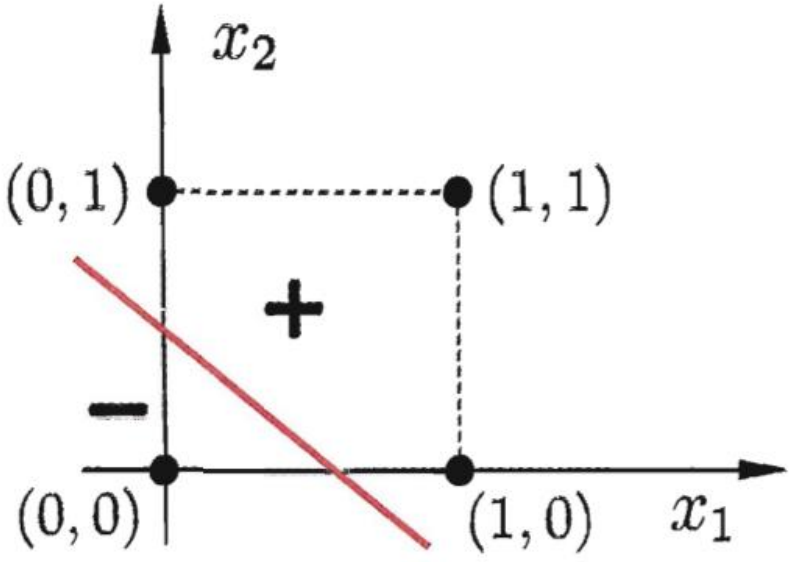
单层感知机的定义

- 单层感知机只拥有一层M-P神经元，即只包含输入层和输出层，输入层接受外界输入信号后传递给输出层，输出层是M-P神经元，进行激活处理。
- 比如，下图所示的M-P神经元模型，就是一个最简单的单层感知机，输出层只有一个神经元。

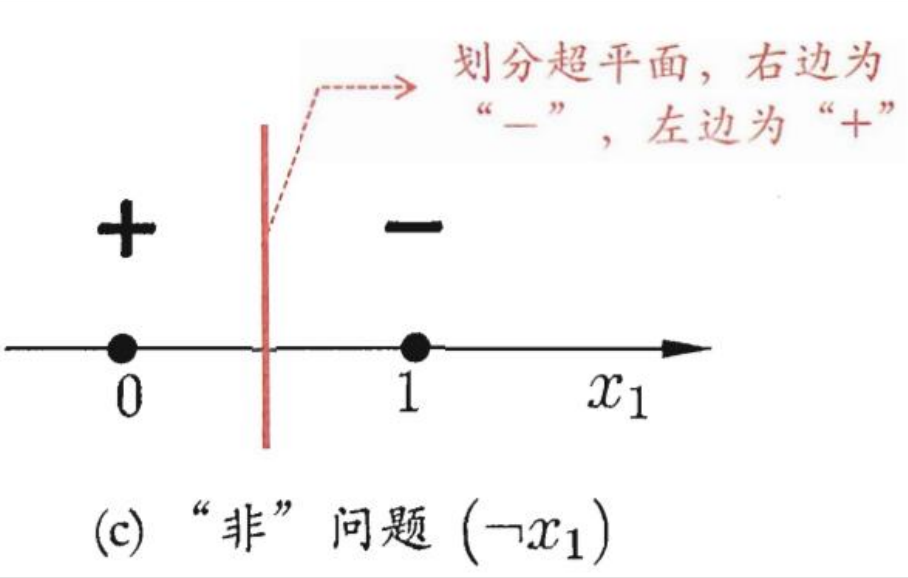




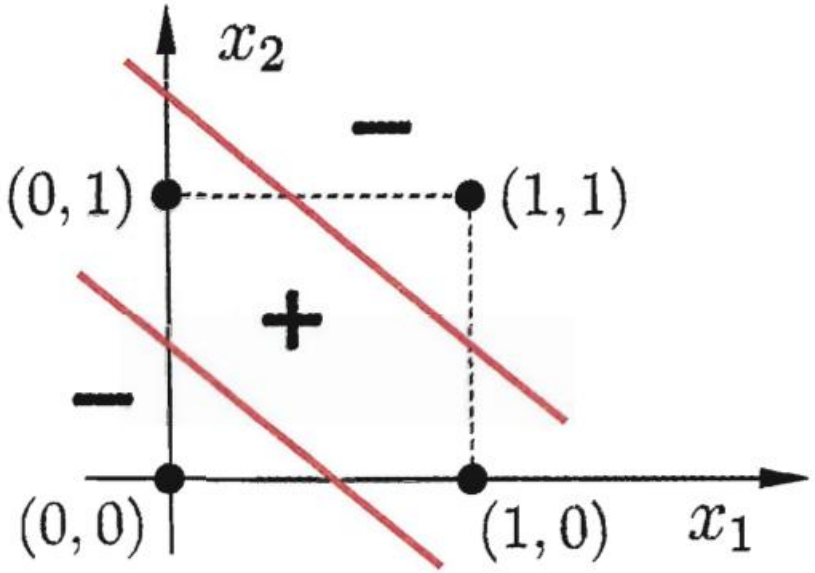
(a) “与”问题 $(x_1 \wedge x_2)$



(b) “或”问题 $(x_1 \vee x_2)$



(c) “非”问题 $(\neg x_1)$



(d) “异或”问题 $(x_1 \oplus x_2)$

神经网络的结构与工作方式

单层感知机的学习规则：

- 给定训练数据集，单层感知机的权重$w_i(i=1,2,\cdots,m)$与阈值θ可以很容易通过学习得到。
- 在单层感知机中，神经元的阈值θ可看作一个固定输入为-1的“哑结点”所对应的连接权重w_{m+1}，这样，权重和阈值的学习就统一为权值的学习了。
- 对训练样例$(\boldsymbol{x},y)$，若当前感知机的输出为$\hat{y}$，则感知机权重调整规则为：$w_i \leftarrow w_i + \triangle w_i$

$$\triangle w_i = (l)(y-\hat{y})x_i$$

其中$l \in (0,1)$为学习率。

若感知机对训练样例$(\boldsymbol{x},y)$预测正确，则感知机不发生变化；否则根据错误程度进行权重的调整。

假定损失函数是平方误差函数

神经网络的结构与工作方式

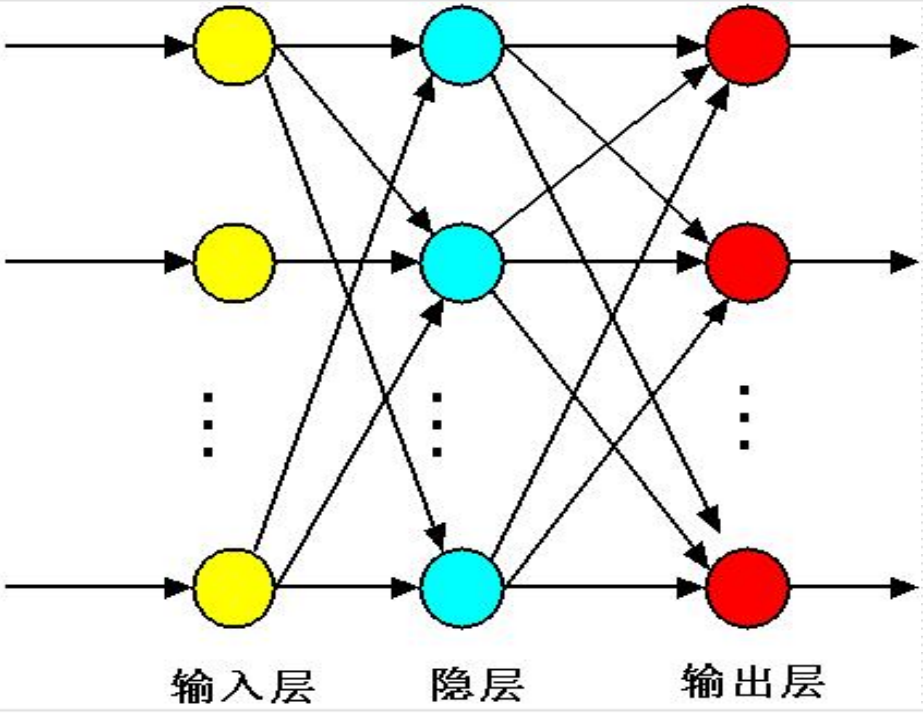
单层感知机的学习能力：

- 尽管单层感知机能够非常容易地实现逻辑与、或、非运算，但其学习能力还是非常有限。
- 事实上，逻辑与、或、非运算问题都是线性可分的问题。可以证明[Minsky and Papert, 1969]，若二分类问题是线性可分的，即存在一个线性超平面能将它们分开，则感知机的学习过程一定会收敛，否则感知机的学习过程将会发生振荡，甚至不能解决异或这样简单的非线性可分问题。
- 要解决非线性可分问题，就需要使用多层功能神经元。比如两层感知机，输入层与输出层之间的一层神经元，被称为隐含层，隐含层和输出层神经元都是拥有激活函数的功能神经元。

神经网络的结构与工作方式

❑ 1. 神经网络的结构

（1）前馈型（ 前向型）



- 所有连接线的箭头方向相同
- 一定包含输入层与输出层，隐含层数量不定
- 神经元间的连接线不能跨层
- 输入层之后的所有层中的神经元均与前面一层的所有神经元有连接，定义为全连接网络
- 每层中神经元之间无连接

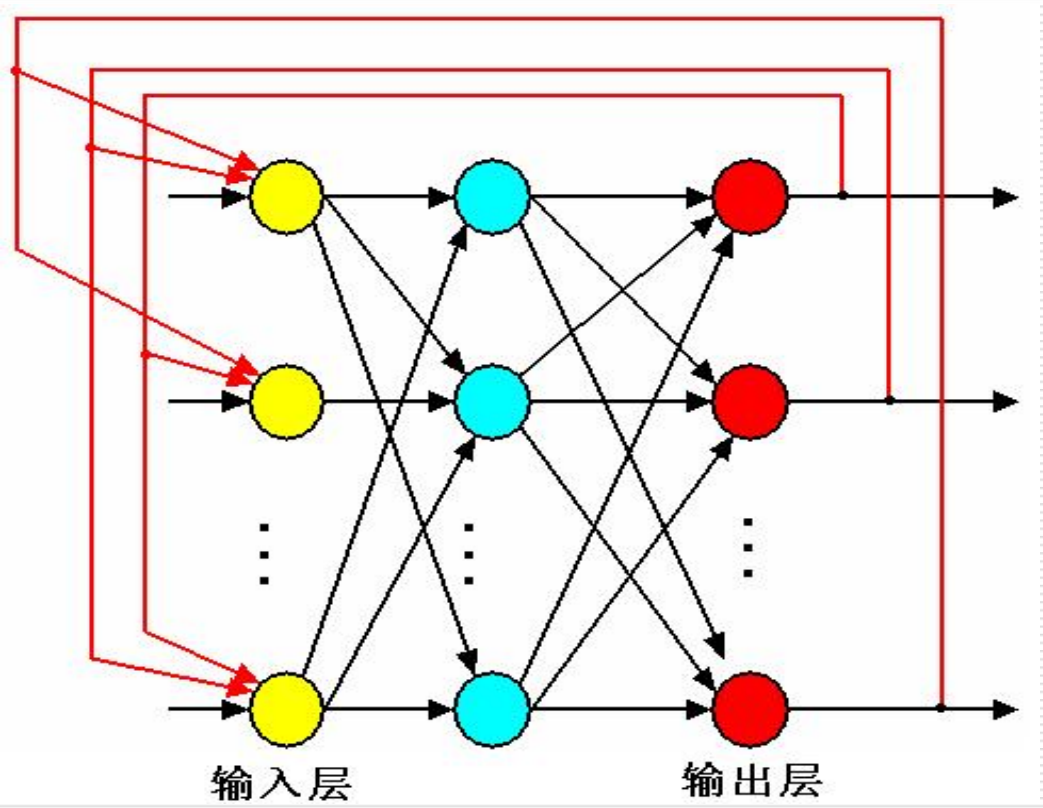
2层网络？ or
3层网络？

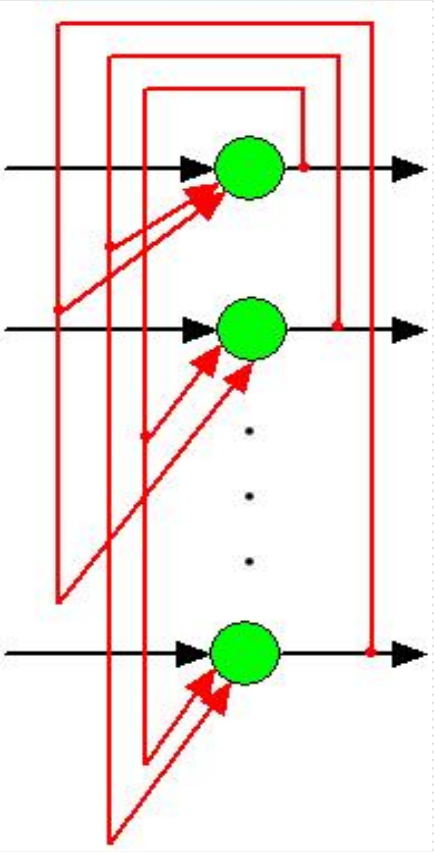
2个全连接层！ or
1个隐含层！

神经网络的结构与工作方式

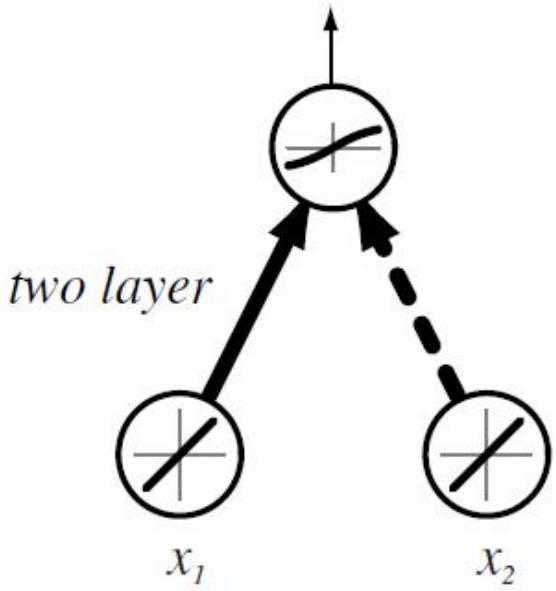
1. 神经网络的结构

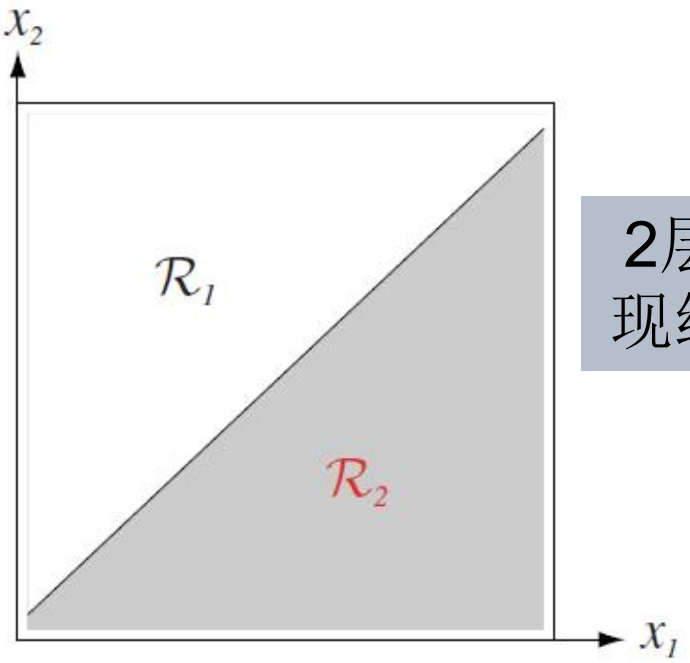
（2）反馈型



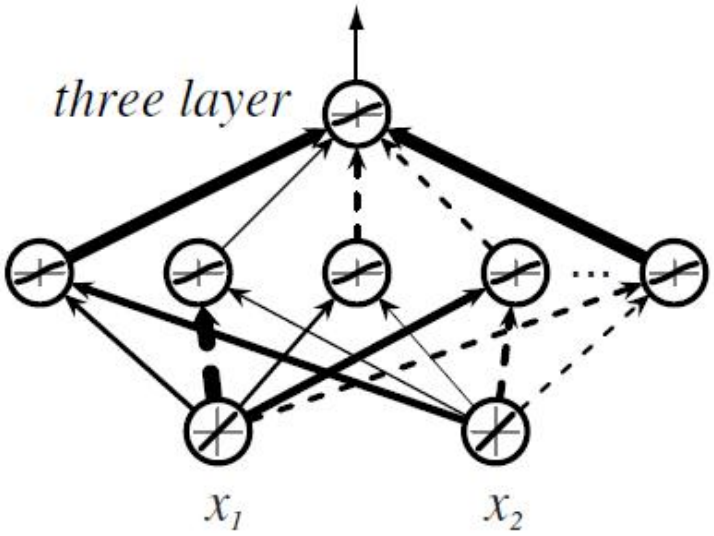


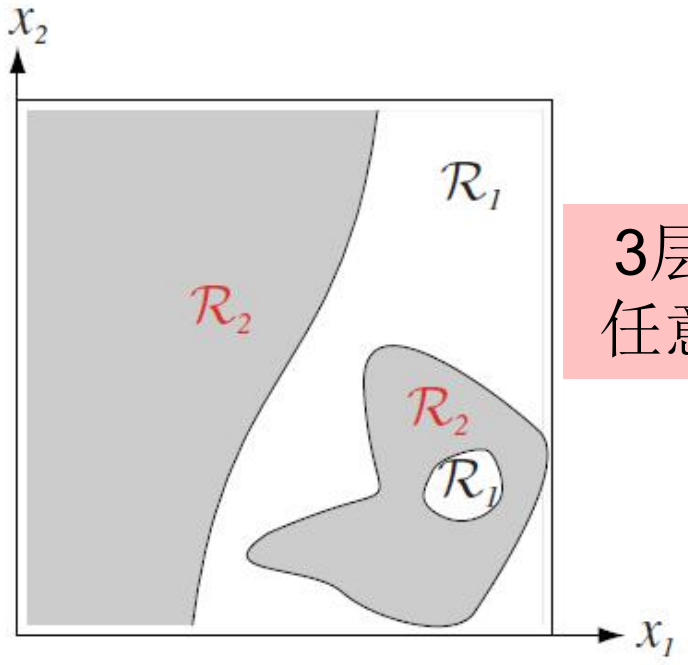
（Hopfield神经网络）





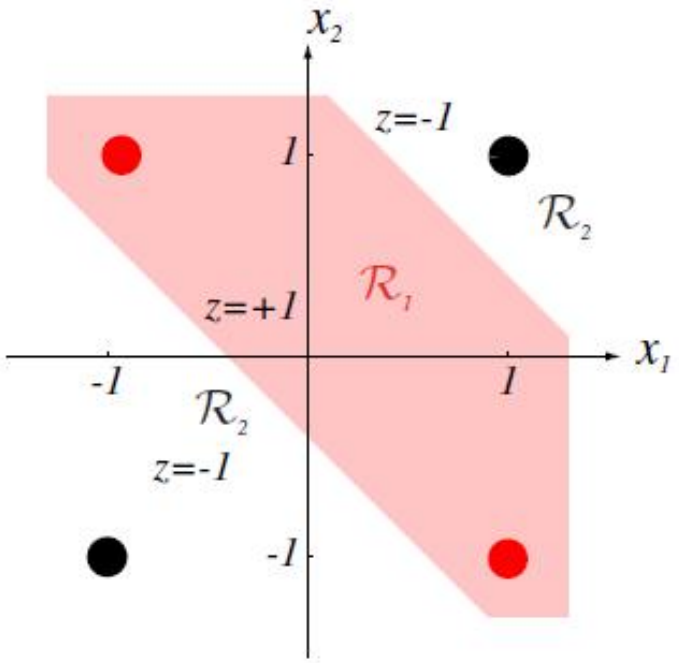
2层网络只能实现线性判决边界

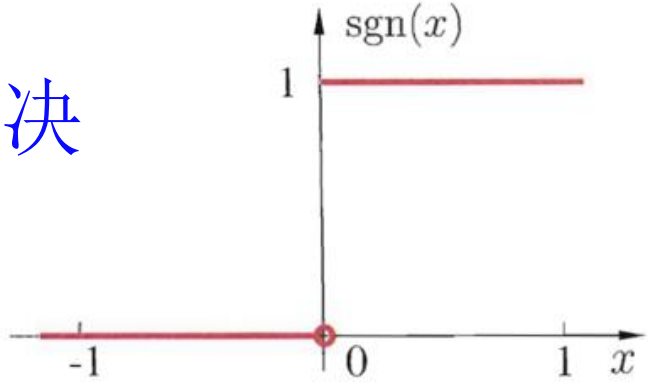




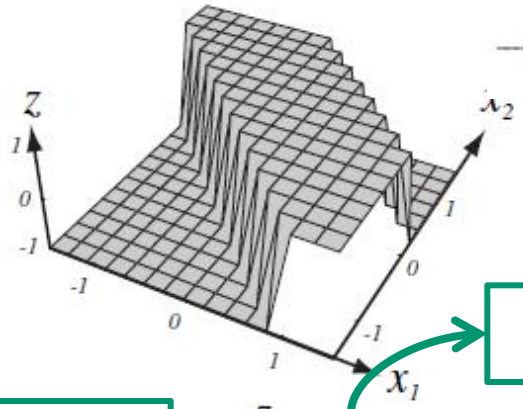
3层网络能实现任意的判决边界

异或运算的解决





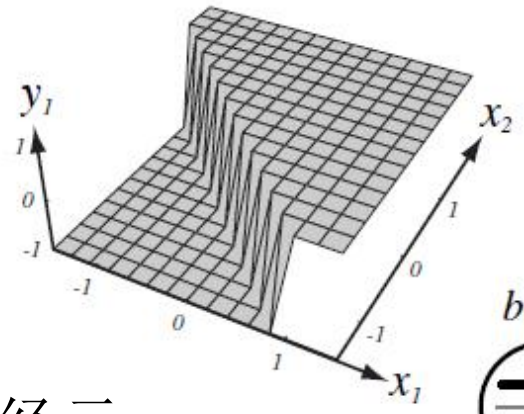
激活函数

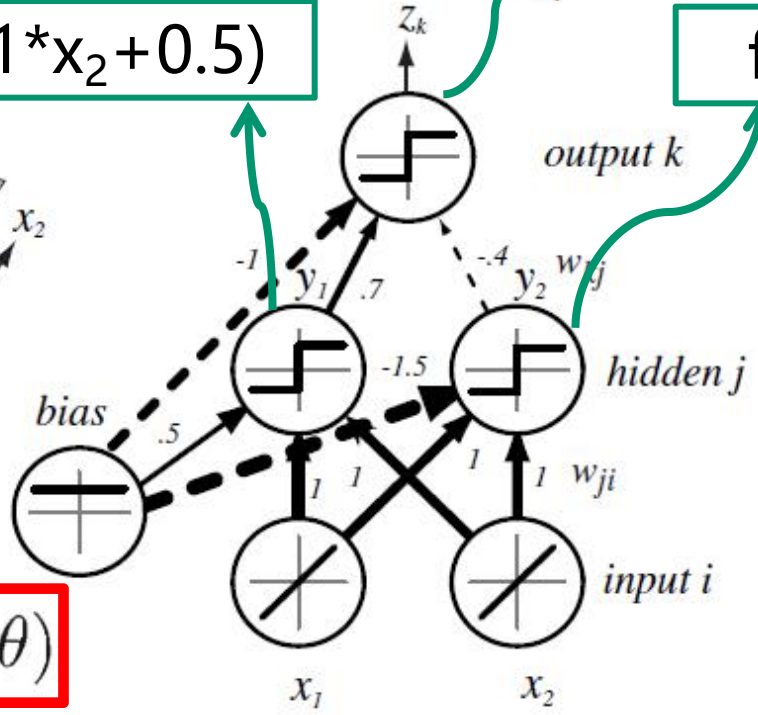


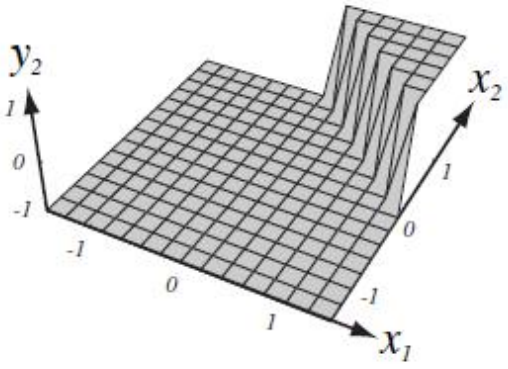
f(0.7*y_1-0.4*y_2-1)

f(1*x_1+1*x_2+0.5)

f(1*x_1+1*x_2-1.5)







神经元

$$y = f(\sum_i w_i x_i - \theta)$$

神经网络的结构与工作方式

2. 神经网络的工作方式

- 同步（并行）方式：任一时刻神经网络中所有神经元同时调整状态。目前神经网络学习的主流方式，效率高。
- 异步（串行）方式：任一时刻只有一个神经元调整状态，而其它神经元的状态保持不变。

人工神经网络及其应用

- 神经元与神经网络结构
- 神经网络学习算法
- 卷积神经网络
- 生成对抗网络及其应用

BP学习算法

- 两个问题：

- （1）是否存在一个BP神经网络能够逼近给定的样本或者函数。

Kolmogorov 定理：给定任意 $\varepsilon > 0$，对于任意的 L_2 型连续函数 $f:[0,1]^n \longrightarrow R^m$，存在一个三层 BP 神经网络，其输入层有 n 个神经元，中间层有 $2n+1$ 个神经元，输出层有 m 个神经元，它可以在任意 ε 平方误差精度内逼近 f。

- （2）如何调整BP神经网络的连接权，使网络的输入与输出与给定的样本相同。

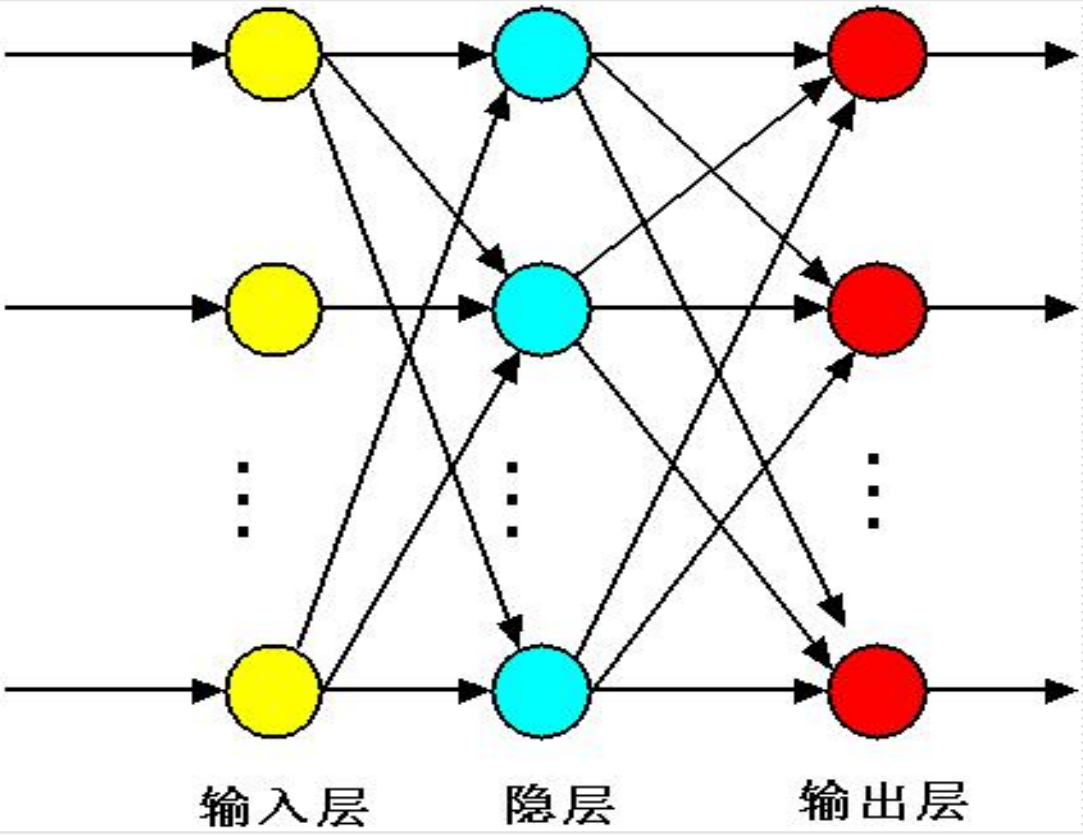
1986年，D. Rumelhart与Hinton等提出BP学习算法。

ML Framework



神经网络架构

- 网络类型：前馈型
- 网络层数：3层
- 每层神经元数量：5,100,10
- 激活函数类型：sigmoid

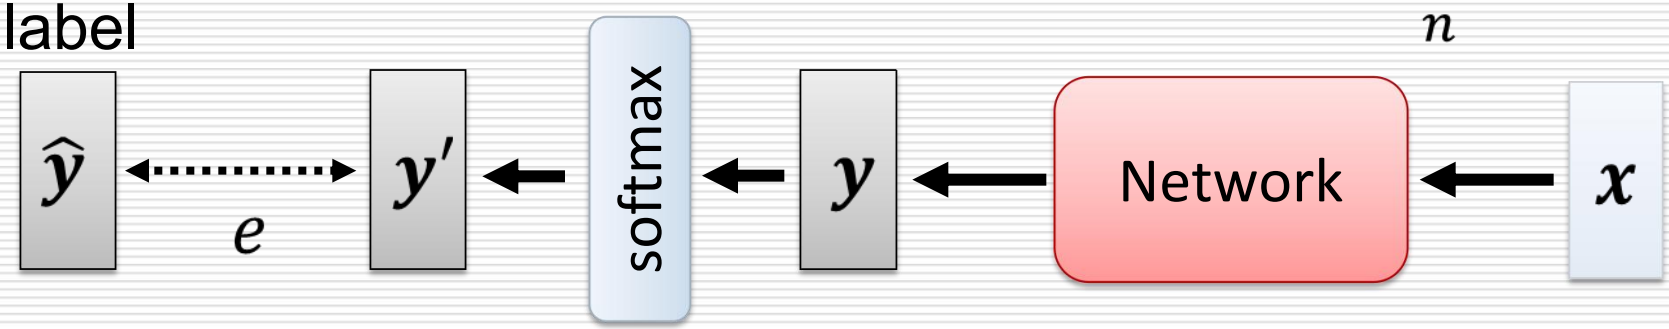


ML Framework



Loss of Classification

$$L = \frac{1}{N}\sum_{n} e_n$$



Mean Square Error (MSE) $e = \sum_{i} (\hat{y}_i - y'_i)^2$

Cross-entropy WIN $e = -\sum_{i} \hat{y}_i ln y'_i$

ML Framework



梯度下降法

Network parameters $\theta = \{w_1, w_2, \cdots, b_1, b_2, \cdots\}$

Starting Parameters $\theta^0 \longrightarrow \theta^1 \longrightarrow \theta^2 \longrightarrow \cdots\cdots$

$$\nabla L(\theta) = \begin{bmatrix} \partial L(\theta)/\partial w_1 \\ \partial L(\theta)/\partial w_2 \\ \vdots \\ \partial L(\theta)/\partial b_1 \\ \partial L(\theta)/\partial b_2 \\ \vdots \end{bmatrix}$$

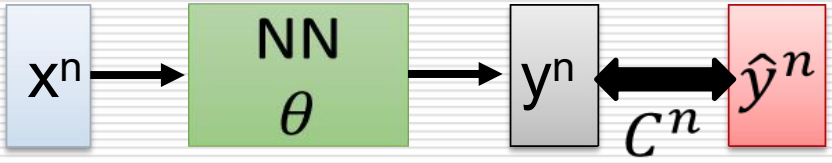
$Compute\ \nabla L(\theta^0)$ $\quad \theta^1 = \theta^0 - \eta \nabla L(\theta^0)$

$Compute\ \nabla L(\theta^1)$ $\quad \theta^2 = \theta^1 - \eta \nabla L(\theta^1)$

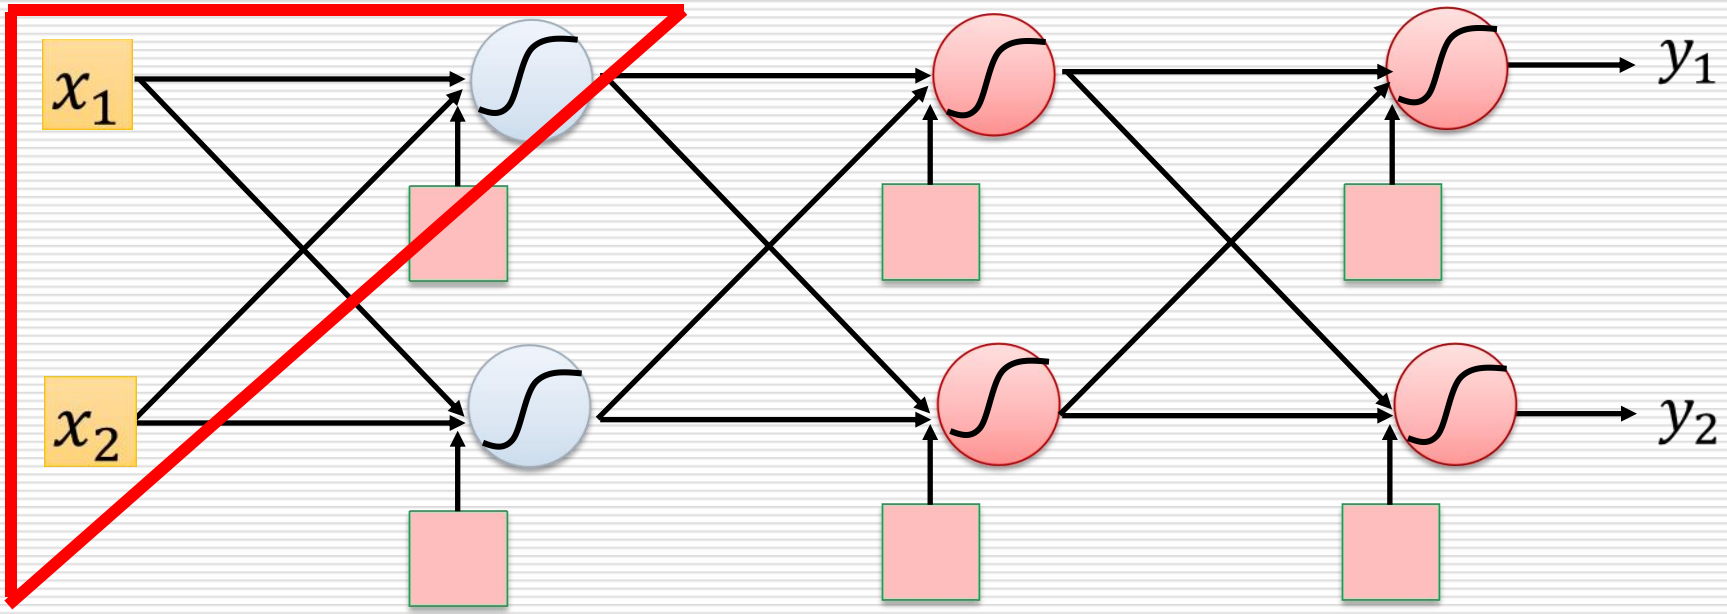
Millions of parameters ……

为了高效地计算梯度，一般采用误差反向传播算法（Backpropagation）.

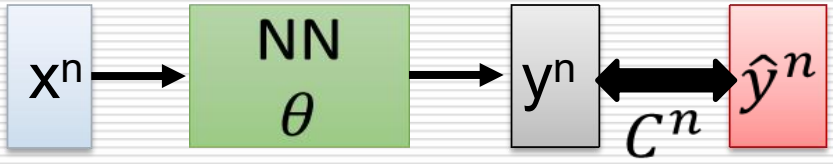
Backpropagation

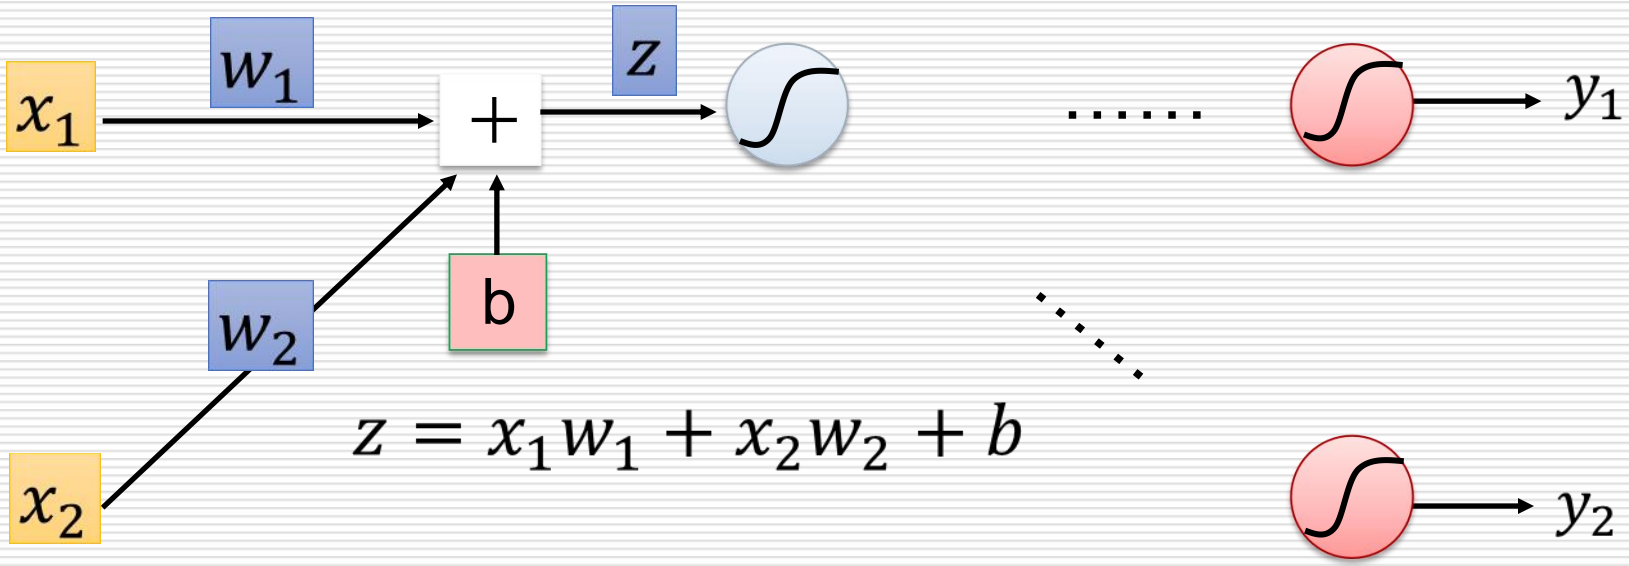


$$L(\theta) = \sum_{n=1}^{N} C^n(\theta) \quad \Rightarrow \quad \frac{\partial L(\theta)}{\partial w} = \sum_{n=1}^{N} \frac{\partial C^n(\theta)}{\partial w}$$



Backpropagation





$$\frac{\partial C}{\partial w} = ? \quad \frac{\partial z}{\partial w}\frac{\partial C}{\partial z}$$

(Chain rule)

前向传播:

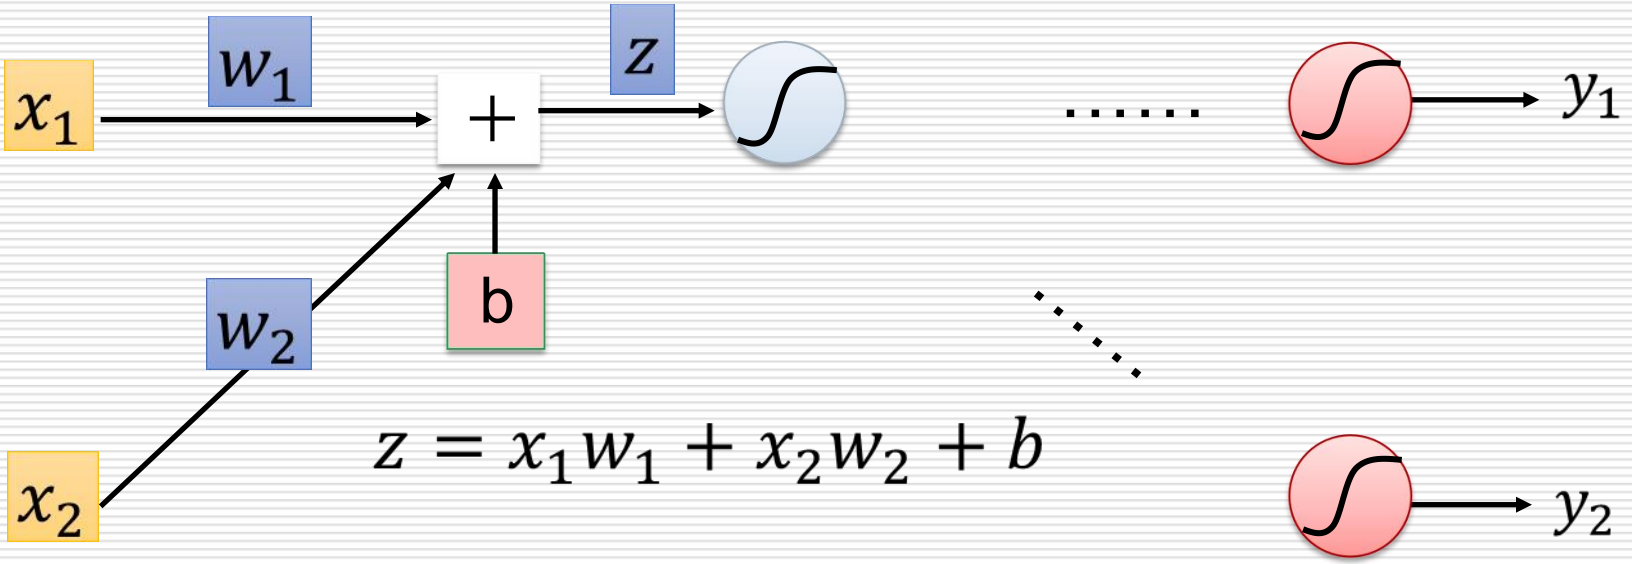
Compute $\partial z/\partial w$ for all parameters

反向传播:

Compute $\partial C/\partial z$ for all activation function inputs z

Backpropagation – 前向传播

Compute $\partial z/\partial w$ for all parameters



$$z = x_1 w_1 + x_2 w_2 + b$$

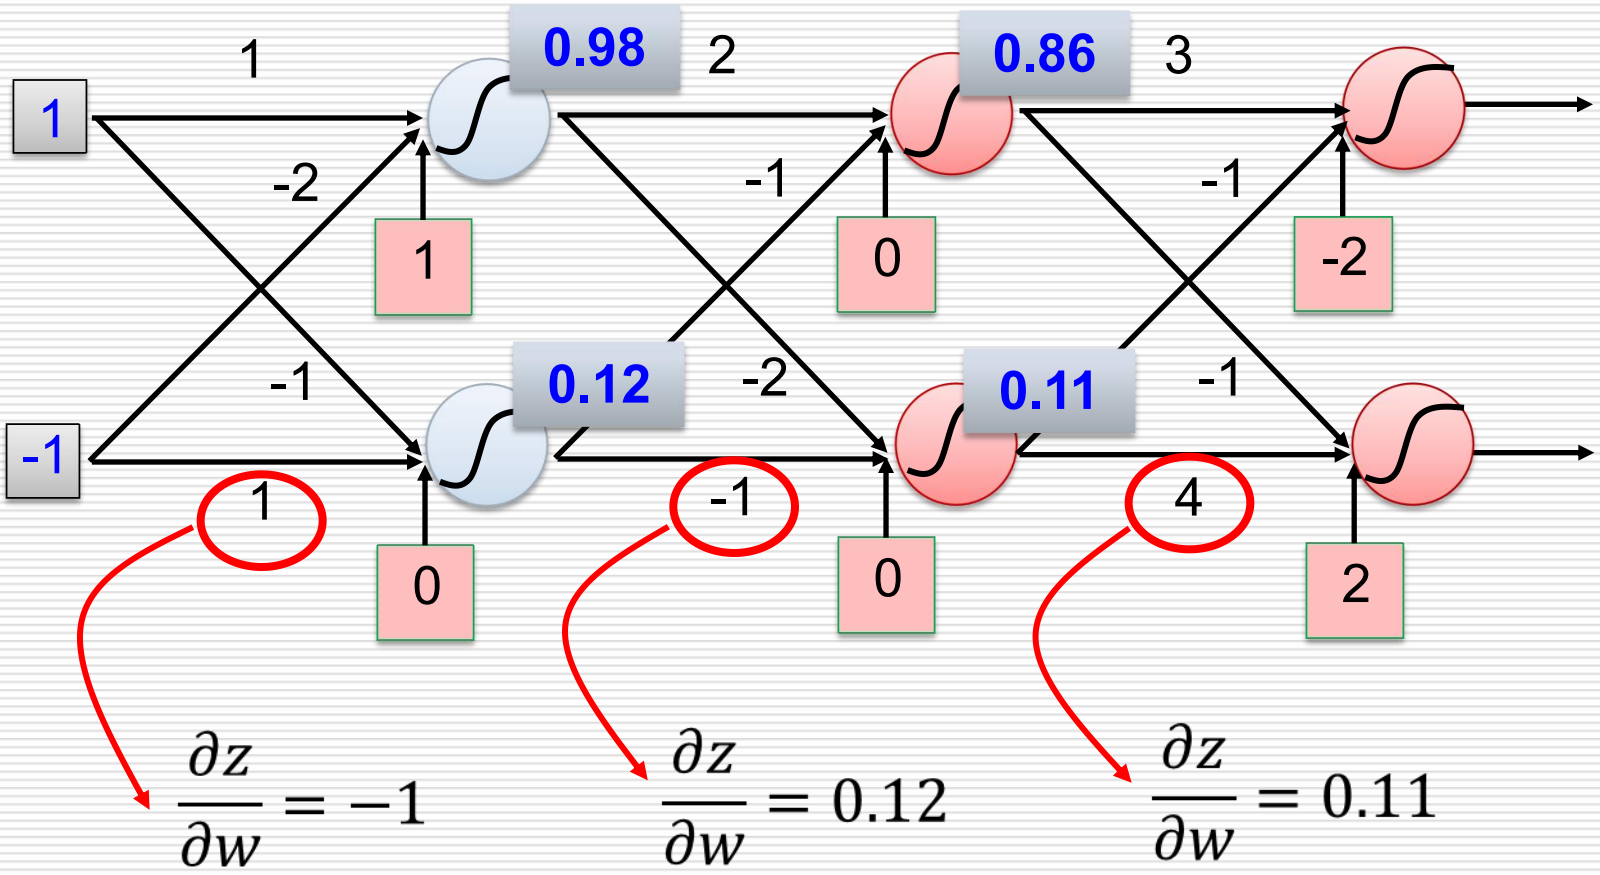
$\partial z/\partial w_1 =?\ x_1$

$\partial z/\partial w_2 =?\ x_2$

} 与权重有连接的输入值

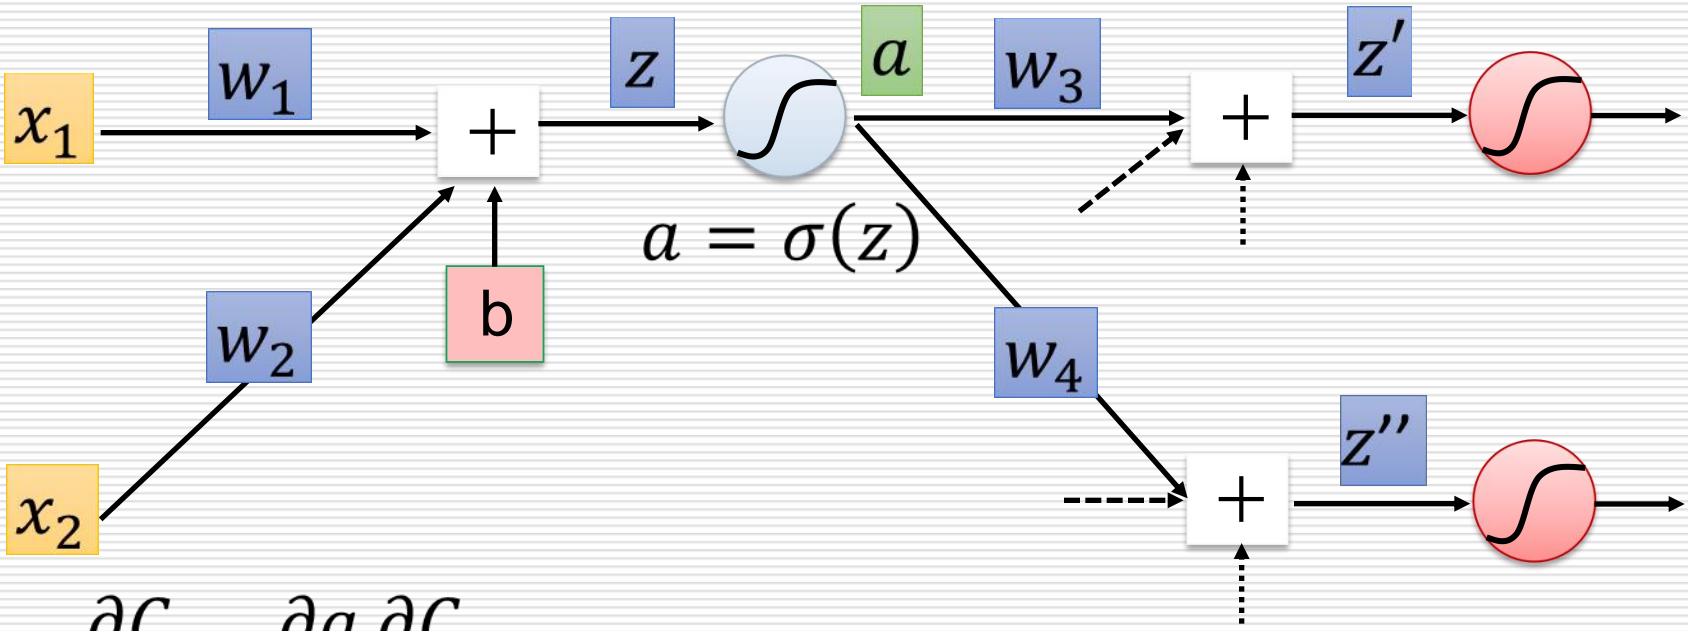
Backpropagation – 前向传播

Compute $\partial z/\partial w$ for all parameters



Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z

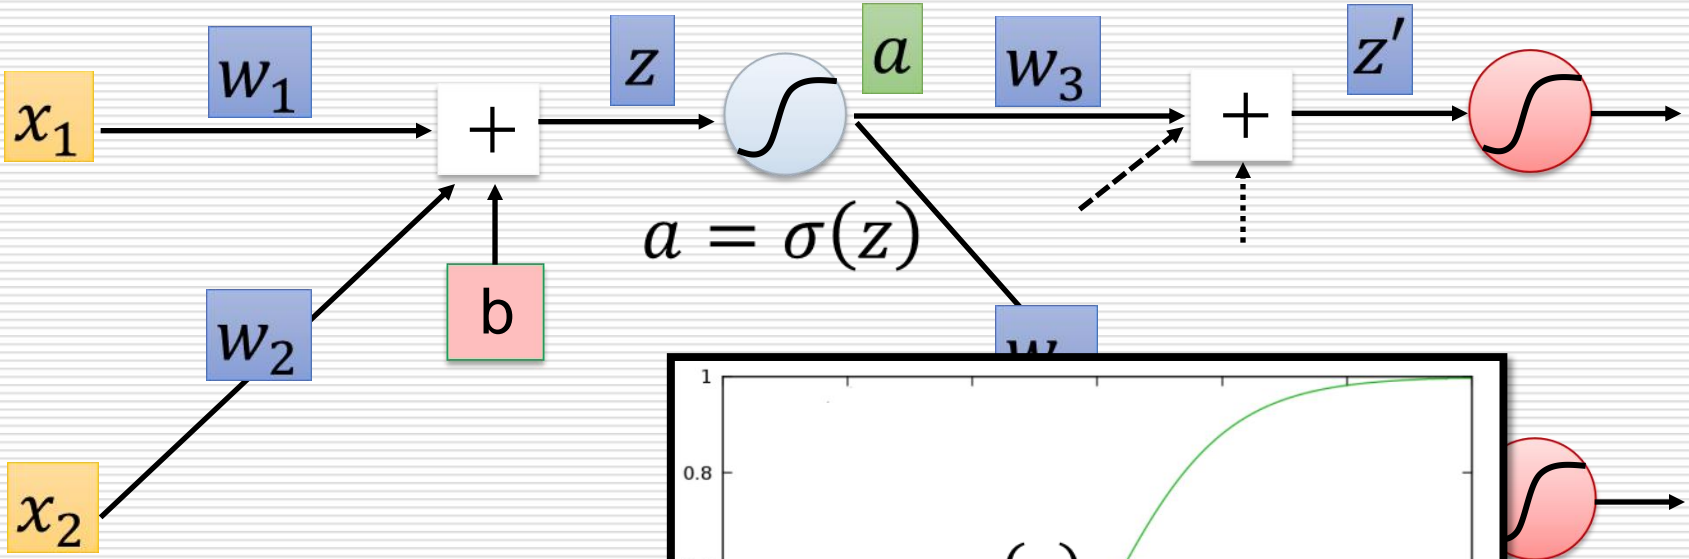


$$\frac{\partial C}{\partial z} = \frac{\partial a}{\partial z}\frac{\partial C}{\partial a}$$

$\sigma'(z)$

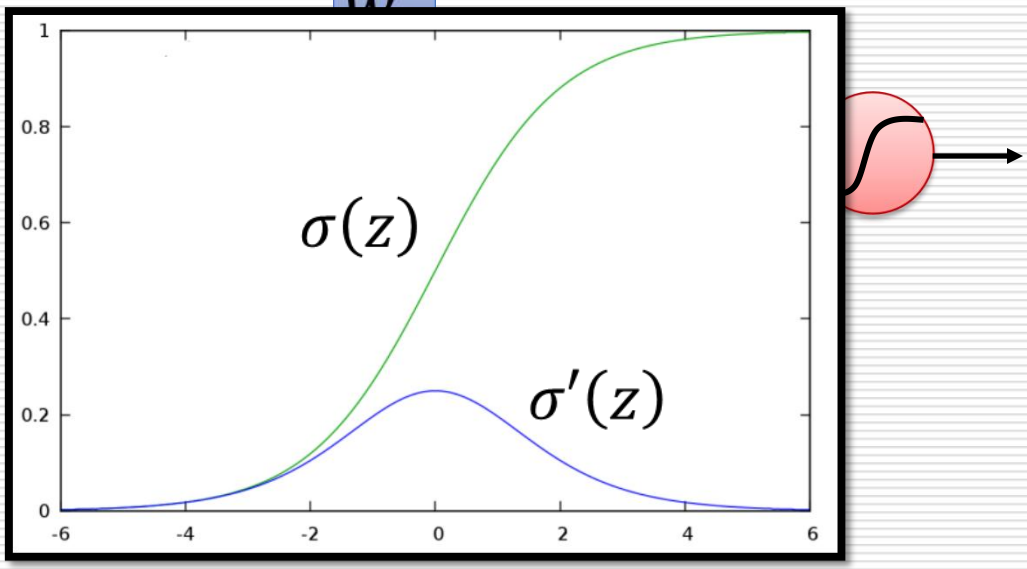
Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z



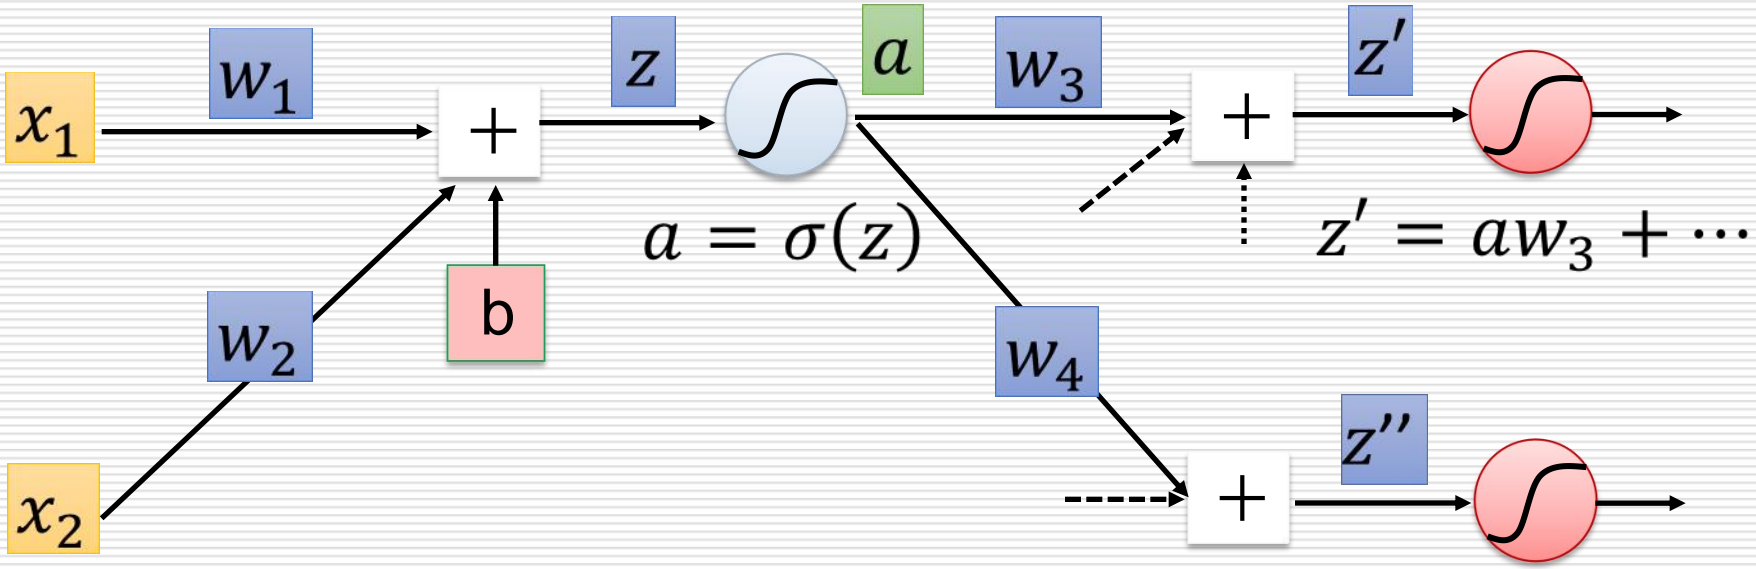
$$\frac{\partial C}{\partial z} = \frac{\partial a}{\partial z}\frac{\partial C}{\partial a}$$

$\Rightarrow \sigma'(z)$



Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z



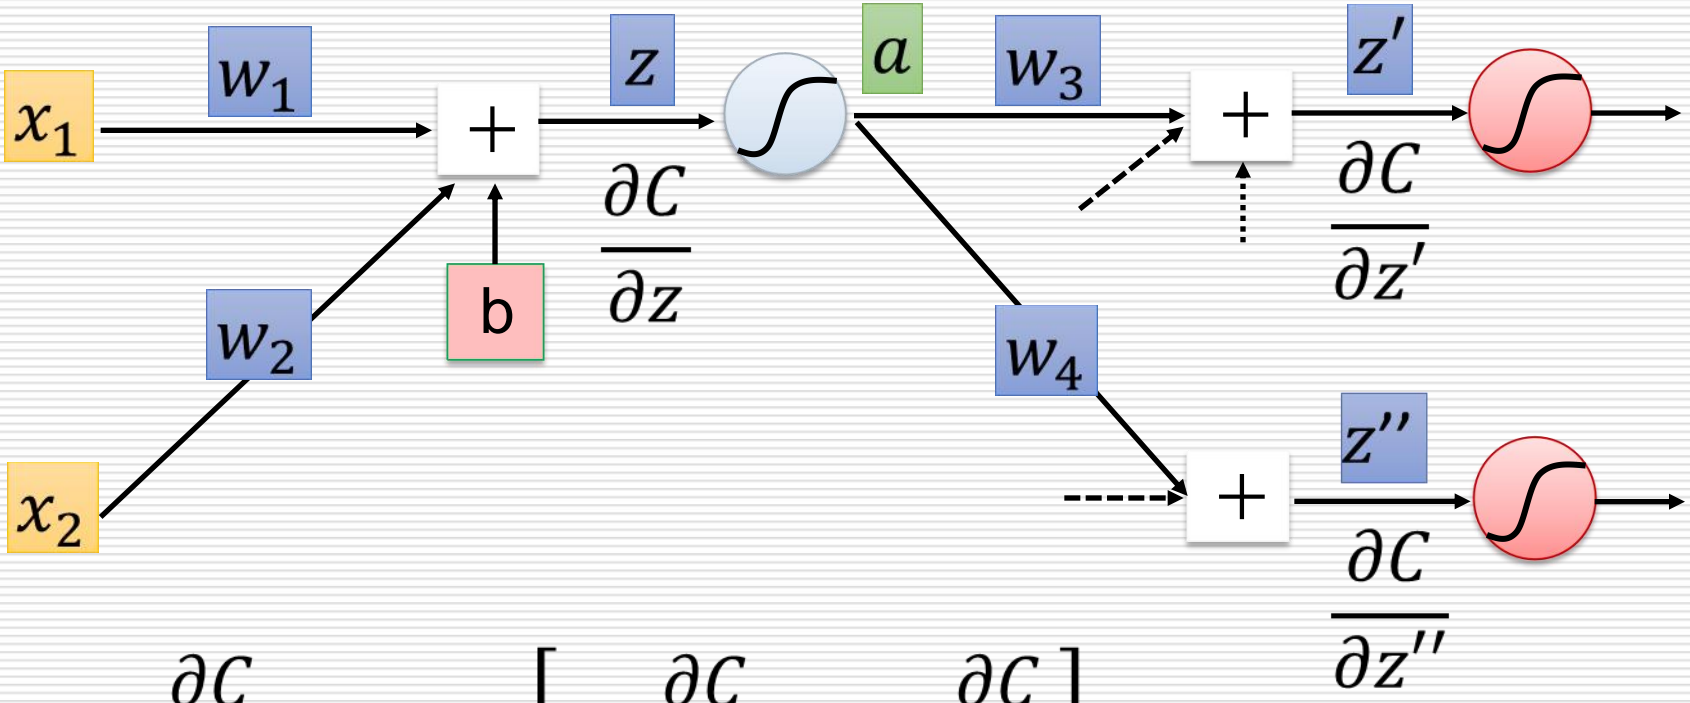
$$\frac{\partial C}{\partial z} = \frac{\partial a}{\partial z}\frac{\partial C}{\partial a} \qquad \frac{\partial C}{\partial a} = \frac{\partial z'}{\partial a}\frac{\partial C}{\partial z'} + \frac{\partial z''}{\partial a}\frac{\partial C}{\partial z''} \text{ (Chain rule)}$$

$\frac{\partial z'}{\partial a} = w_3$, $\frac{\partial C}{\partial z'}$ = ?, $\frac{\partial z''}{\partial a} = w_4$, $\frac{\partial C}{\partial z''}$ = ?

假定这两个偏导数已知

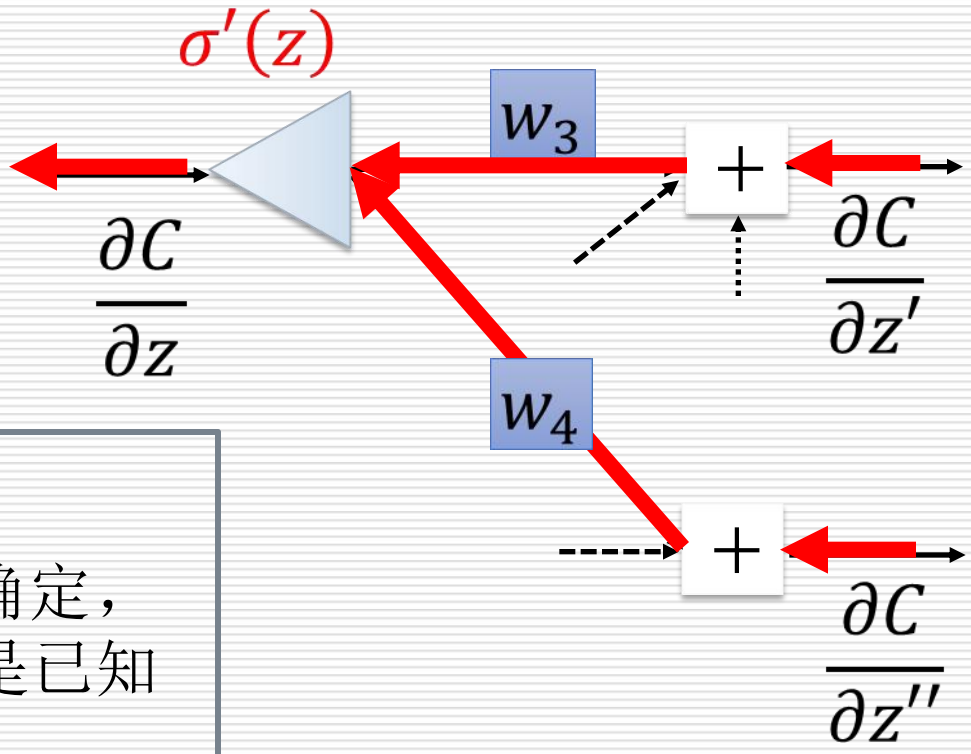
Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z



$$\frac{\partial C}{\partial z} = \sigma'(z)\left[w_3\frac{\partial C}{\partial z'} + w_4\frac{\partial C}{\partial z''}\right]$$

Backpropagation – 后向传播



$\sigma'(z)$

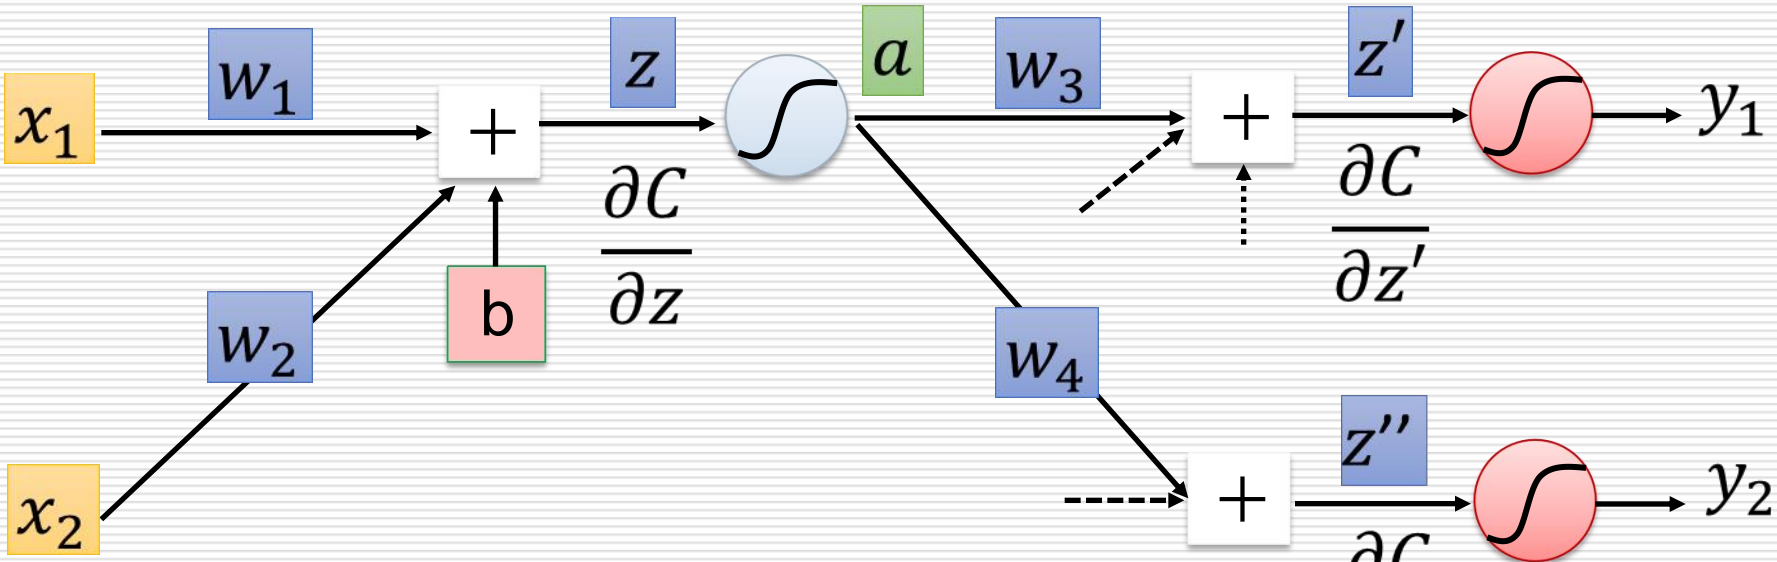
z的值在前向过程中已经确定，而激活函数的导数形式也是已知的，故该值也是已知的。

可解：

$$\frac{\partial C}{\partial z} = \sigma'(z)\left[w_3\frac{\partial C}{\partial z'} + w_4\frac{\partial C}{\partial z''}\right]$$

Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z



Case 1. Output Layer

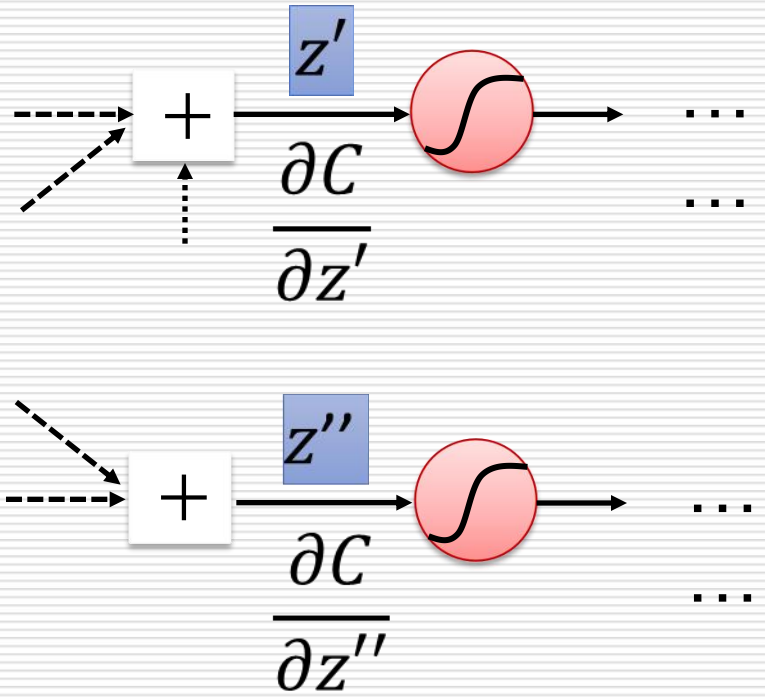
$$\frac{\partial C}{\partial z'} = \frac{\partial y_1}{\partial z'}\frac{\partial C}{\partial y_1} \qquad \frac{\partial C}{\partial z''} = \frac{\partial y_2}{\partial z''}\frac{\partial C}{\partial y_2}$$

Done!

Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z

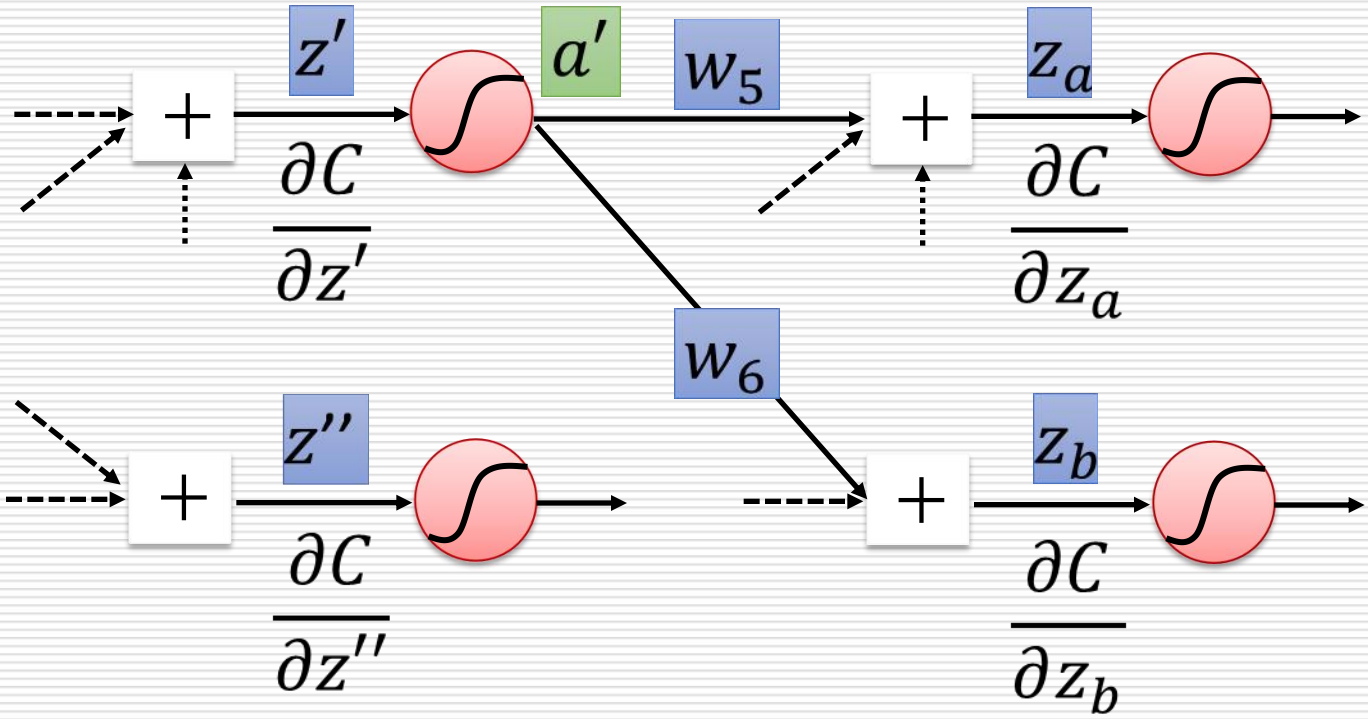
Case 2. Not Output Layer



Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z

Case 2. Not Output Layer

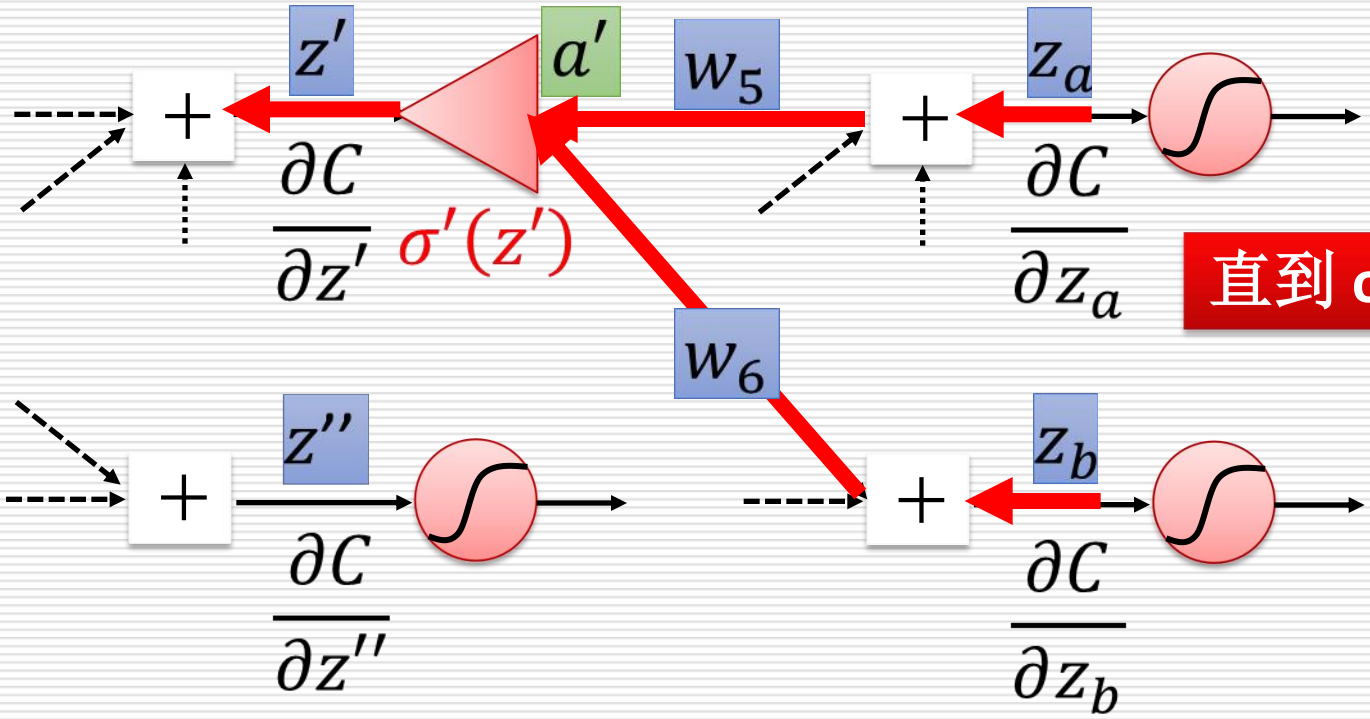


Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z

Case 2. Not Output Layer

Compute $\partial C/\partial z$ recursively

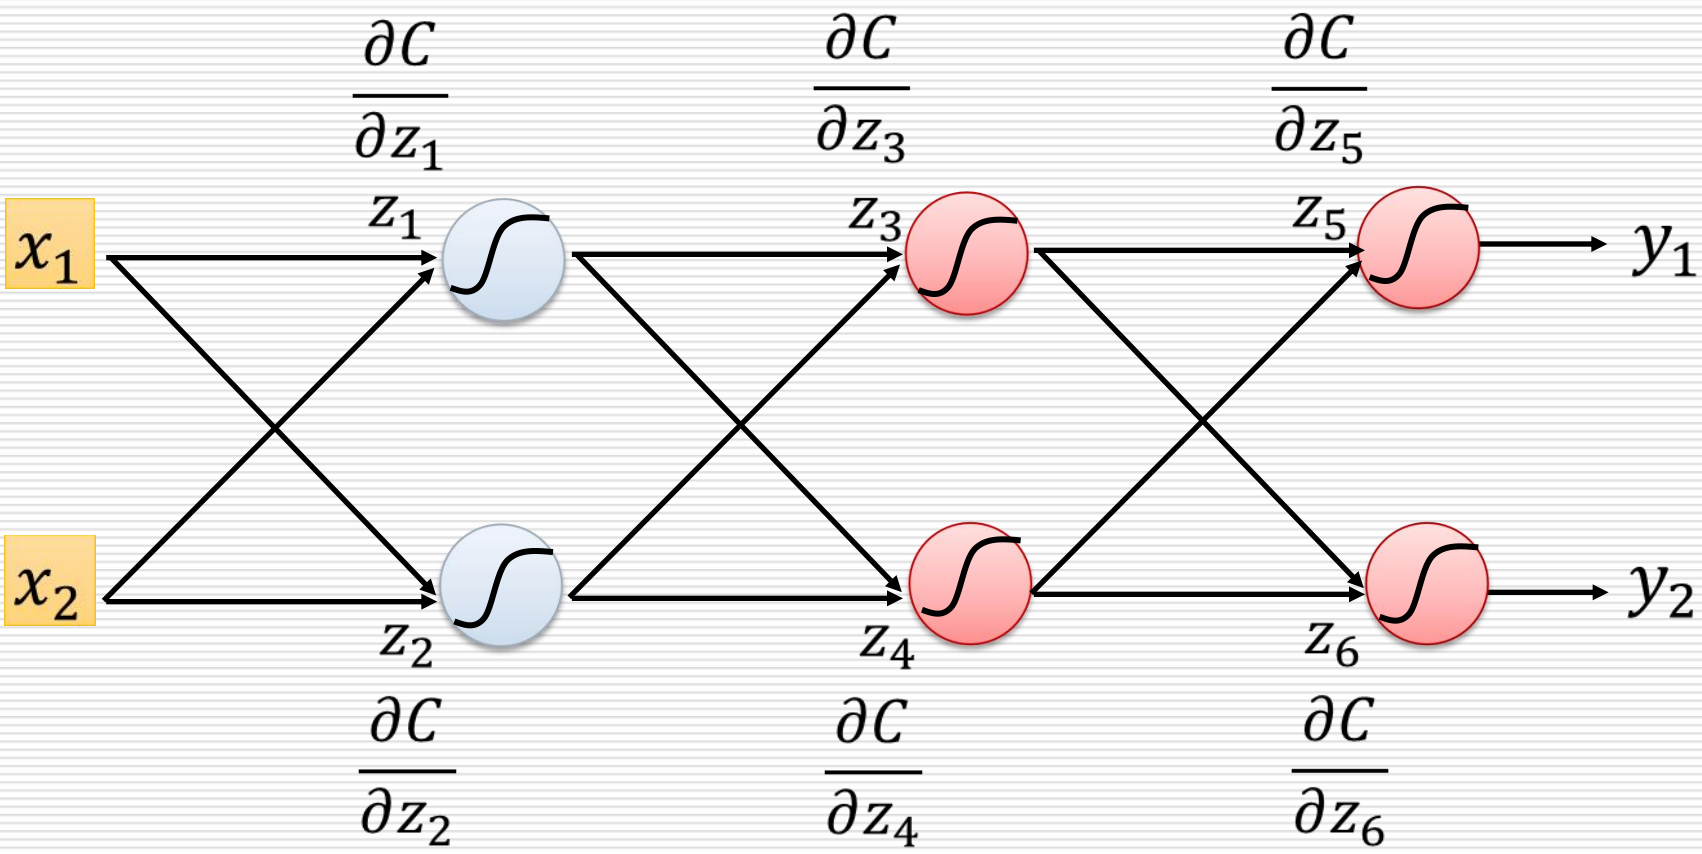


直到 output layer ……

Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z

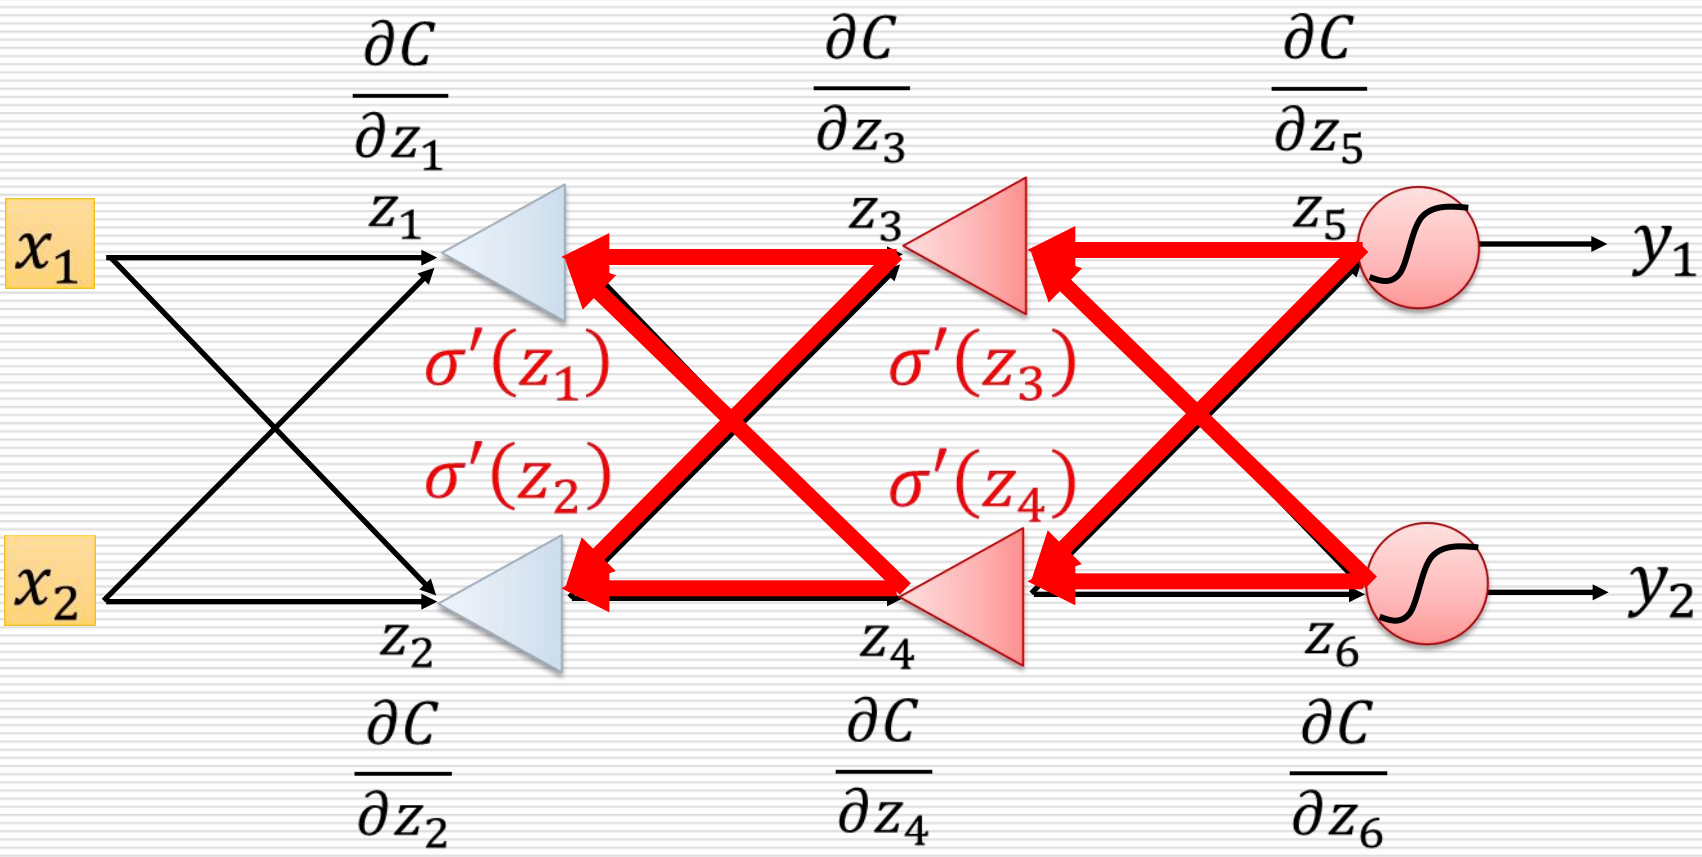
Compute $\partial C/\partial z$ from the output layer



Backpropagation – 后向传播

Compute $\partial C/\partial z$ for all activation function inputs z

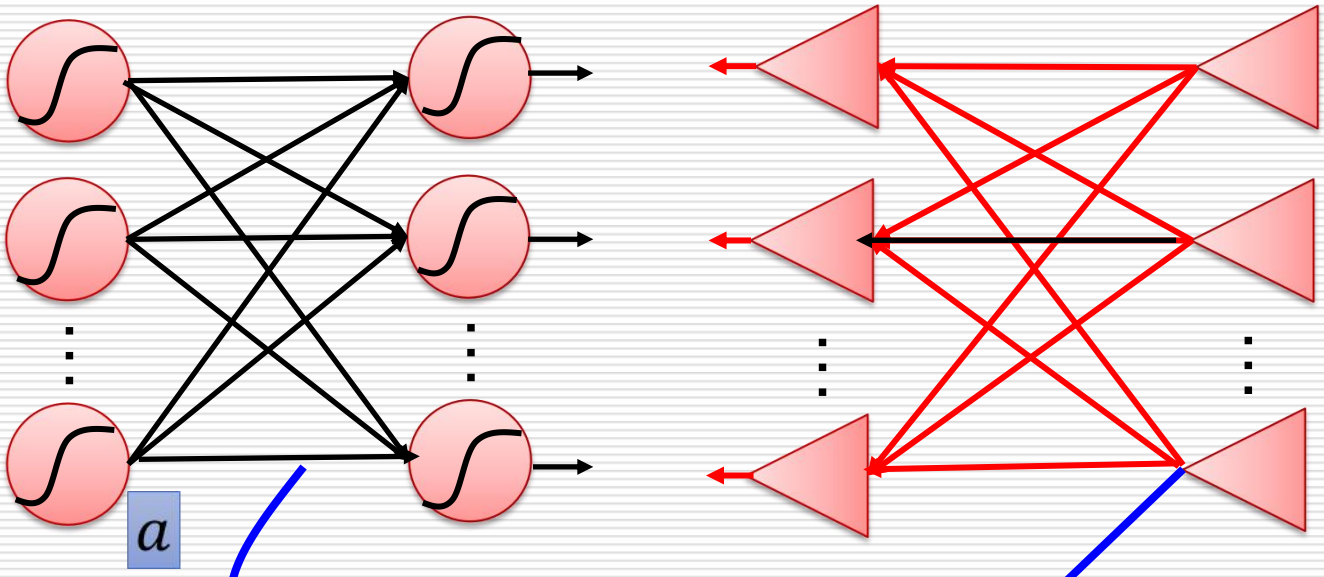
Compute $\partial C/\partial z$ from the output layer



Backpropagation – 小结

Forward Pass

Backward Pass



BP算法的核心步骤

1.前向传播计算输出

2.计算目标损失

3.反向传播计算梯度

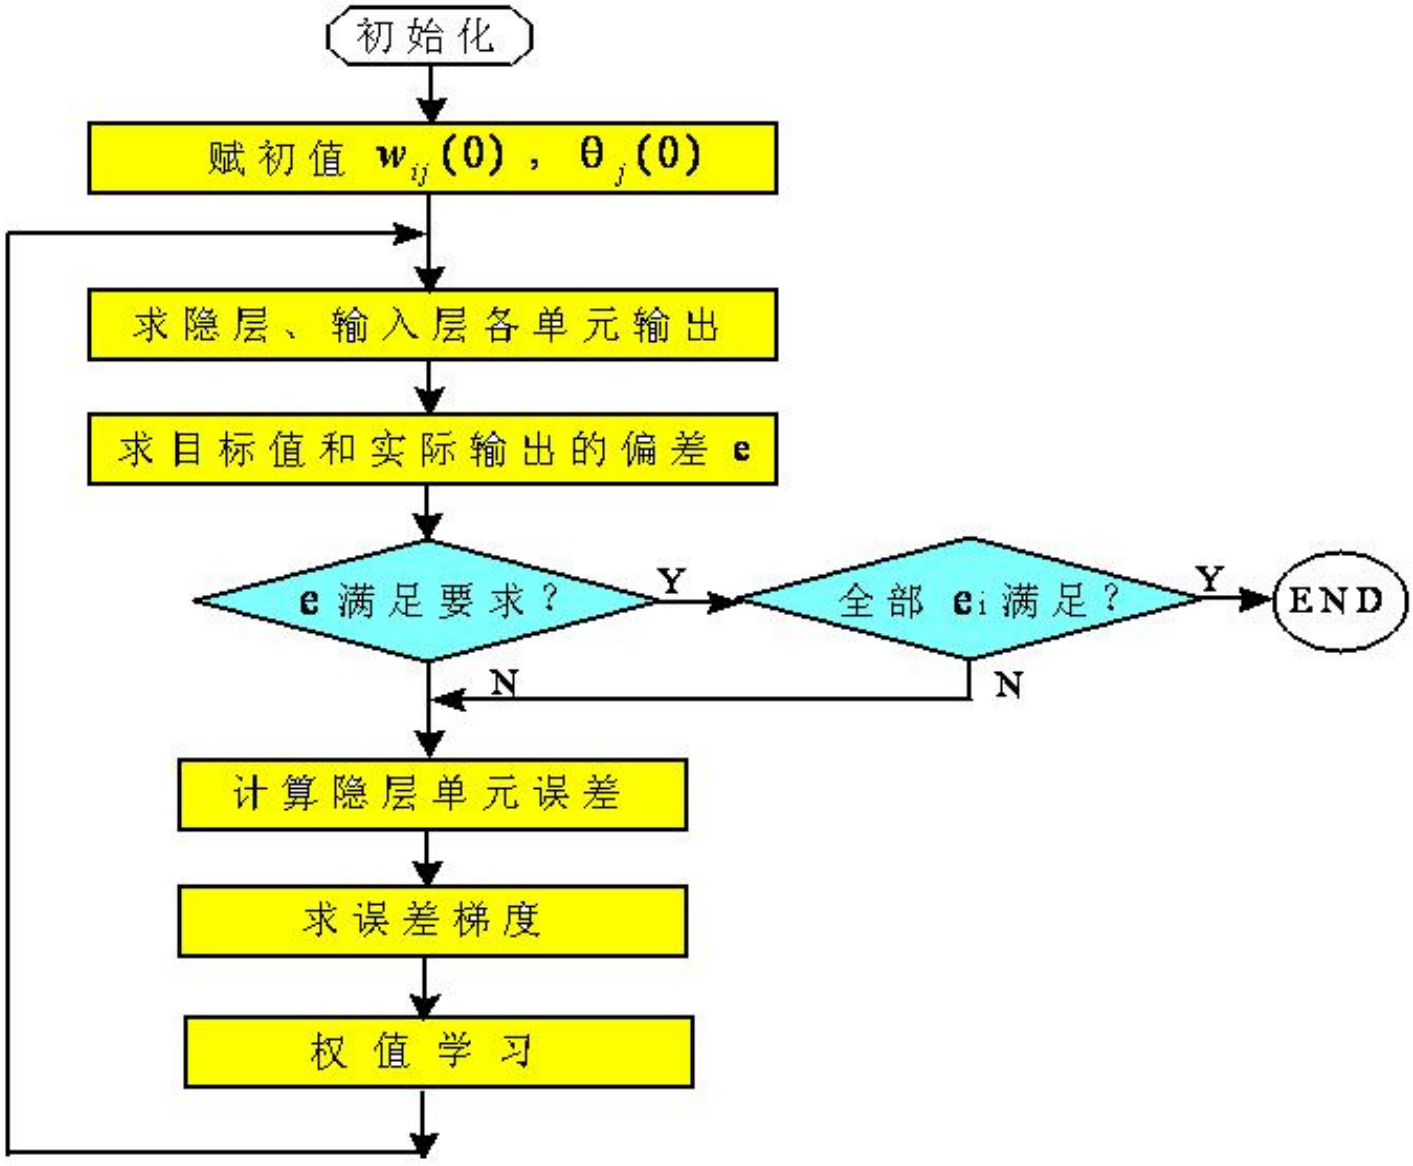
4.更新模型参数

5.重复迭代直至收敛

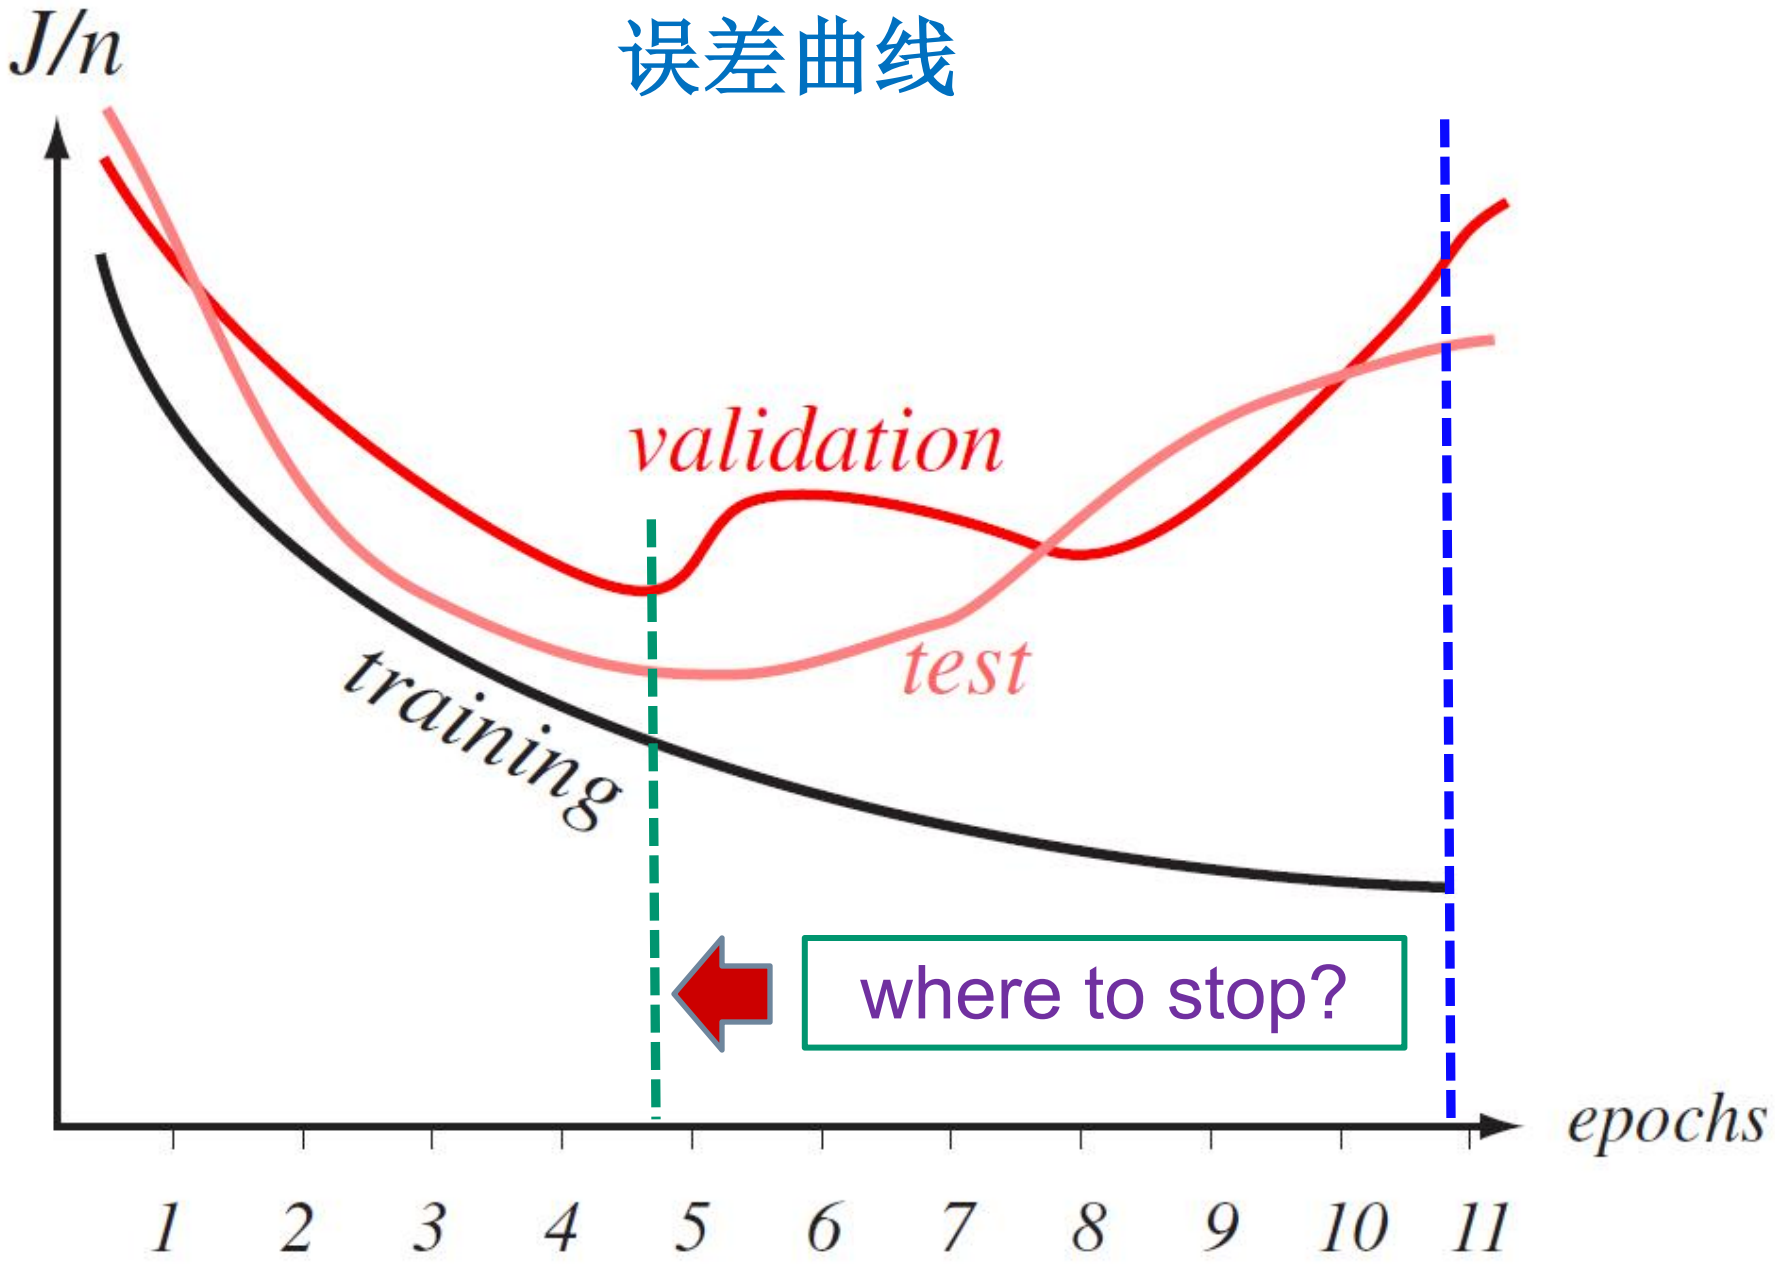
$$\frac{\partial z}{\partial w} = a \quad \times \quad \frac{\partial C}{\partial z} = \frac{\partial C}{\partial w}$$

for all w

BP算法实现流程图


初始化
赋初值 $w_{ij}(0)$，$\theta_j(0)$
求隐层、输入层各单元输出
求目标值和实际输出的偏差 e
e 满足要求？
Y
全部 e_i 满足？
Y
END
N
N
计算隐层单元误差
求误差梯度
权值学习

误差曲线


J/n
validation
test
training
where to stop?
epochs
1
2
3
4
5
6
7
8
9
10
11

人工神经网络及其应用

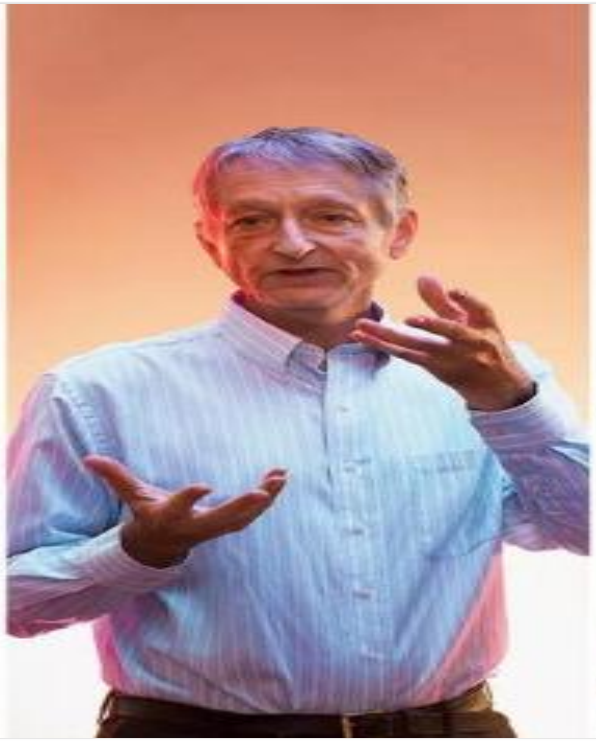
- 神经元与神经网络结构
- 神经网络学习算法
- 卷积神经网络
- 生成对抗网络及其应用

神经网络领域科学家

深度学习3巨头，共同获得2018年度图灵奖



Yann Lecun
美国纽约大学
Meta首席科学家
CNN模型



Geoffrey Hinton
加拿大多伦多大学
深度学习理论
2024年度诺贝尔物理学奖



Yoshua Bengio
加拿大蒙特利尔大学
生成式对抗网络

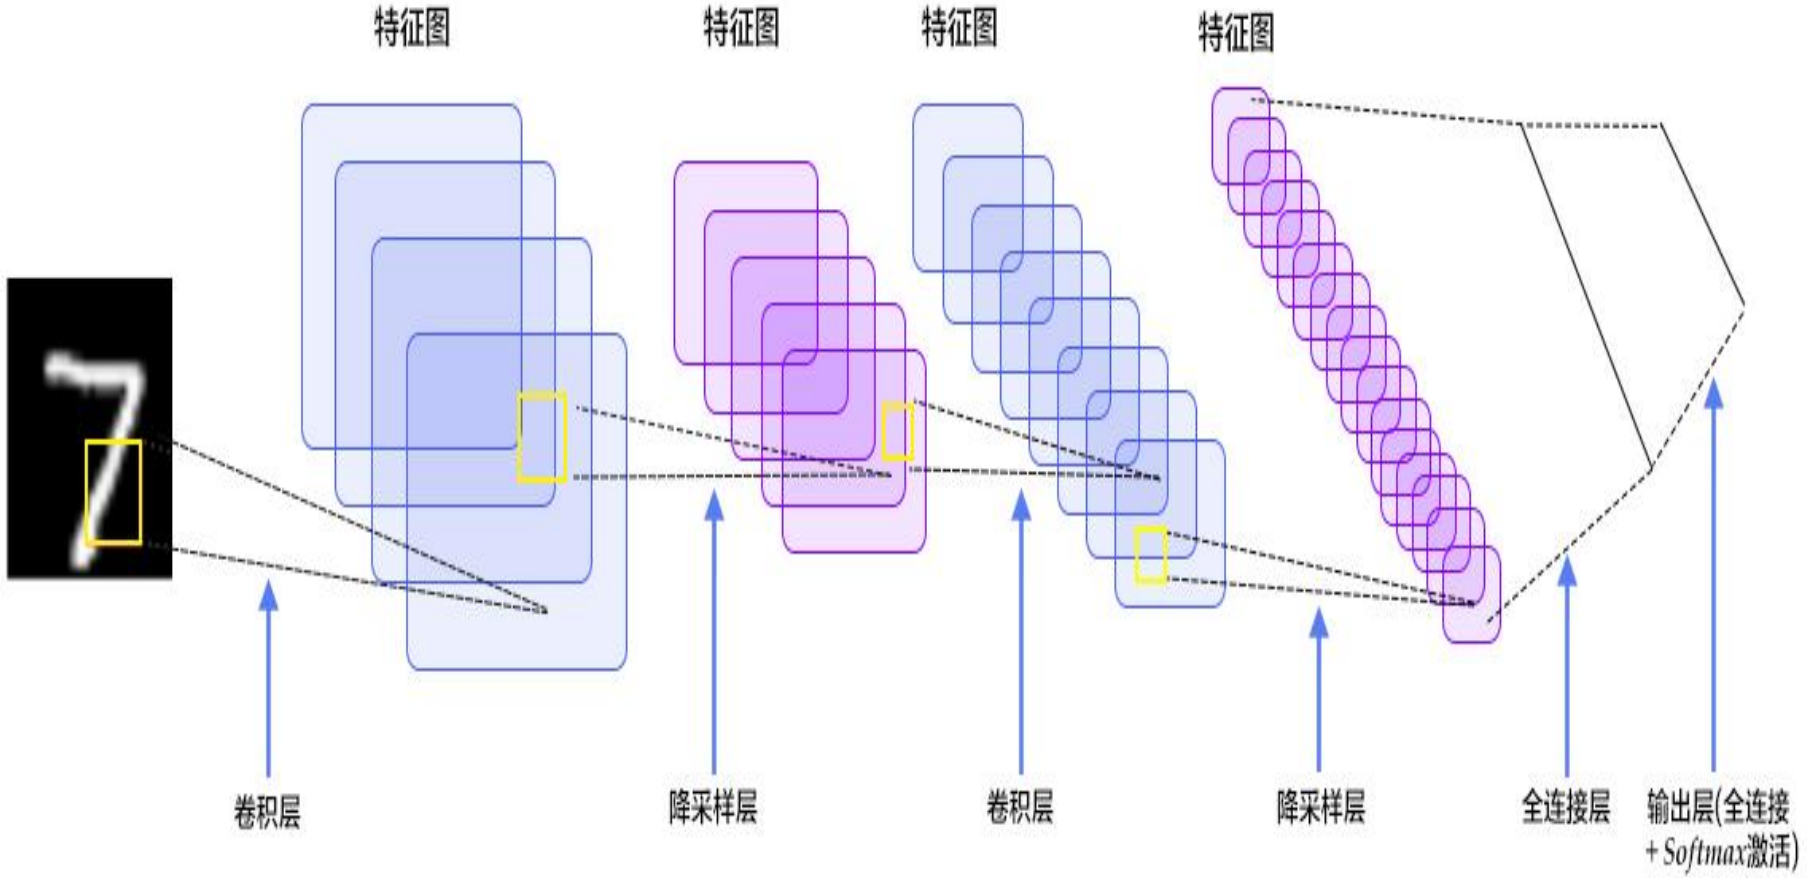
神经网络发展的里程碑

- 1986年，Rumelhart与Hinton提出BP算法。
- 1989年，Yann Lecun提出LeNet，数字识别，卷积网络CNN。
- 2006年，Hinton在SCIENCE发表深度神经网络论文，可以认为是深度学习的起点。
- 2012年，Hinton在ImageNet数据库竞赛中使用CNN获得极高精度，引爆了深度学习的浪潮。AlexNet。
- 2014年，Ian Goodfellow和Bengio提出生成式对抗网络GAN。
- 2015年，何恺明提出残差网络ResNet。
- 2016年，DeepMind发布AlphaGo，CNN+RL，Sutton教授。
- 2017年，Google发表Transformer，大模型的基础框架。
- 2022年，OpenAI发布GPT3.5，并发布ChatGPT，纯文本。
- 2023年，GPT4.0发布，具备多模态功能。
- 2025年，Deepseek，GPT5.0



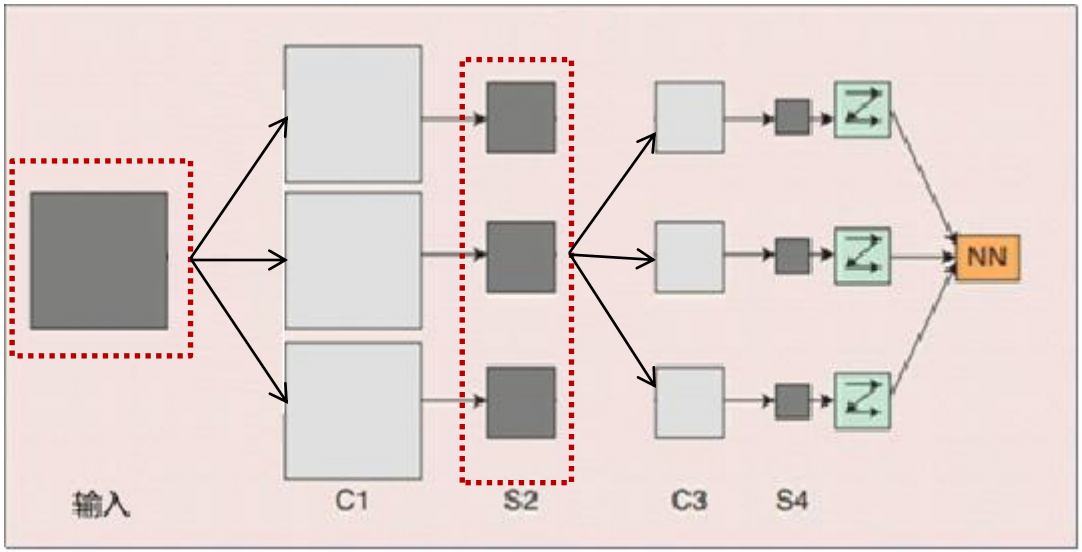
GPU
英伟达公司
黄仁勋

卷积神经网络的结构



卷积神经网络的结构

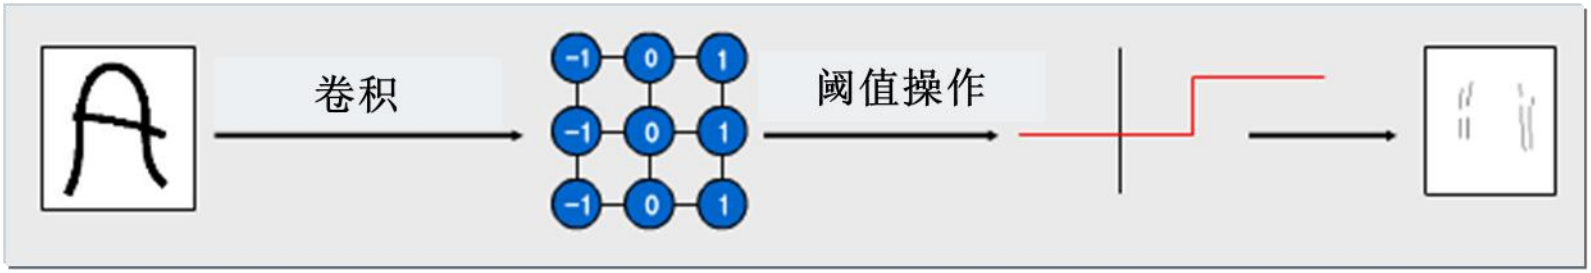
卷积神经网络的结构

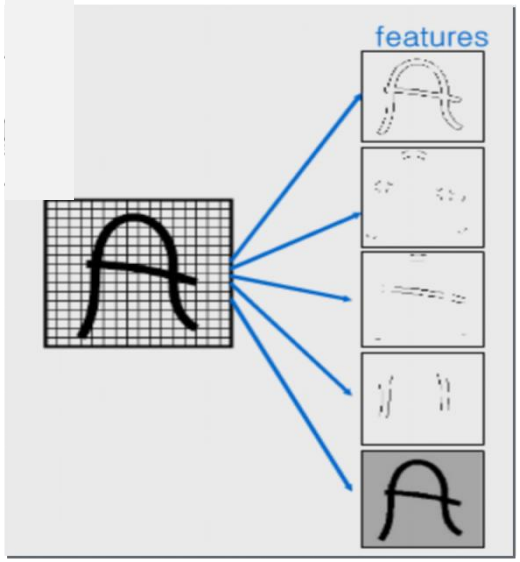


- CNN是一个多层的神经网络，每层由多个二维平面组成，而每个平面由多个独立神经元组成
- C层为特征提取层（卷积层），一个卷积模板（滤波器）产生一个特征图。
- S层是特征映射层（池化层（Pooling）/下采样层）（可选）
- CNN中的每一个C层一般都紧跟着一个S层。

卷积神经网络的结构

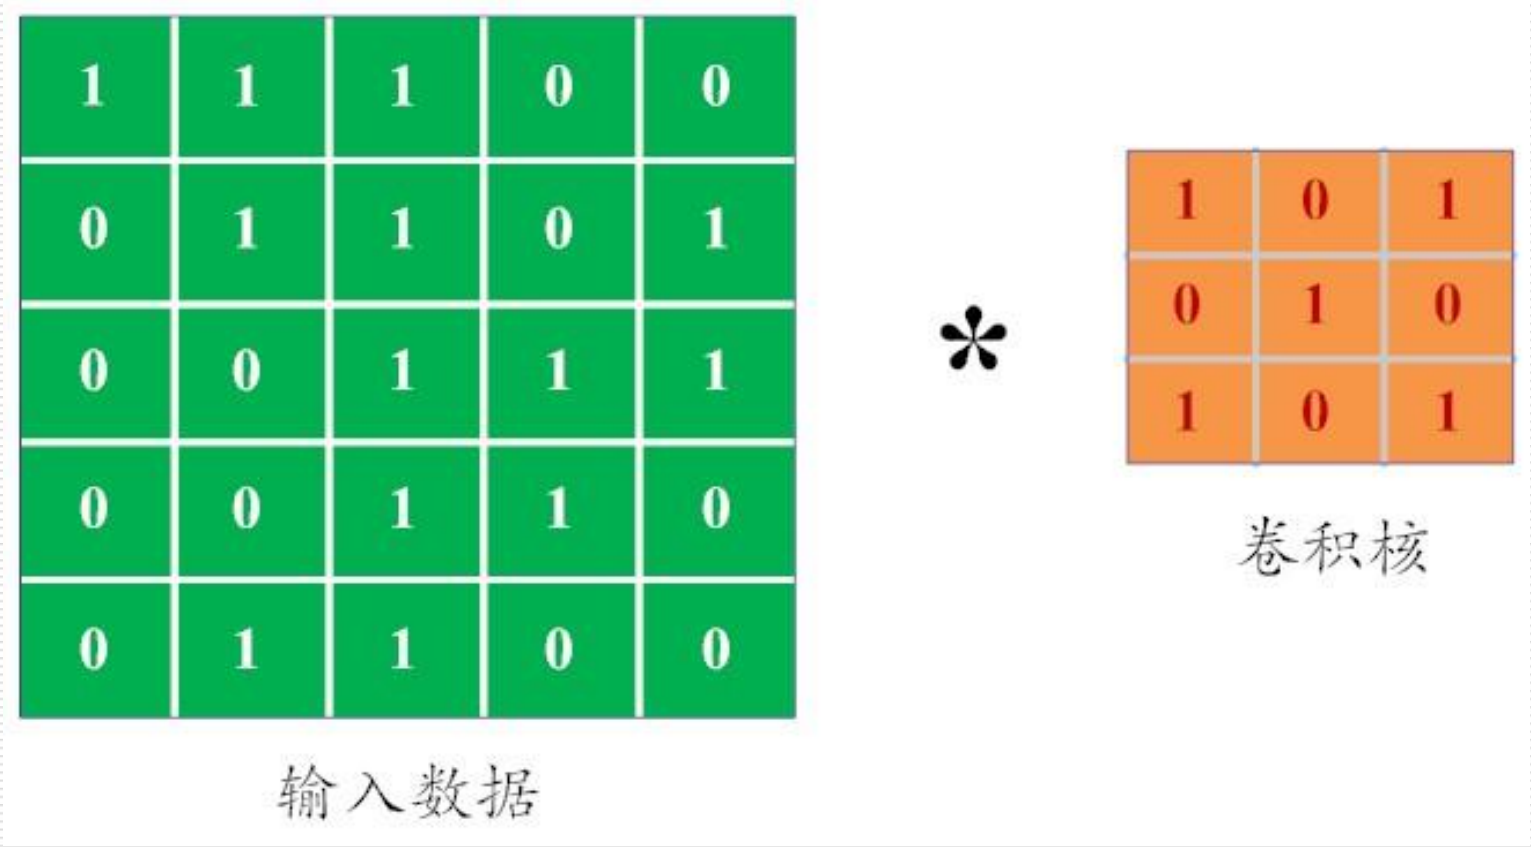
- 特征提取层（卷积层）——C层（Convolution layer）



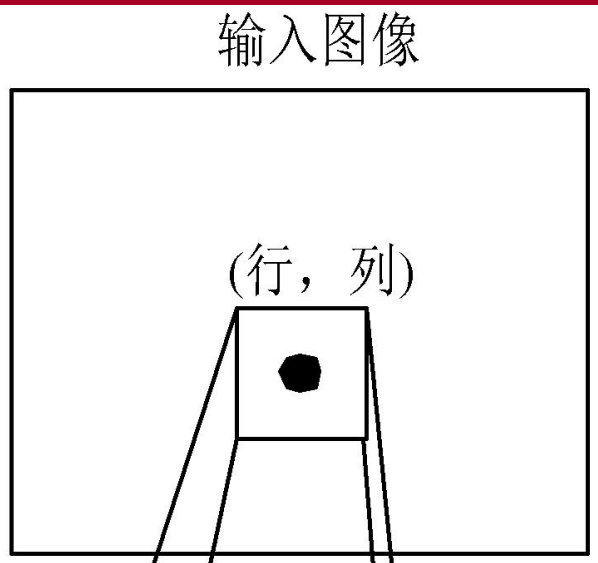


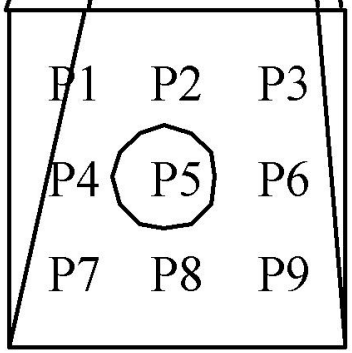
- 大部分的特征提取都依赖于卷积运算
- 利用卷积算子对图像进行滤波，可以得到显著的边缘特征。

卷积神经网络的卷积运算



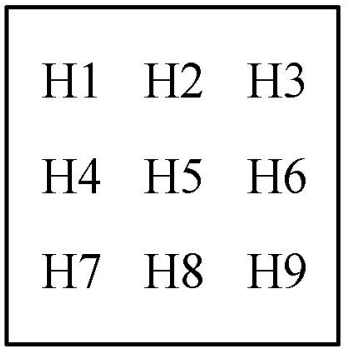
卷积神经网络的卷积运算





3×3 邻域

*



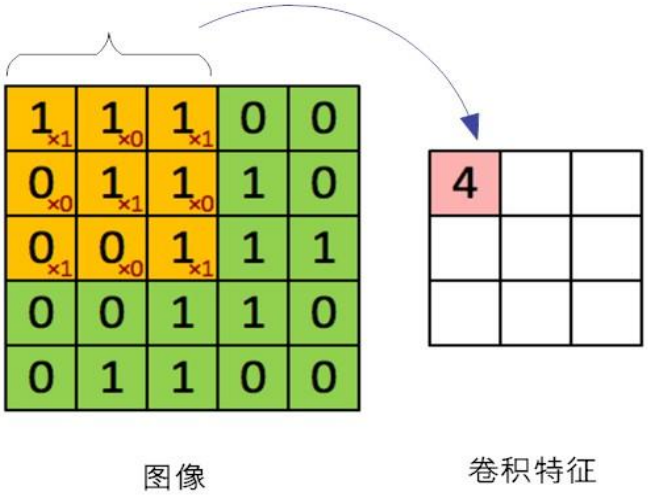
3×3 卷积核

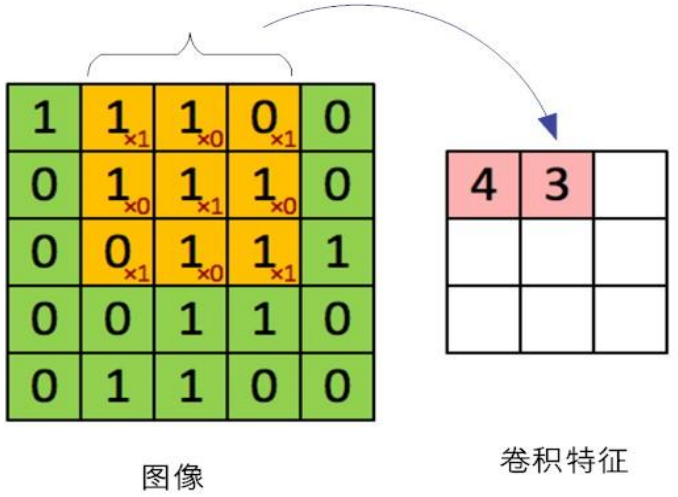
加权和计算：

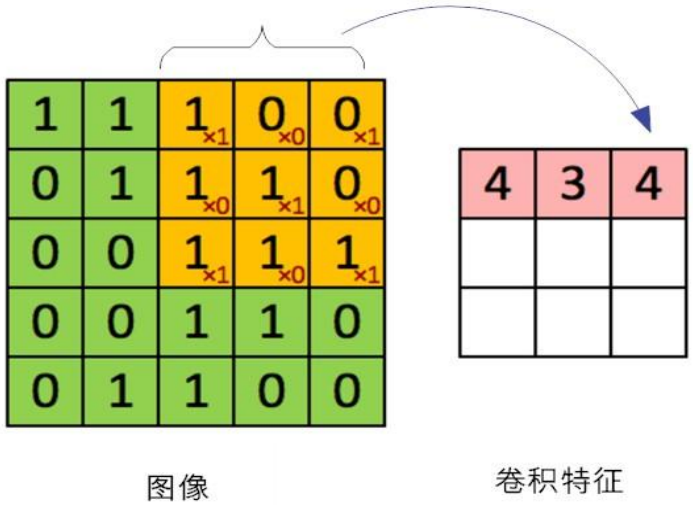
H1·P1＋
H2·P2＋
H3·P3＋
H4·P4＋
H5·P5＋
H6·P6＋
H7·P7＋
H8·P8＋
H9·P9＋

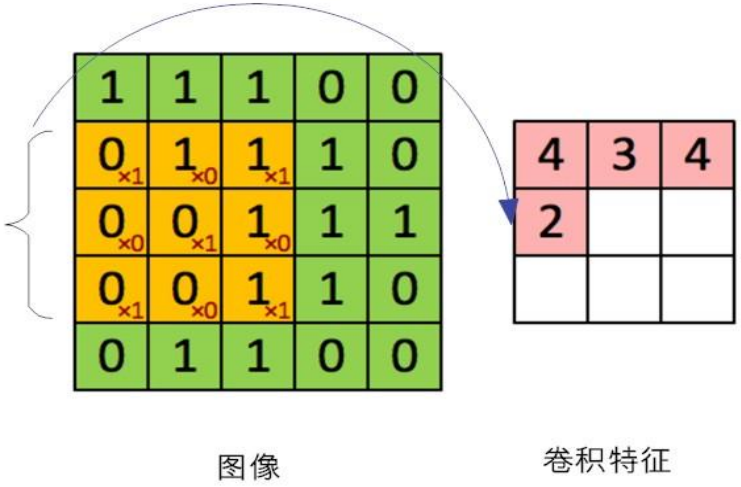
P5的新值

卷积神经网络的卷积运算



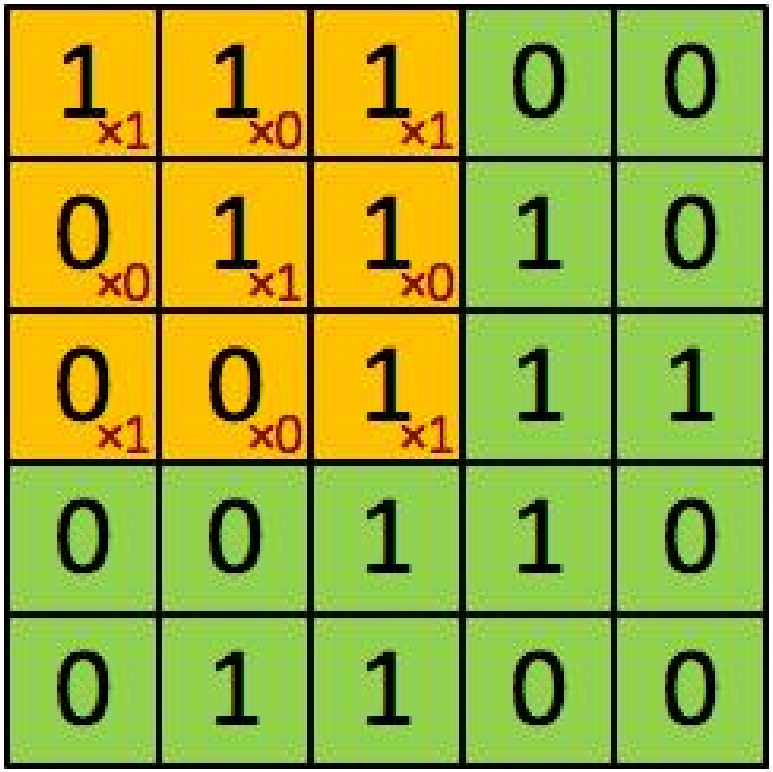




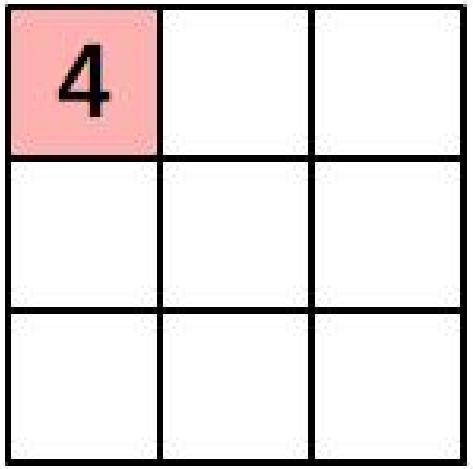


卷积神经网络的卷积运算

标准卷积后的特征图尺寸会小于输入图，边界处无法进行卷积运算



Image



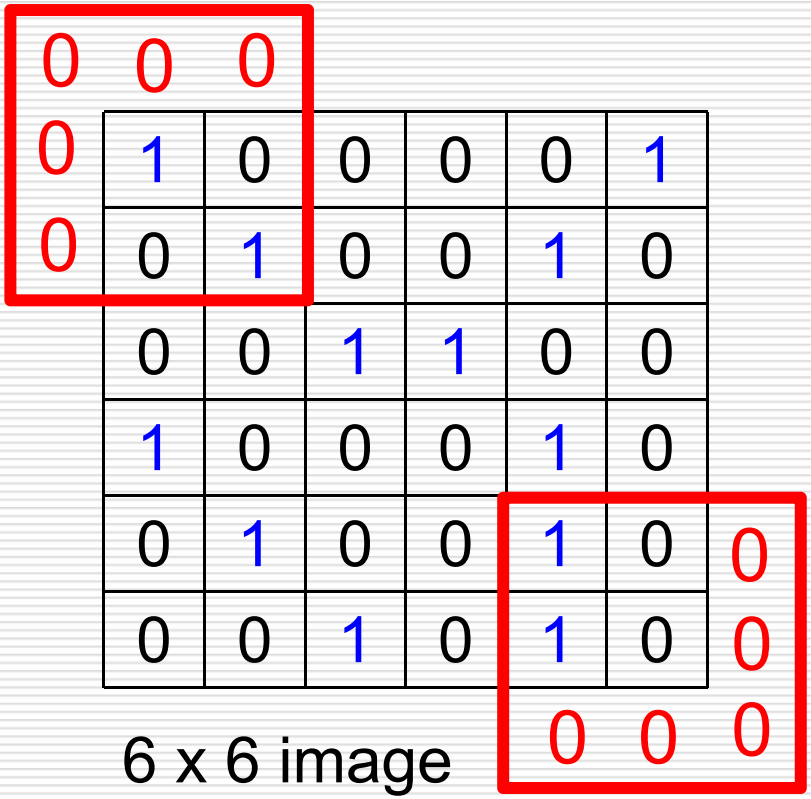
Convolved Feature

卷积神经网络的卷积运算

CNN – Zero Padding

1	-1	-1
-1	1	-1
-1	-1	1

卷积模板

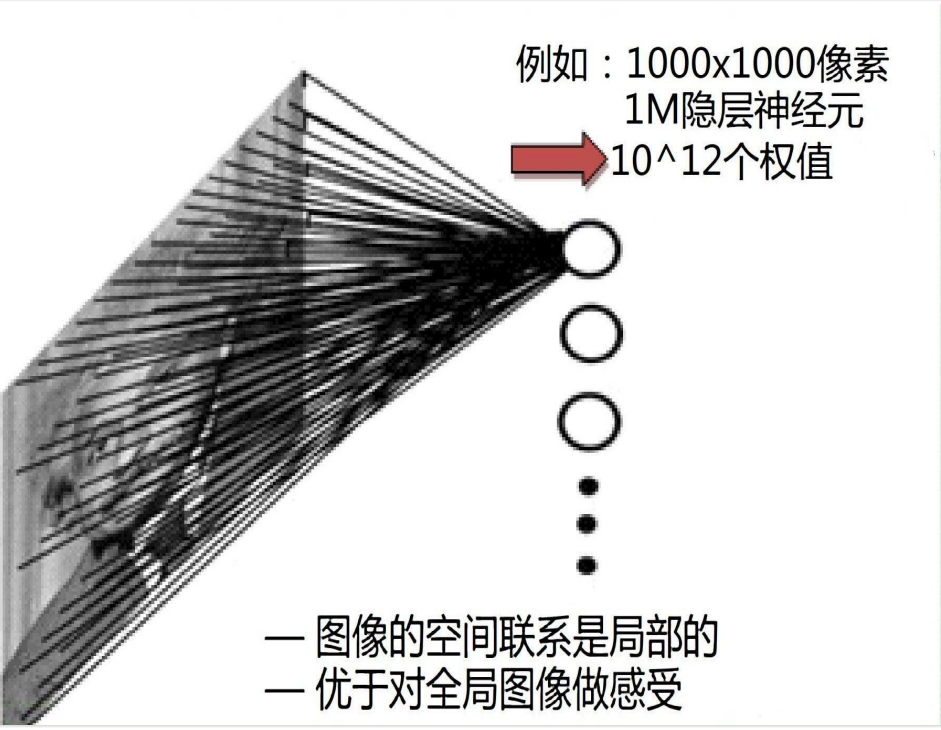


Zero padding

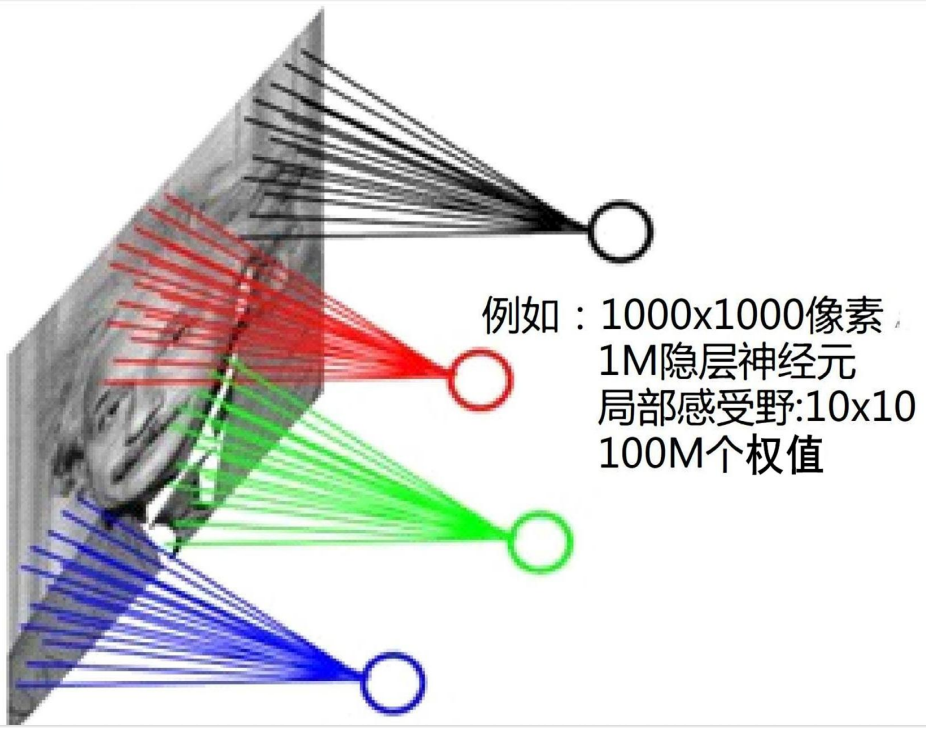
卷积后的图像尺寸大小不变，仍为6 x 6

卷积神经网络中的关键技术

- 局部链接



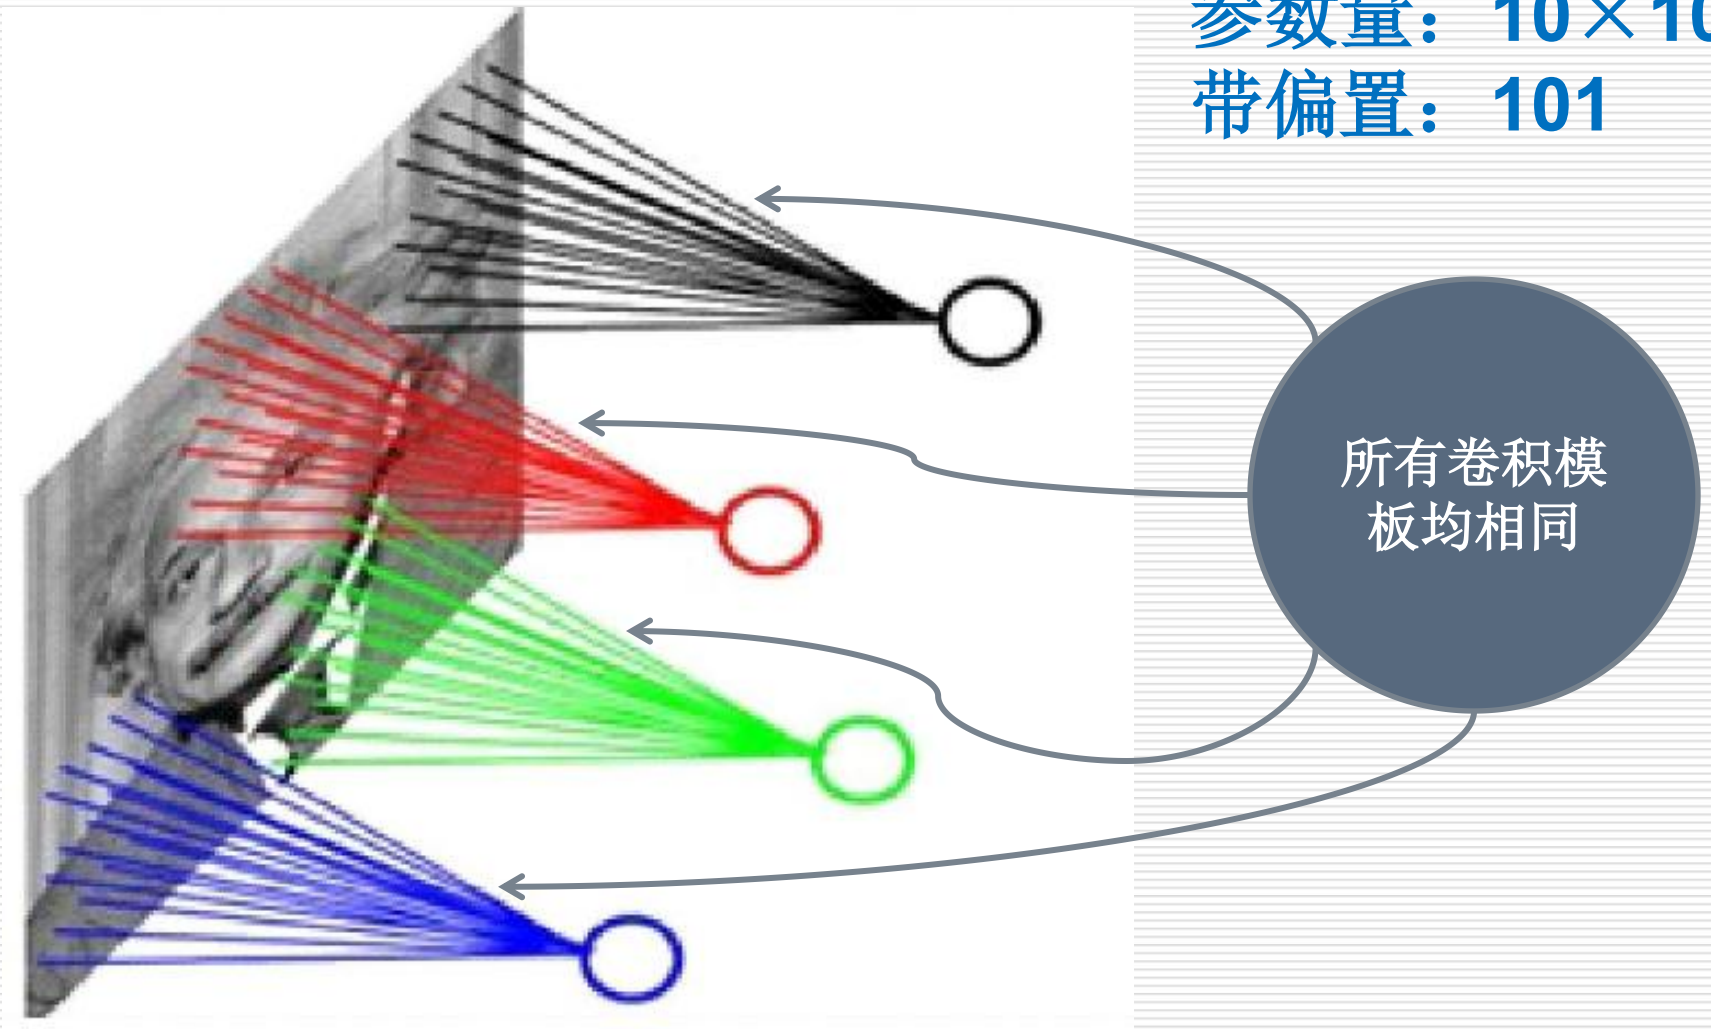
(a) 全连接神经网络



(b) 局部连接神经网络

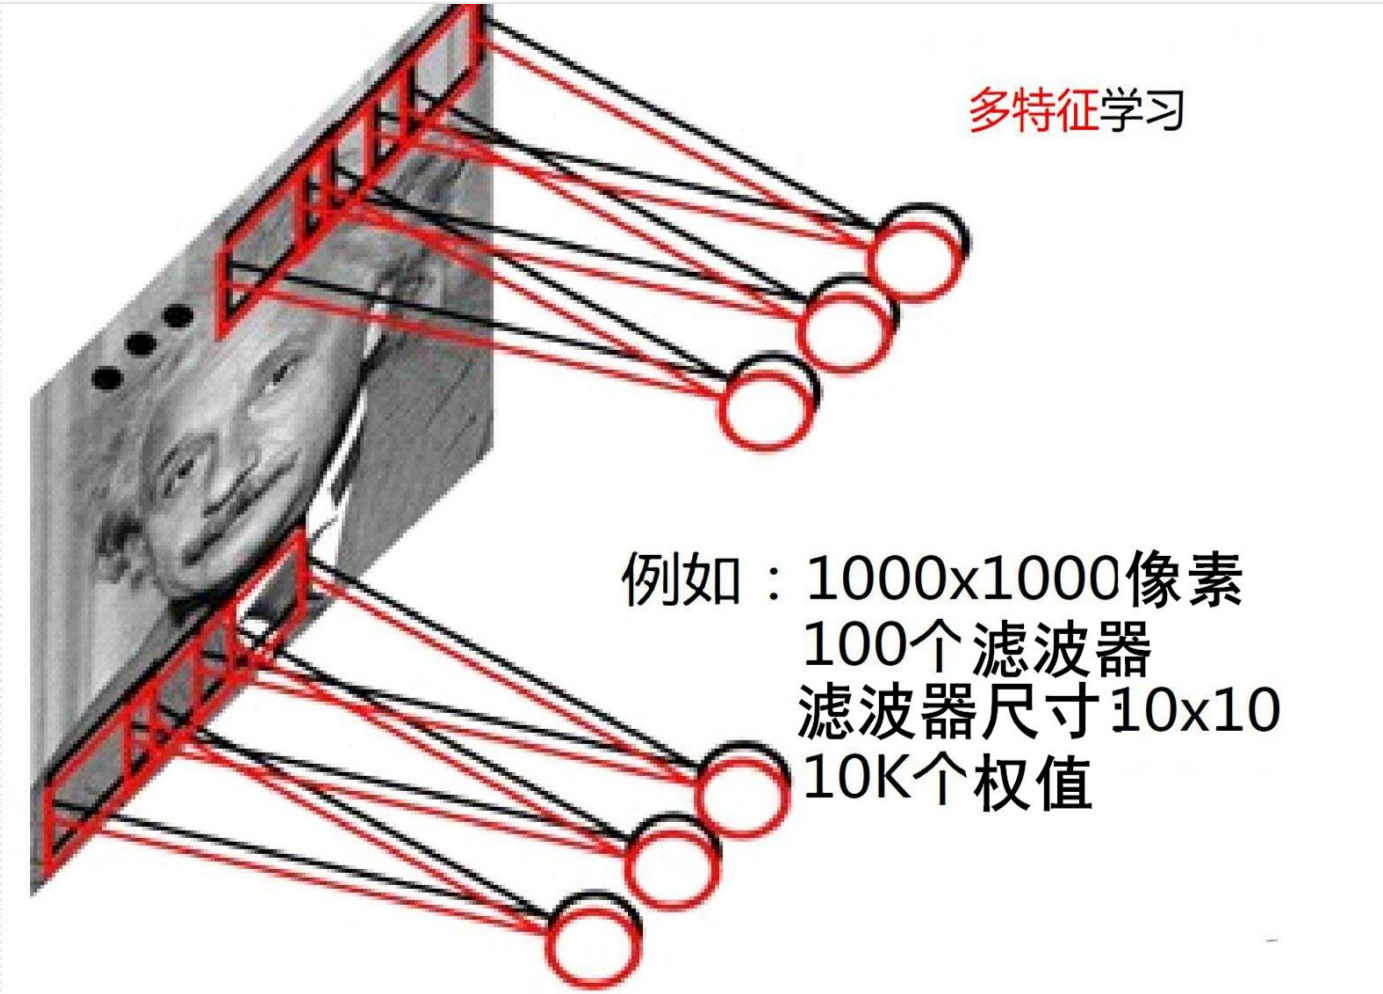
卷积神经网络中的关键技术

- 权值共享



卷积神经网络中的关键技术

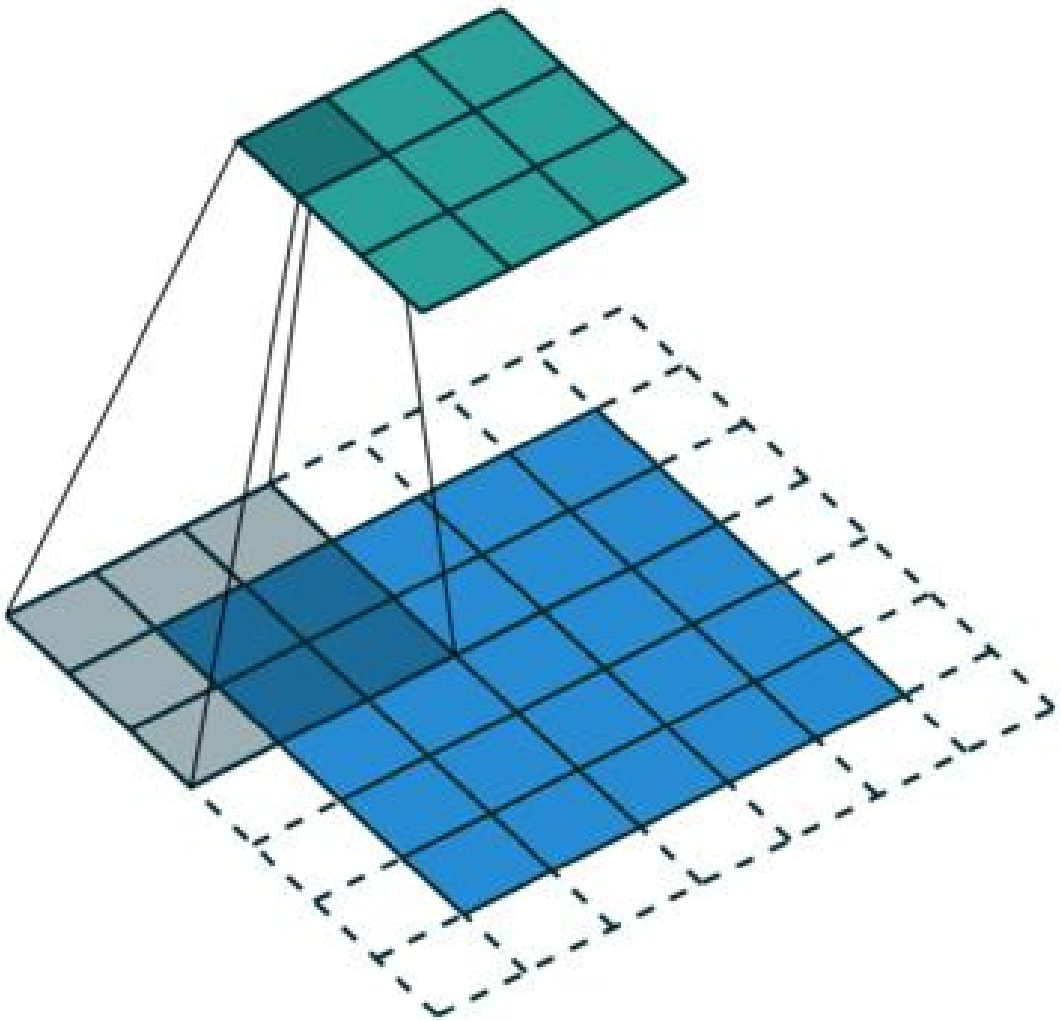
- 多卷积核



卷积神经网络中的关键技术

滑动过程示意图

局部感受野



权值共享

卷积神经网络中的关键技术

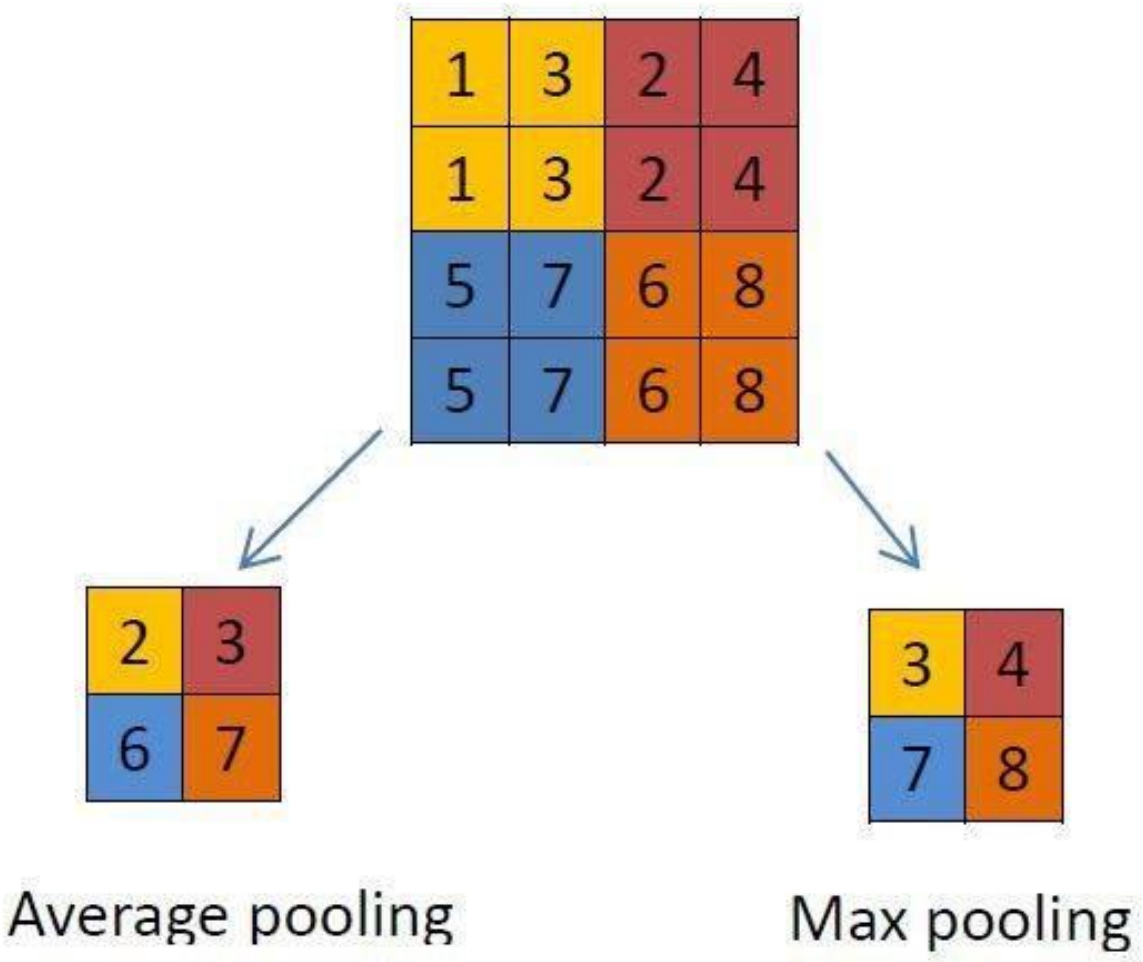
池化

- 对不同位置的特征进行聚合统计,称为池化 (pooling)。
- 池化常用方法：平均池化、最大池化。

卷积神经网络中的关键技术

池化应用示例

下采样



降低特征维度

卷积神经网络中的关键技术

池化的作用

- **降低特征维度**

通过卷积获得了特征之后，如果直接利用这些特征训练分类器，计算量是非常大的。（卷积核的数量巨大）

- **扩大感受野**

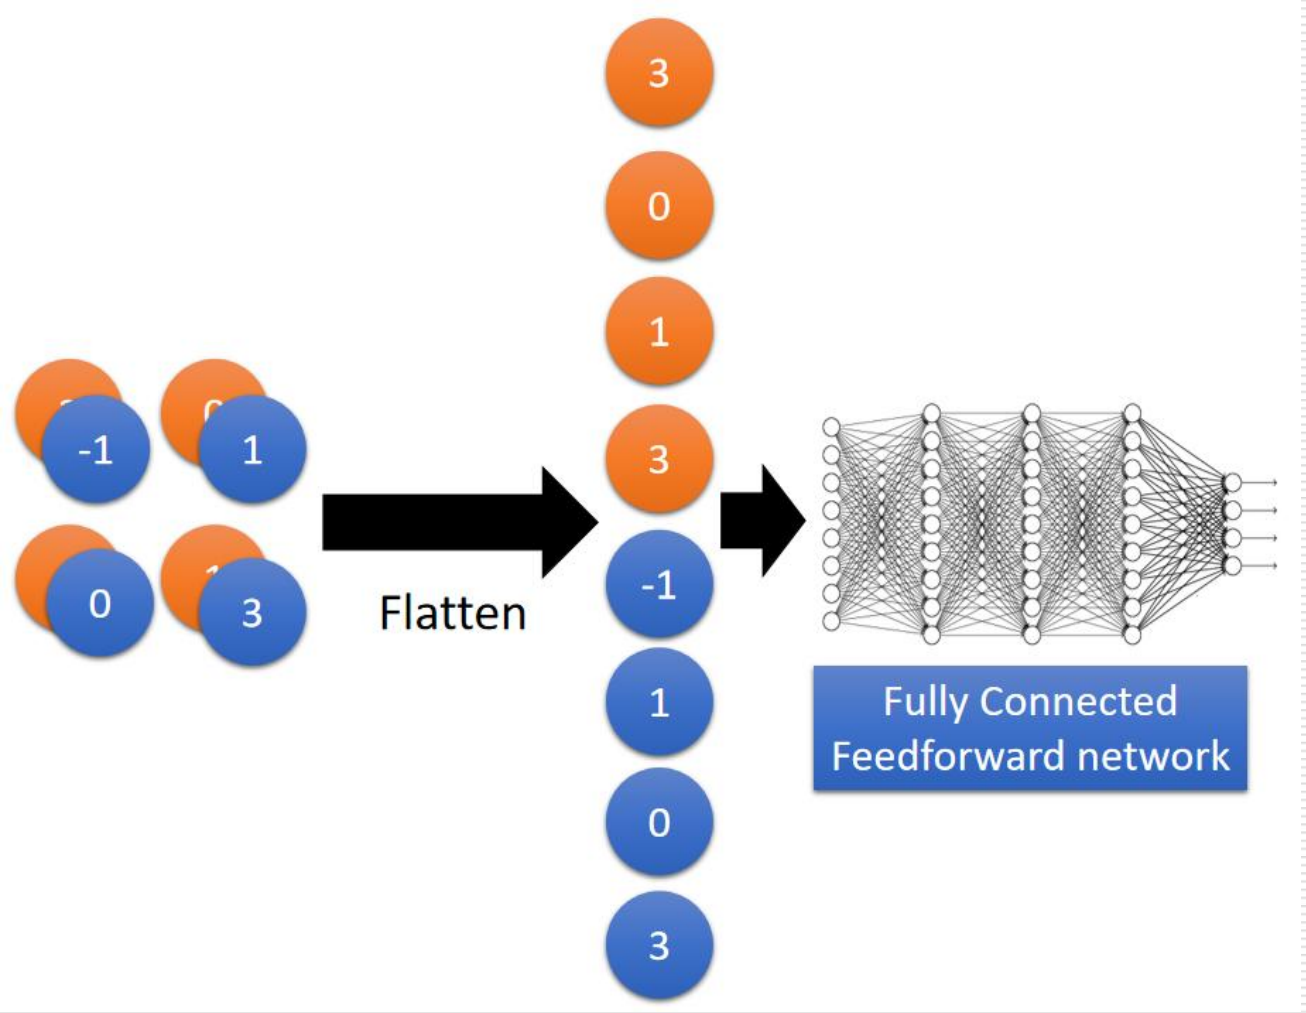
让后续的卷积层能够“看到”输入图像中更广阔的区域。

- **引入平移不变性**

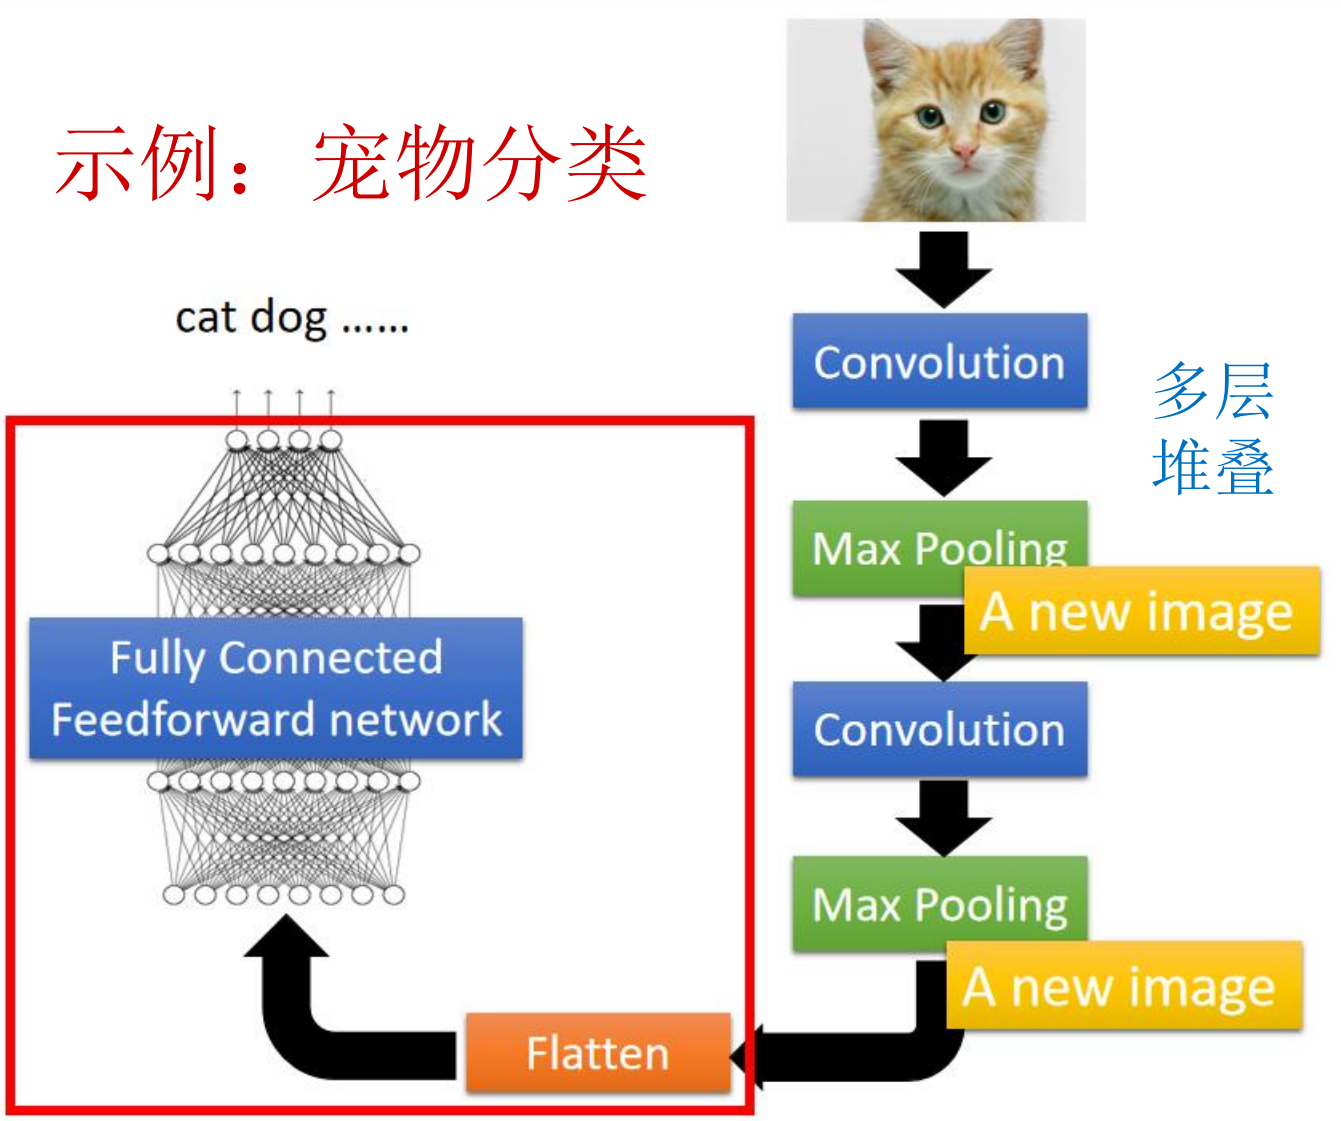
使网络对目标位置的微小变化不敏感。例如，一个猫的眼睛在图像中向左或向右移动几个像素，经过最大池化后，可能仍然会被同一个神经元激活。

卷积神经网络中的关键技术

Flatten



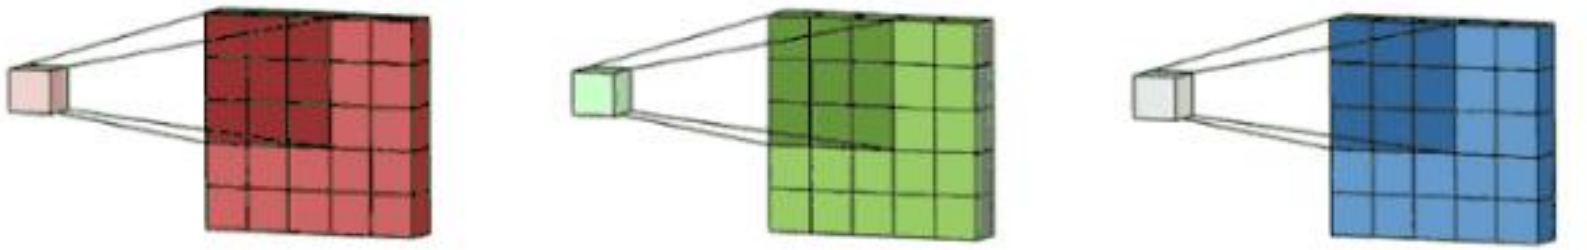
CNN模型使用


示例：宠物分类
cat dog ……
Fully Connected Feedforward network
Flatten
A new image
Convolution
Max Pooling
A new image
Convolution
Max Pooling
多层堆叠

3通道的2D CNN

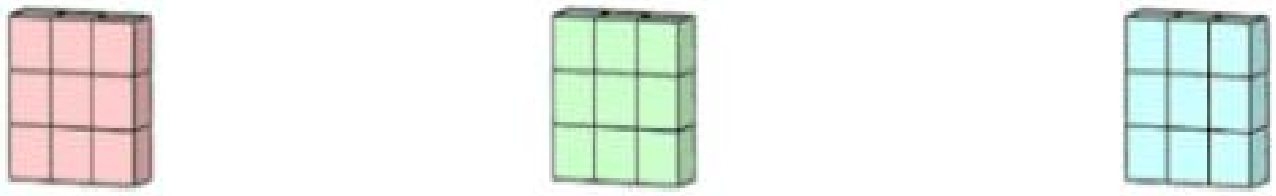
彩色图像由R、G、B三个通道的数据组成。
假设输入层是一个 5 x 5 x 3 矩阵，它有 3 个通道。过滤器定义为一个 3 x 3 x 3 矩阵。

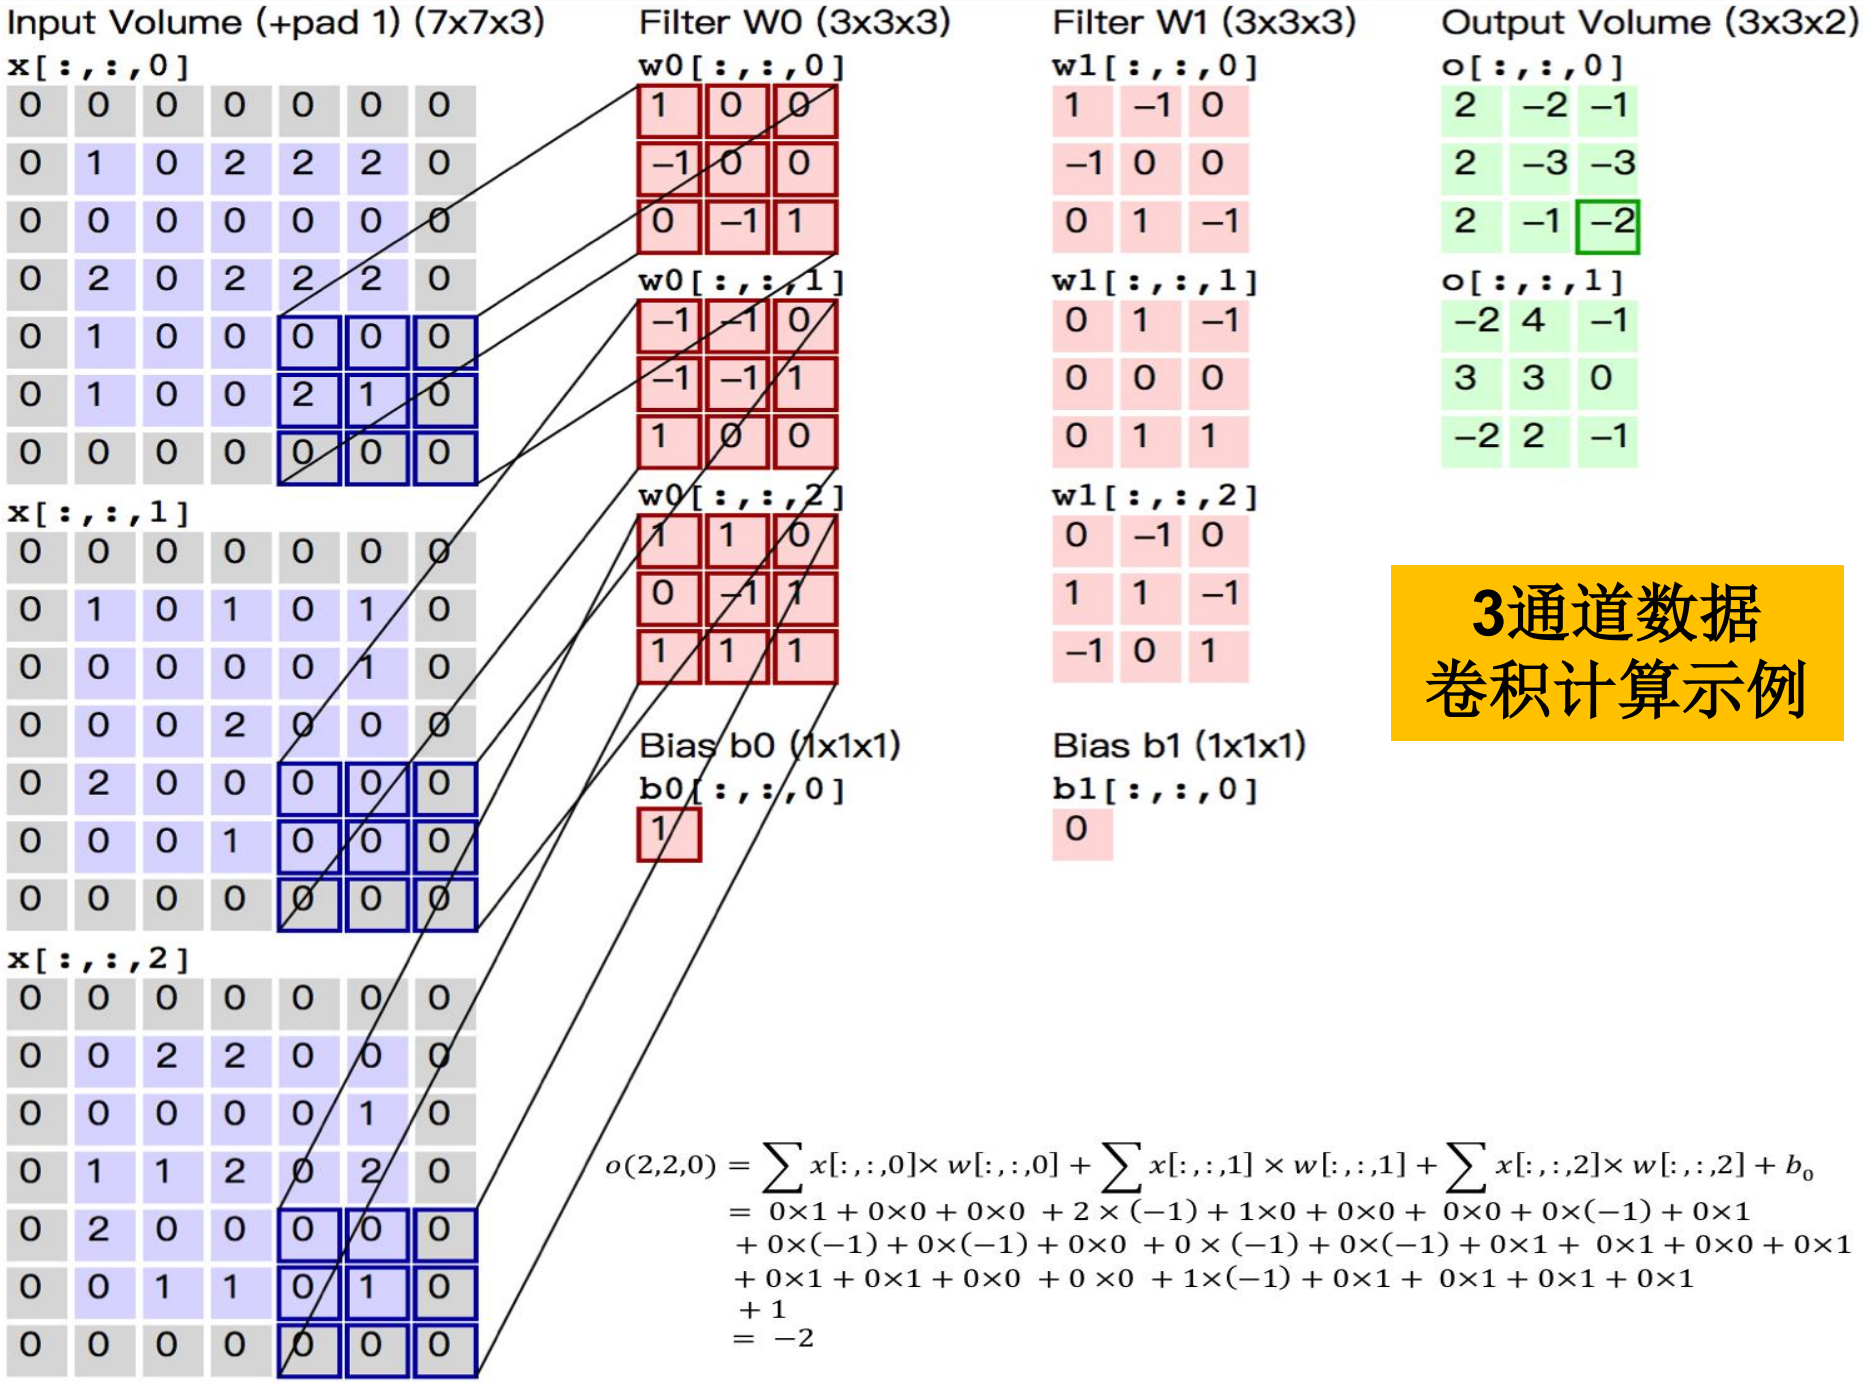
- Step1: 过滤器中的每个卷积核都应用到输入层的 3 个通道，执行 3 次卷积后得到了尺寸为 3 x 3 的 3 个通道。



3通道的2D CNN

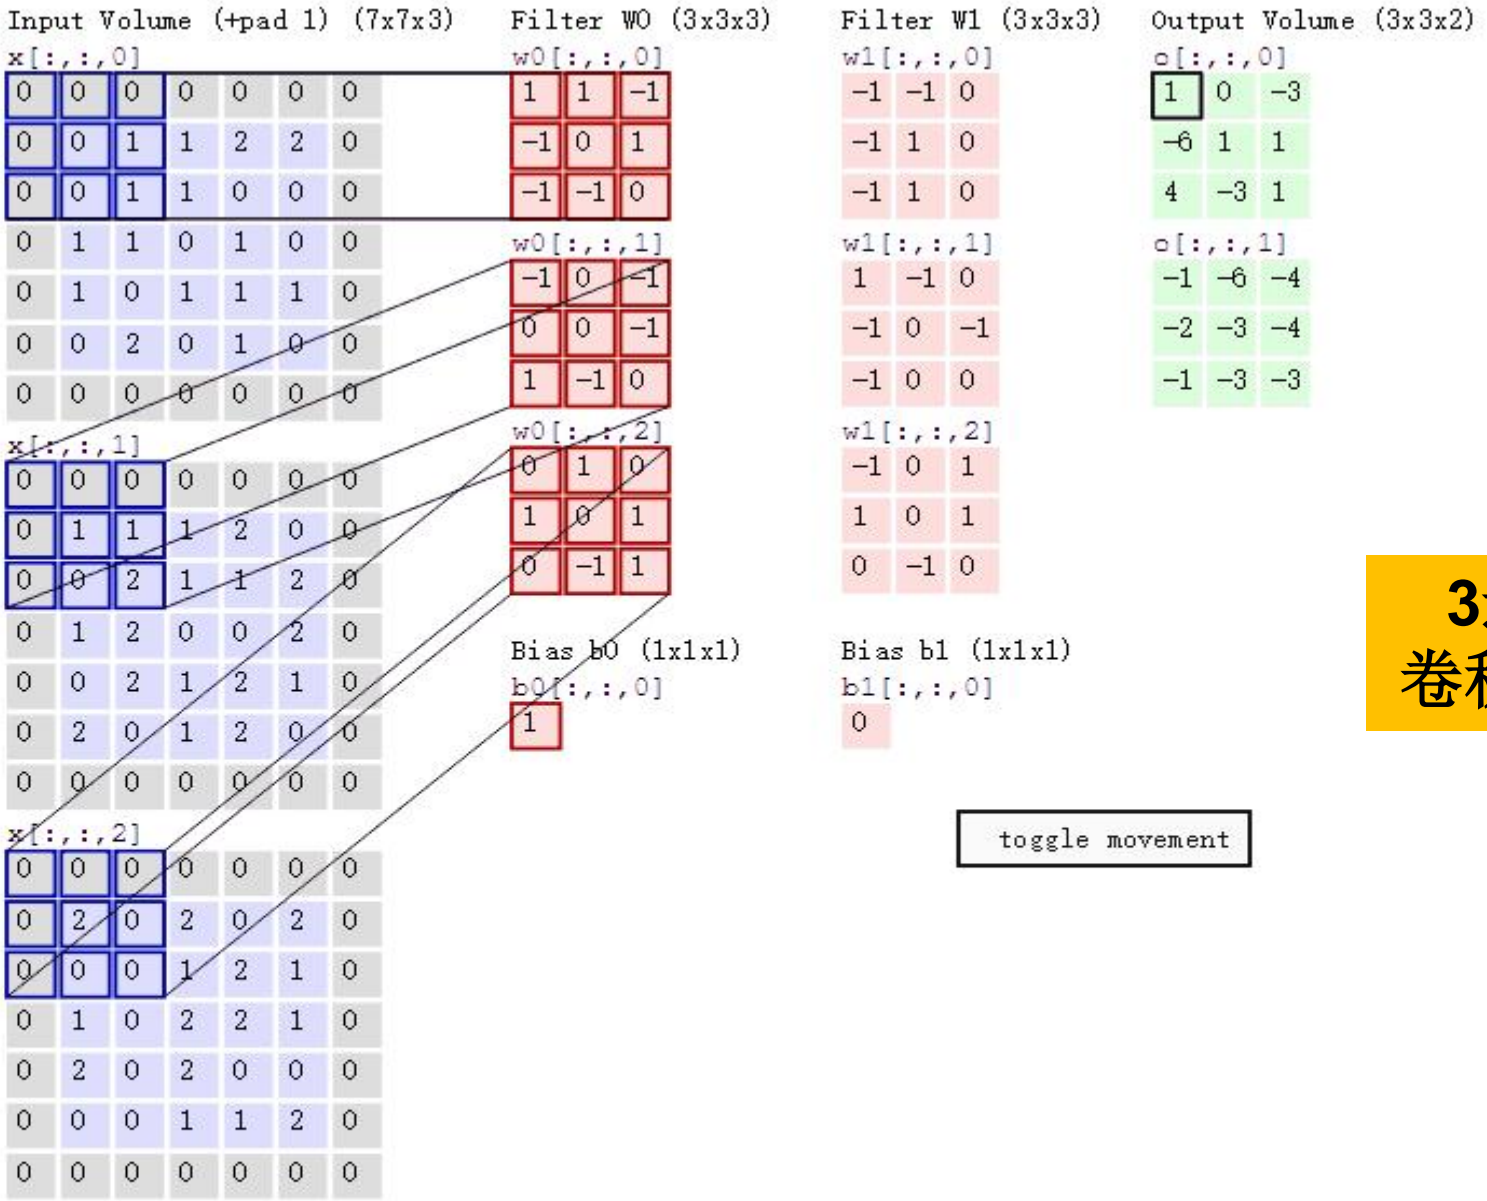
- Step2: 融合3个通道的结果，即将3个通道的输出结果求和，变成单通道数据形式。





3通道数据卷积计算示例

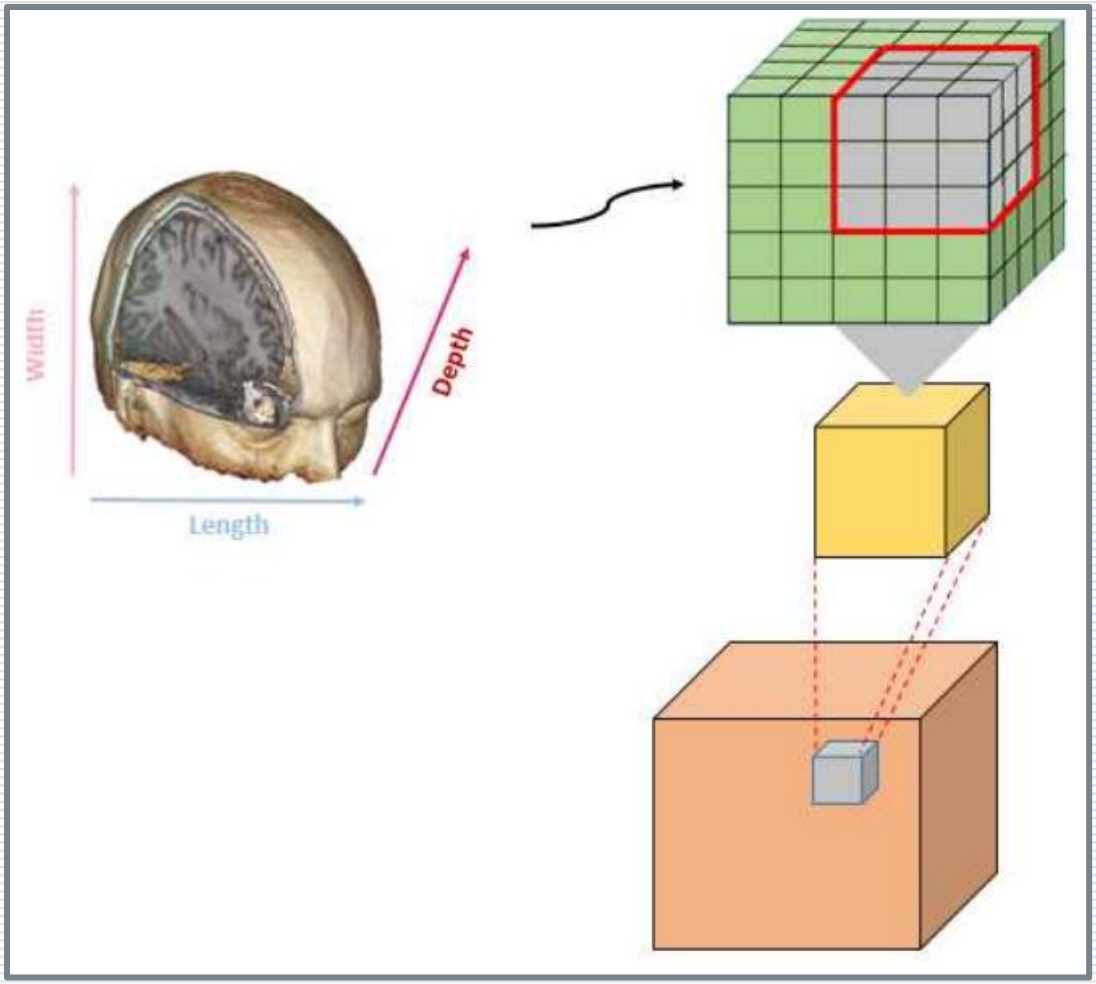
$$
\begin{aligned}
o(2,2,0) &= \sum x[:,:,0]\times w[:,:,0] + \sum x[:,:,1]\times w[:,:,1] + \sum x[:,:,2]\times w[:,:,2] + b_0 \\
&= 0\times1 + 0\times0 + 0\times0 + 2\times(-1) + 1\times0 + 0\times0 + 0\times0 + 0\times(-1) + 0\times1 \\
&\quad + 0\times(-1) + 0\times(-1) + 0\times0 + 0\times(-1) + 0\times(-1) + 0\times1 + 0\times1 + 0\times0 + 0\times1 \\
&\quad + 0\times1 + 0\times1 + 0\times0 + 0\times0 + 1\times(-1) + 0\times1 + 0\times1 + 0\times1 + 0\times1 \\
&\quad + 1 \\
&= -2
\end{aligned}
$$



3通道数据卷积计算示例

3D CNN

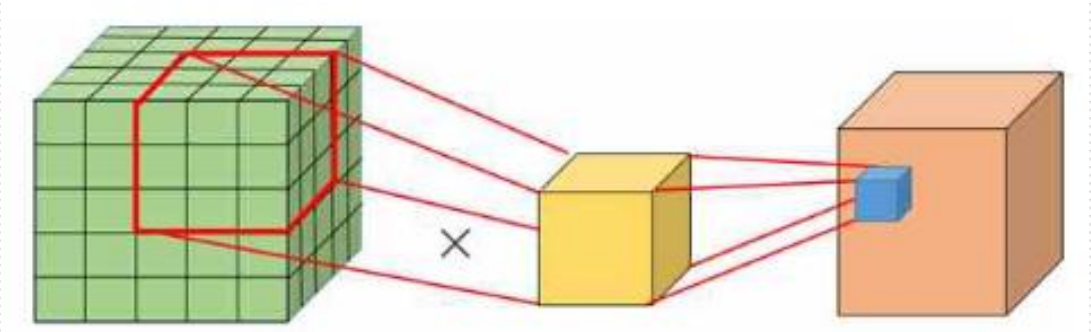
空间上的三维结构



时间上的三维结构



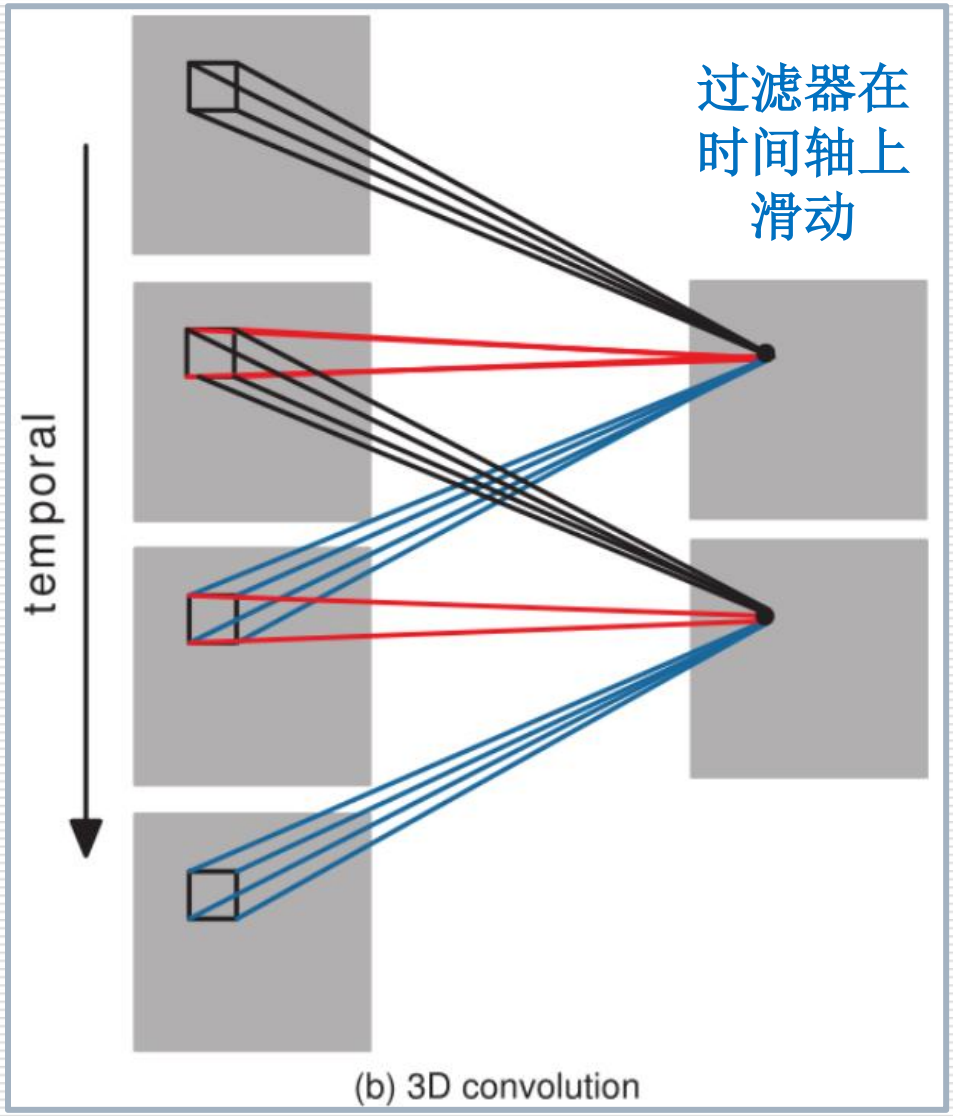
视频帧
时间序列

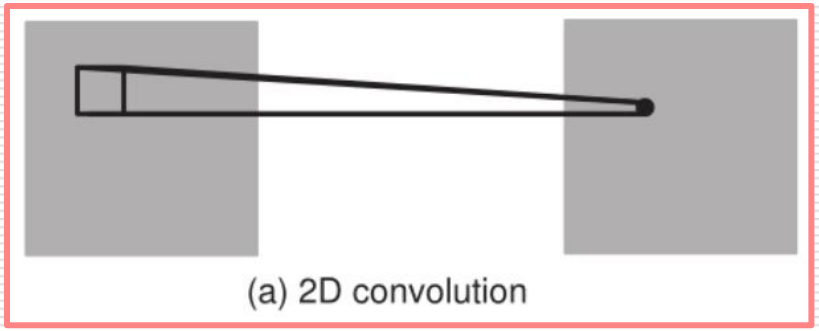


输入　　过滤器　　输出

3D CNN

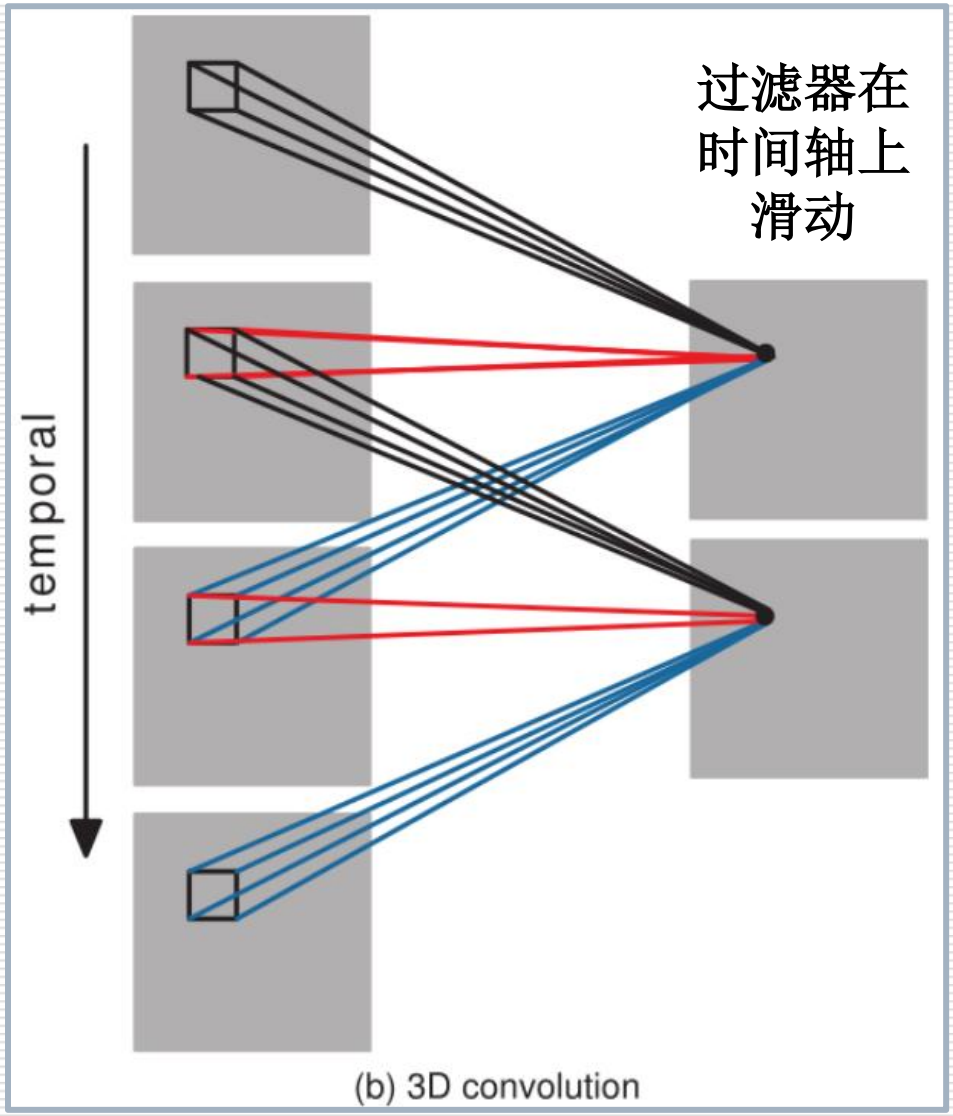
单个过滤器生成一个特征图



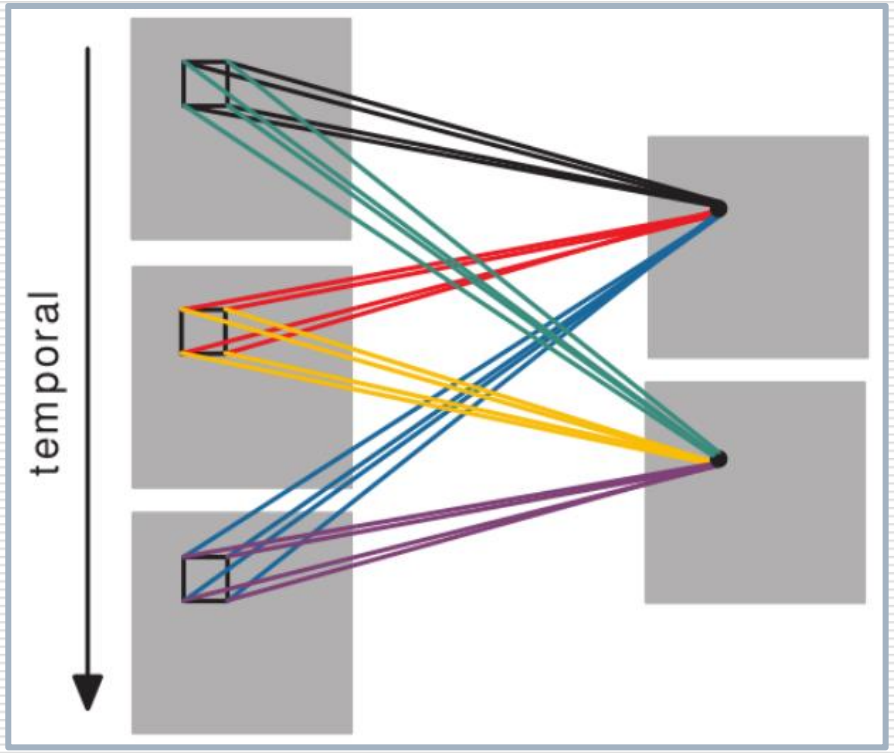


3D CNN

单个过滤器生成一个特征图



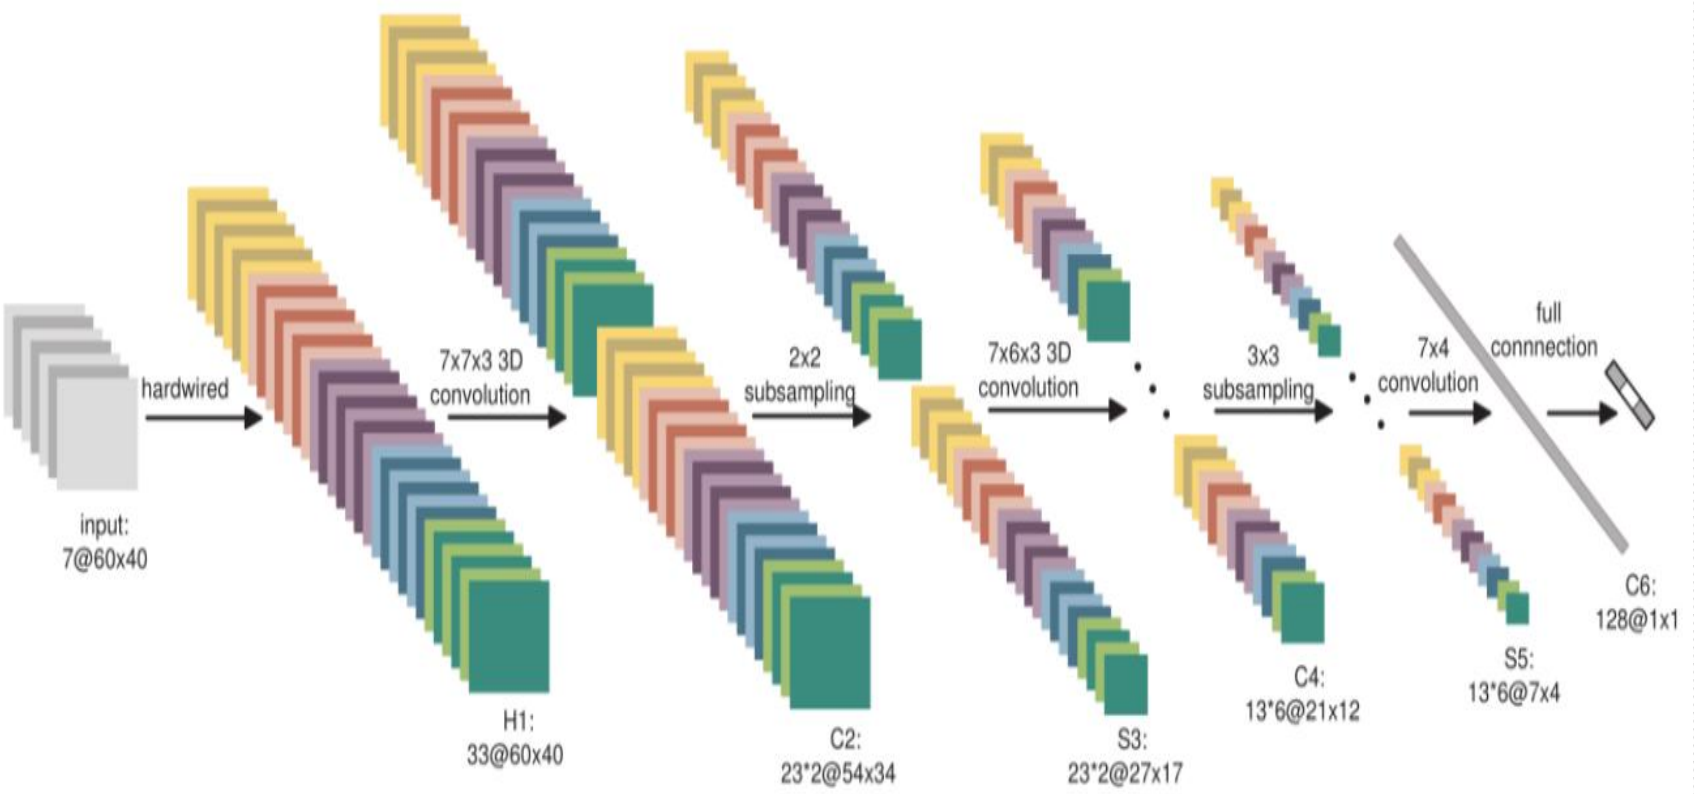
两个过滤器生成两个特征图



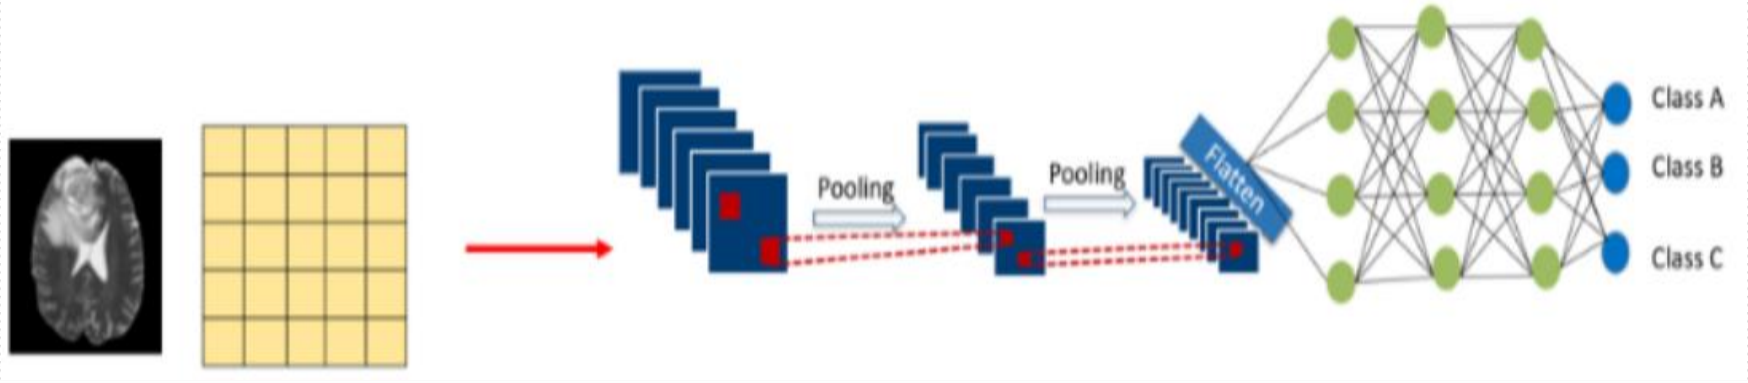
3D CNN

基于3D CNN的视频流处理示例

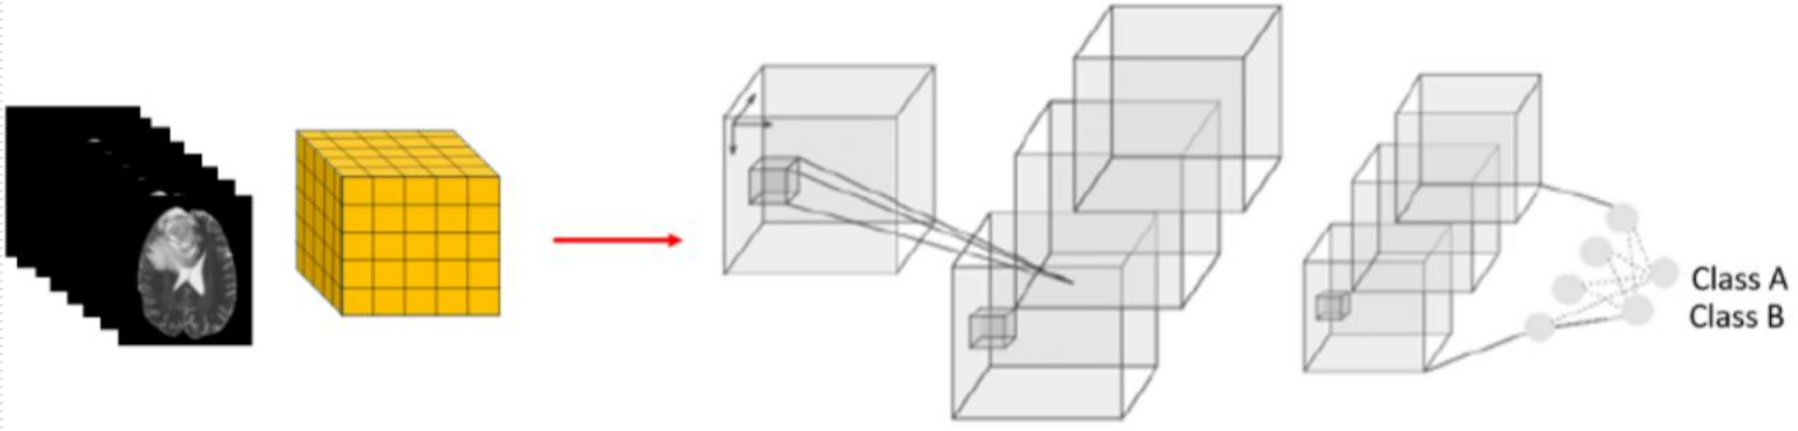
- 网络包含1个hardwired kernels层，3个卷积层，2个下采样层，1个全连接层组成。
- 直接对连续的帧做3D卷积，提取的信息过于简单，一般在3D卷积之前做一次hardwired kernels 卷积（含有灰度、x方向梯度、y方向梯度、x方向光流、y方向光流等5种特征信息）。



3D CNN与2D CNN网络结构对比



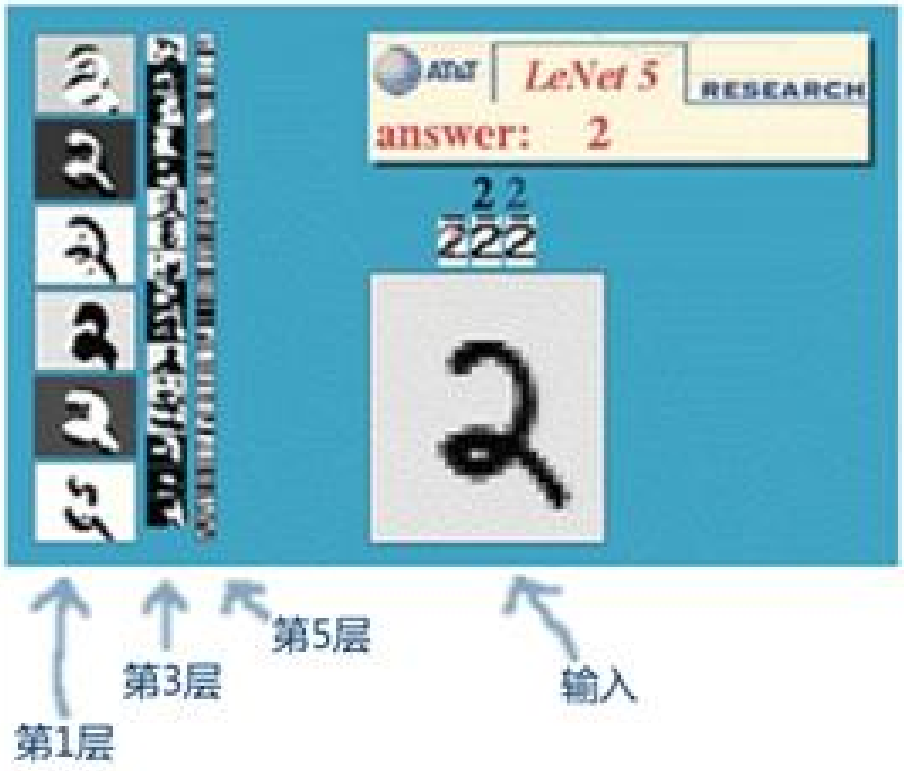
2D CNN典型网络结构



3D CNN典型网络结构

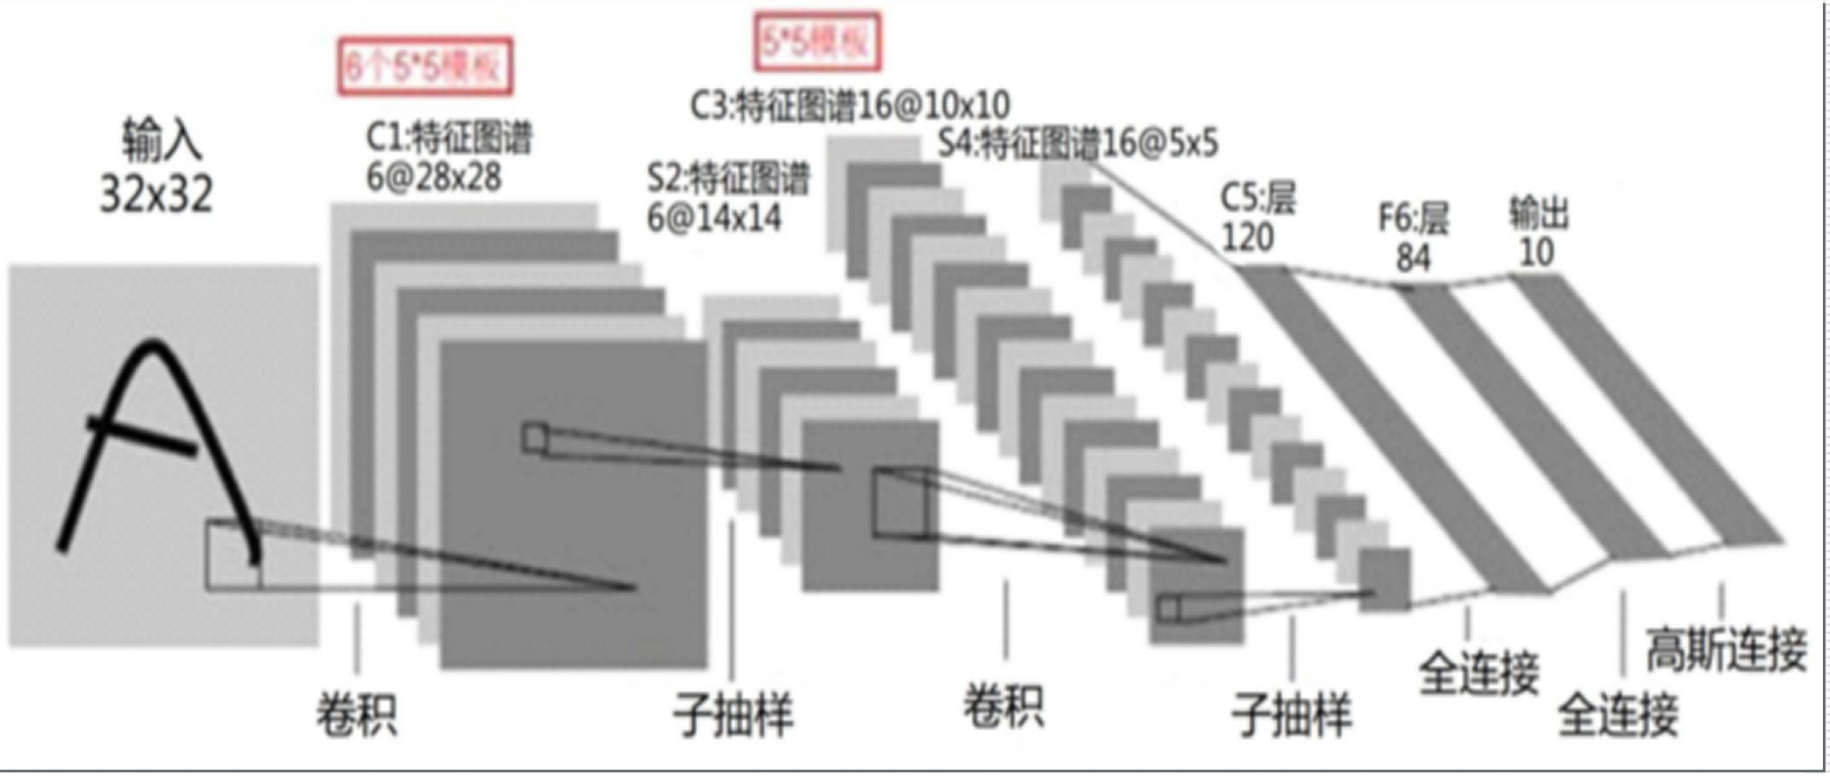
卷积神经网络的应用

- 一种典型的用来识别数字的卷积网络是LeNet-5。美国大多数银行当年用它识别支票上面的手写数字，达到了商用地步，说明该算法具有很高的准确性。



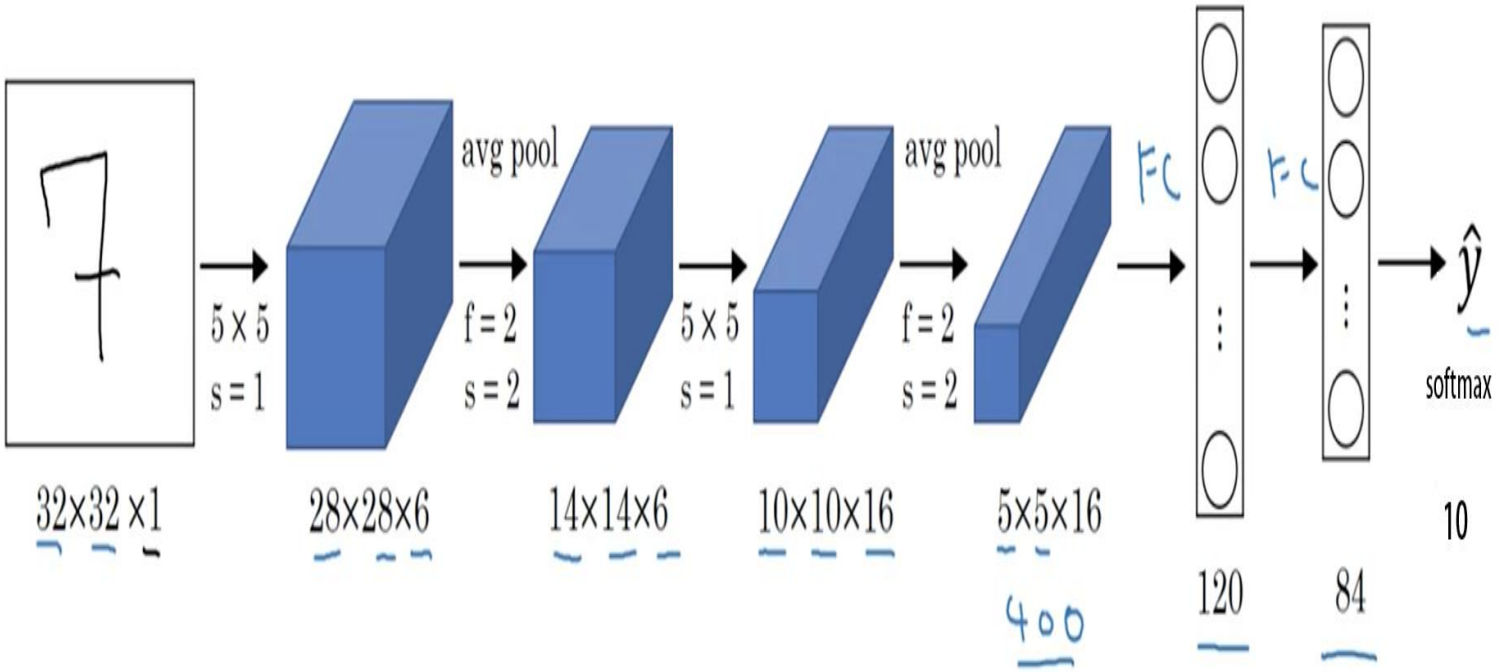
卷积神经网络的应用

- **LeNet-5是一个数字手写系统，不包含输入层，共有7层，每层都包含可训练参数（连接权重）。输入图像为32*32大小。**



卷积层参数

- **卷积核大小：**卷积核大小可以指定为小于输入图像尺寸的任意值，卷积核越大，可提取的输入特征越复杂。
- **步长：**卷积核相邻两次扫过特征图时位置的距离，卷积步长为1时，卷积核会逐个扫过特征图的元素，步长为n时会在下一次扫描跳过n-1个像素。
- **填充：**0填充或重复边界值填充等。由卷积核的交叉相关计算可知，随着卷积层的堆叠，特征图的尺寸会逐步减小，例如16×16的输入图像在经过单位步长、无填充的5×5的卷积核后，会输出12×12的特征图。为此，填充是在特征图通过卷积核之前人为增大其尺寸以抵消计算中尺寸收缩影响的方法。



人工神经网络及其应用

- 神经元与神经网络结构
- 神经网络学习算法
- 卷积神经网络
- 生成对抗网络及其应用

生成对抗网络的基本原理

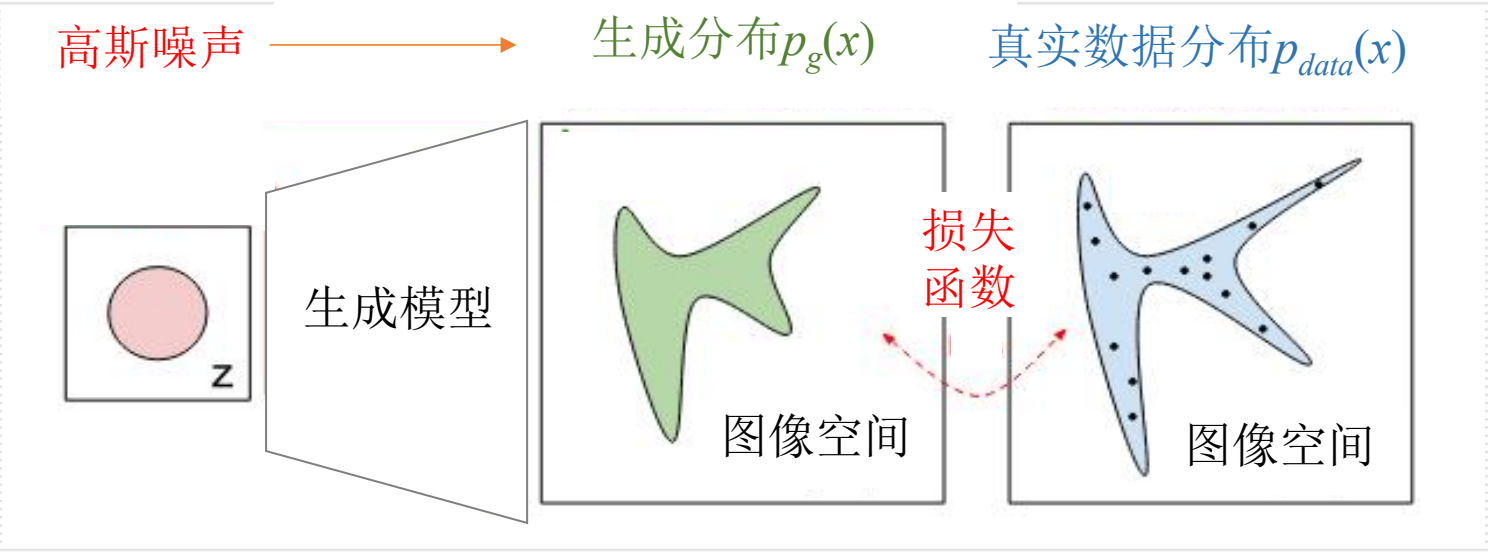
假币制作与识别



警察与小偷



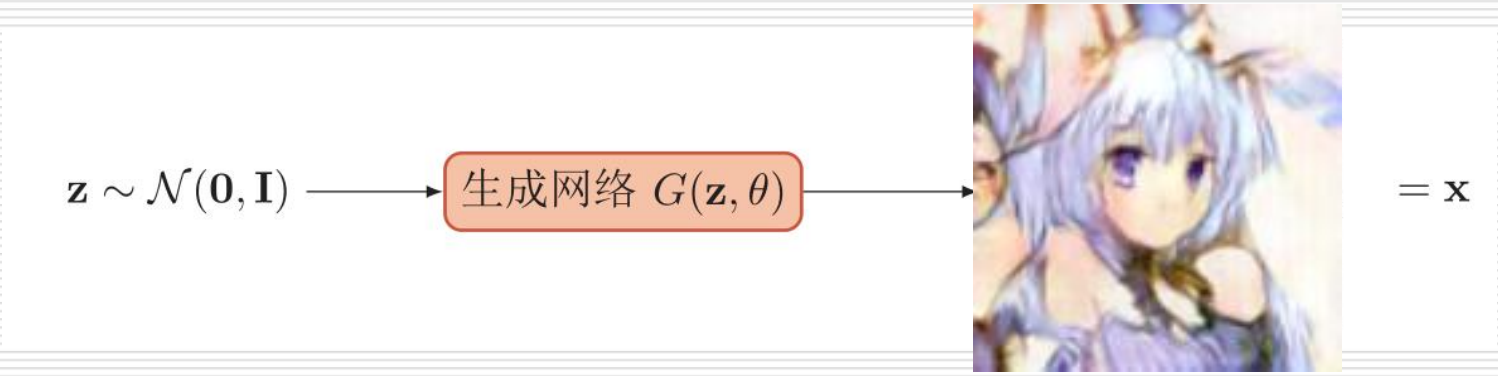
- **Ian Goodfellow等于2014年提出一种新型生成式模型——生成对抗网络（GAN, generative adversarial network），使用对抗训练机制对两个神经网络进行训练**



生成对抗网络的基本原理

生成网络

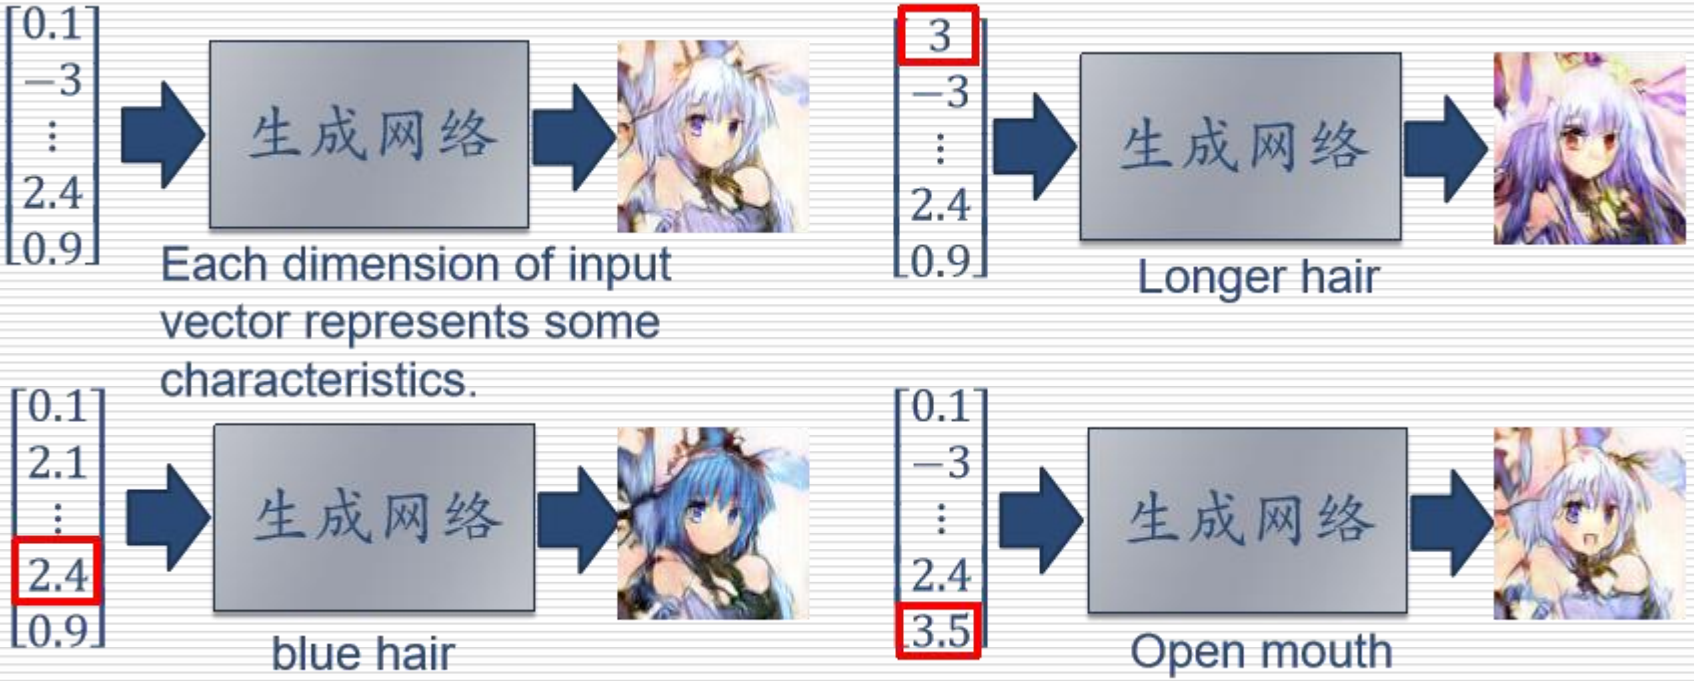
生成网络从隐空间（latent space）中随机采样作为输入，其输出结果需要尽量模仿训练集中的真实样本。



如何学习生成网络？

生成对抗网络的基本原理

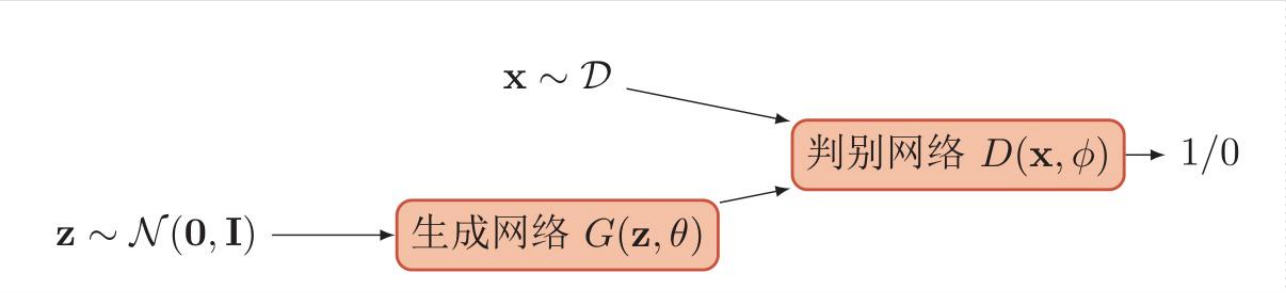
生成网络示例



生成对抗网络的基本原理

判别网络

判别网络的输入则为真实样本或生成网络的输出，其目的是将生成网络的输出从真实样本中尽可能分辨出来。





生成对抗网络的结构与训练

对抗训练

- 生成网络要尽可能地欺骗判别网络
- 判别网络将生成网络生成的样本与真实样本尽可能区分出来

两个网络相互对抗、不断调整参数，最终目的是使判别网络无法判断生成网络的输出结果是否真实。

生成对抗网络的结构与训练

生成网络
(student)

判别网络
(teacher)



生成网络
v1



判别网络
v1

No eyes

生成网络
v2



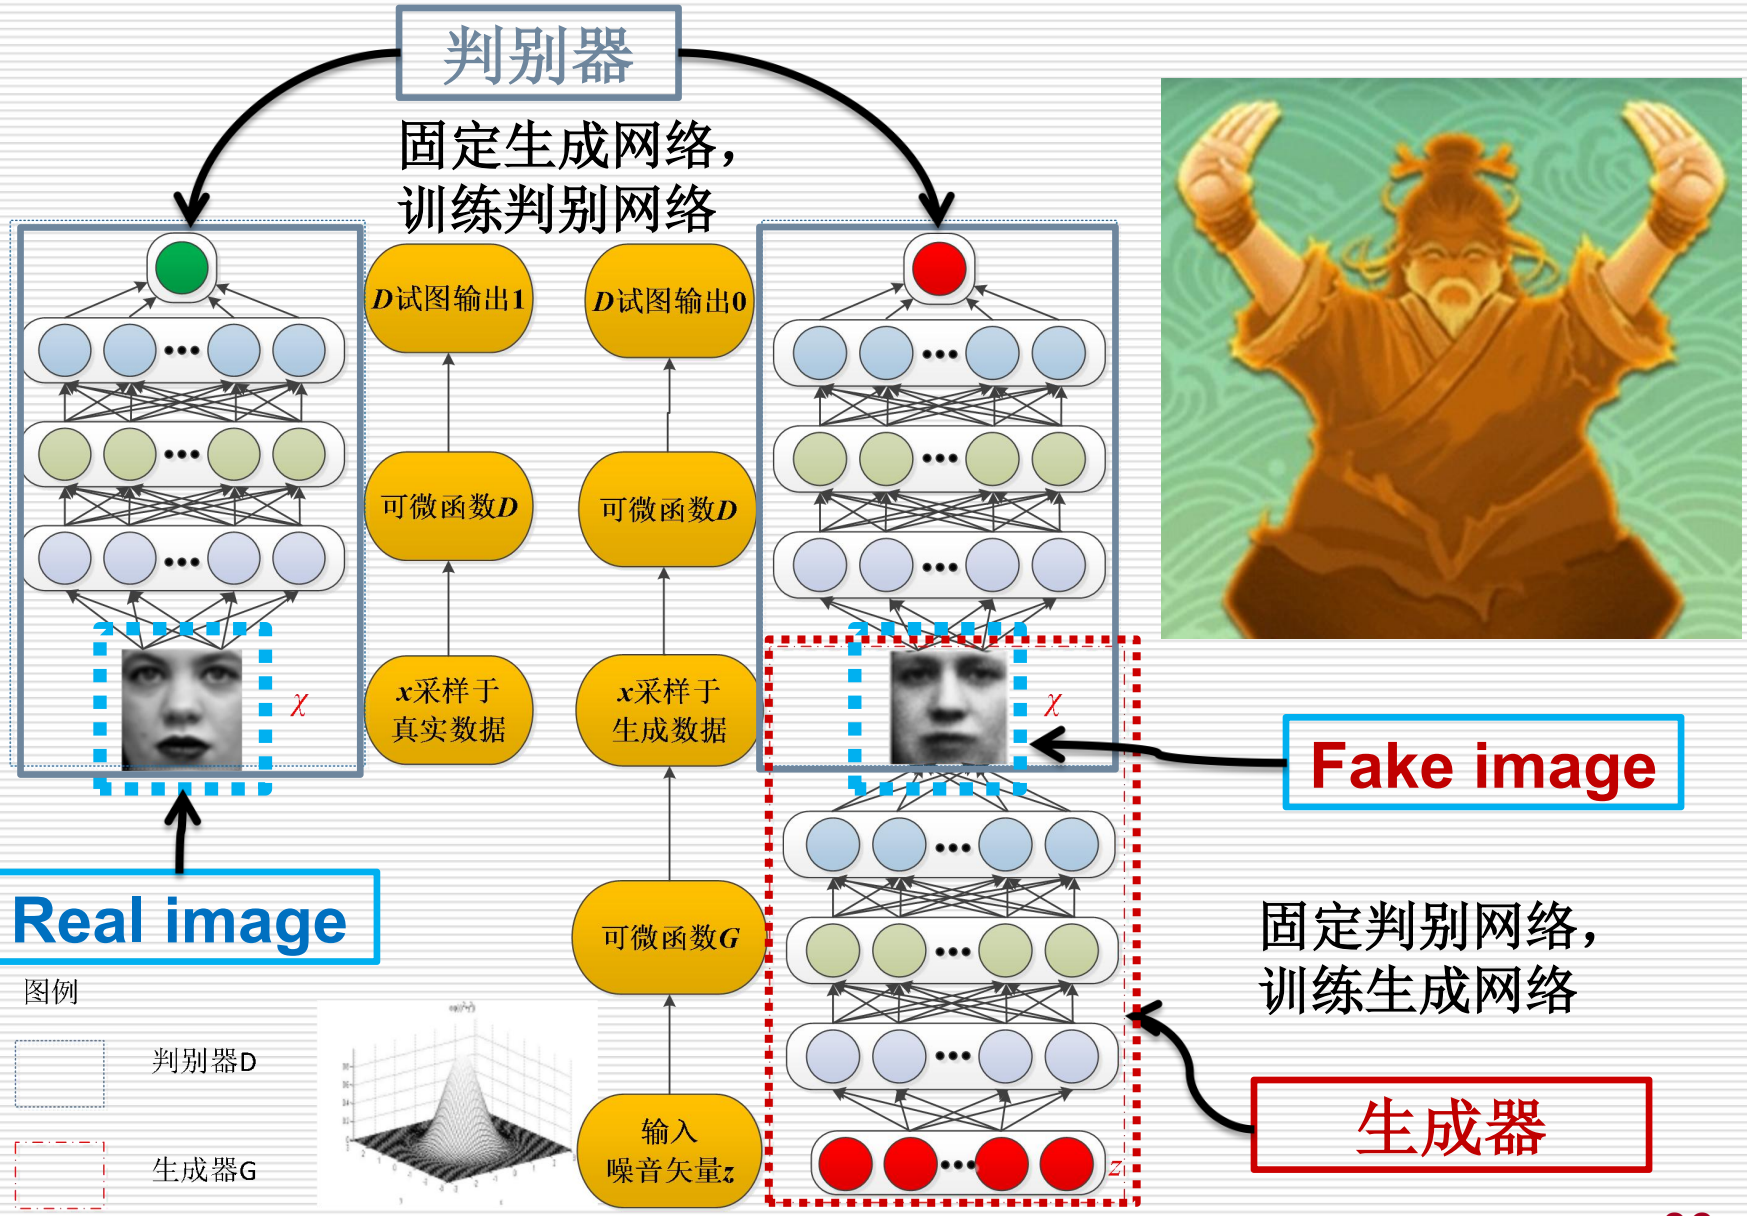
判别网络
v2

No mouth

生成网络
v3



生成对抗网络的结构与训练



生成对抗网络的结构与训练

损失函数

判别器

真实分布　　噪声分布

$$\max_{\phi} \mathbb{E}_{\boldsymbol{x}\sim p_r(\boldsymbol{x})}\Big[\log D(\boldsymbol{x};\phi)\Big] + \mathbb{E}_{\boldsymbol{z}\sim p(\boldsymbol{z})}\Big[\log(1 - D\Big(G(\boldsymbol{z};\theta);\phi\Big)\Big]$$

生成器

$$\max_{\theta} \left(\mathbb{E}_{\boldsymbol{z}\sim p(\boldsymbol{z})}\Big[\log D\Big(G(\boldsymbol{z};\theta);\phi\Big)\Big]\right)$$

Minimax Game（极小化极大博弈）

$$\min_{\theta}\max_{\phi} \left(\mathbb{E}_{\boldsymbol{x}\sim p_r(\boldsymbol{x})}\Big[\log D(\boldsymbol{x};\phi)\Big] + \mathbb{E}_{\boldsymbol{z}\sim p(\boldsymbol{z})}\Big[\log(1 - D\Big(G(\boldsymbol{z};\theta);\phi\Big)\Big]\right)$$

生成对抗网络的结构与训练

GAN在训练中容易出现一些问题，训练过程具有强烈的不稳定性，实验结果随机，具体表现：

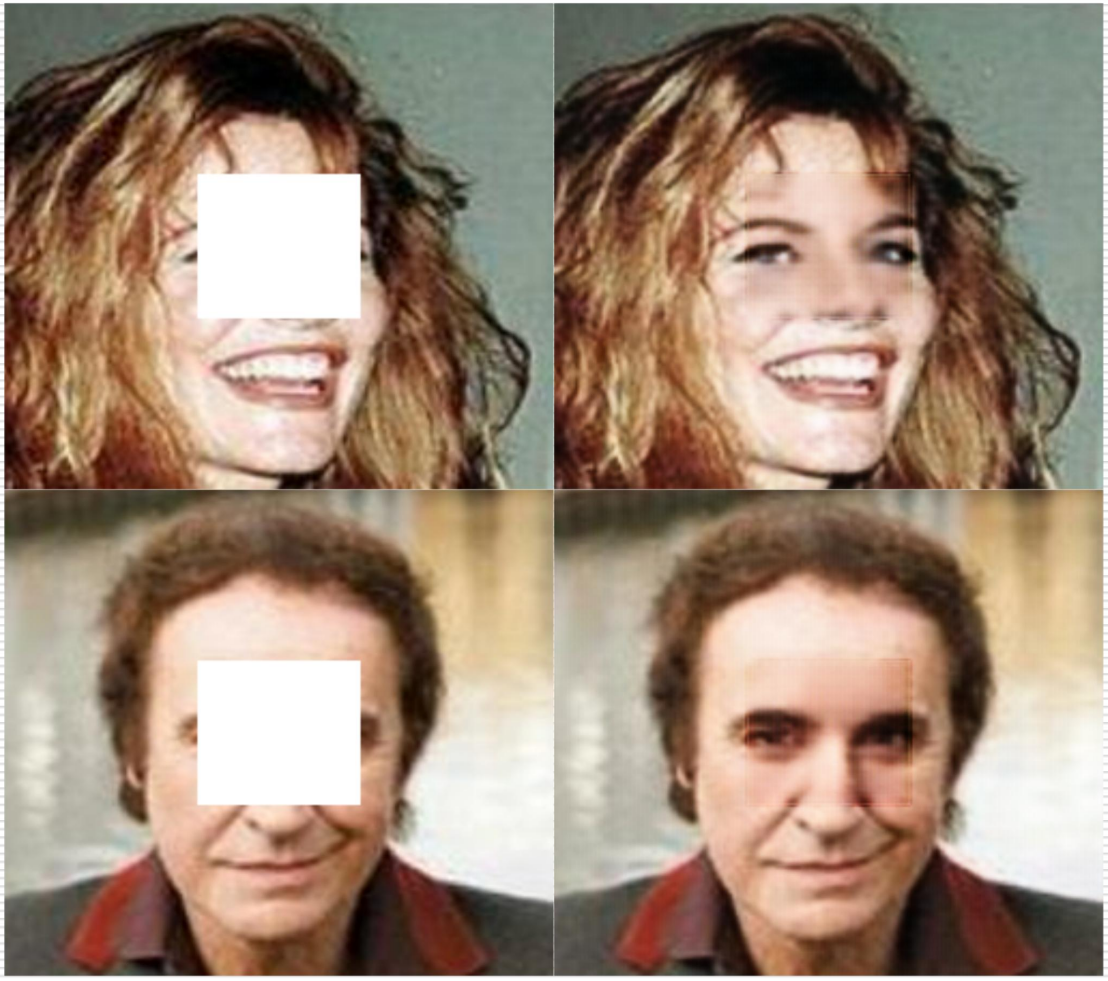
- 训练过程难以收敛，经常出现震荡。
- 训练收敛，但是出现模式崩溃(model collapse)，生成的样本缺乏多样性。
- 训练收敛，但是GAN还会生成一些没有意义或者现实中不可能出现的图片。

生成对抗网络的应用

- 生成对抗网络在图像处理中的应用
- 生成对抗网络在语言处理中的应用
- 生成对抗网络在视频生成中的应用

生成对抗网络在图像处理中的应用

图像修复



生成对抗网络在图像处理中的应用

图像风格迁移



生成对抗网络在图像处理中的应用

图像风格迁移



生成对抗网络在图像处理中的应用

图像风格迁移





生成对抗网络在图像处理中的应用

图像风格迁移



德国小镇



另一种风格的《沉船》

19世纪英国画家特纳的《沉船》

生成对抗网络在图像处理中的应用

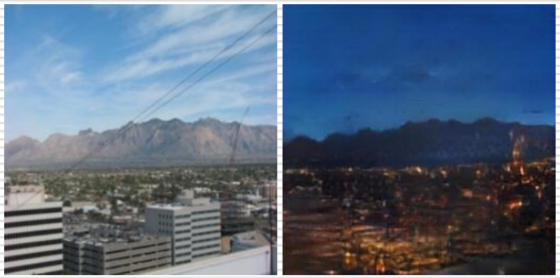
图像翻译



地图生成航拍图像



轮廓图像生成照片



白天图像生成对应夜景

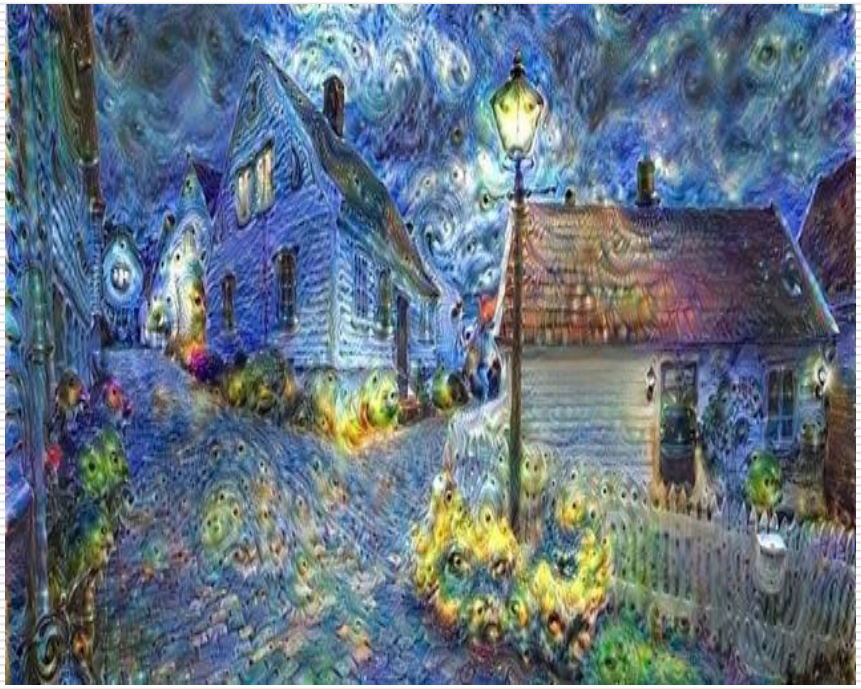




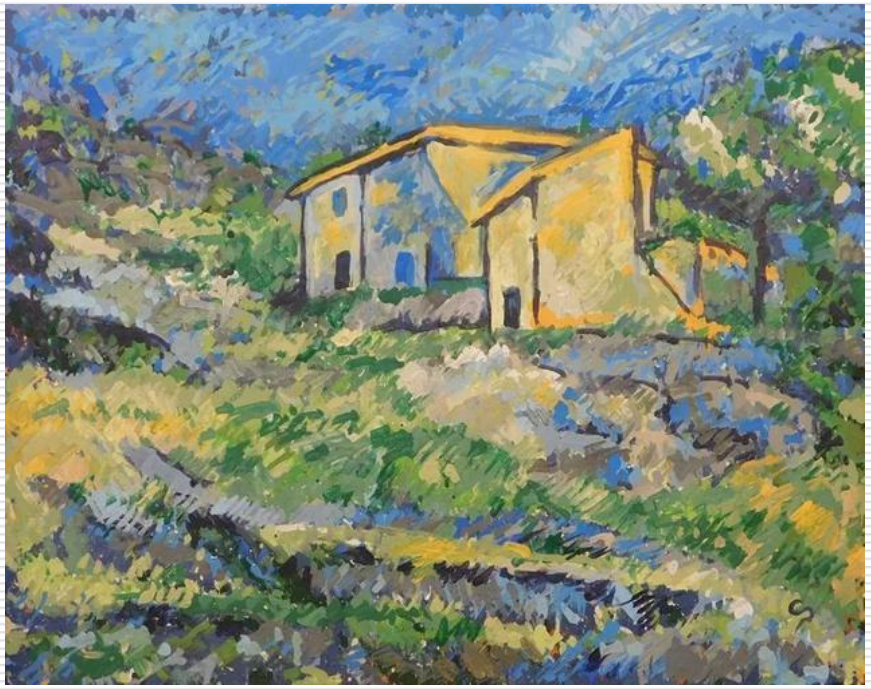
多模态图像翻译



生成对抗网络在艺术创作中的应用



Deep Dream的画作



机器人作画

生成对抗网络在语言处理中的应用

从文字描述生成图片

这只小鸟有着小小的鸟喙、胫骨和双足，蓝色的冠部和覆羽，以及黑色的脸颊。



这朵花有着长长的粉色花瓣和朝上的橘黄色雄蕊。



生成对抗网络在语言处理中的应用

诗歌写作

九歌

2017年清华孙茂松团队的计算机古诗作诗系统检验现有神经网络深度学习主流模型的能力

写一首七言绝句：

生成结果

信息人间百虑消

春风吹散一溪桥

何须更觅东坡路

门外松阴自在条

中国面孔

生成结果

平生面面气雄豪

中国声名一代褒

四海共推周典礼

百年谁识汉文高

生成对抗网络在语言处理中的应用

诗歌写作

ChatGPT

SI 背一下李白的《黄鹤楼送孟浩然之广陵》

好的，以下是李白的《黄鹤楼送孟浩然之广陵》：

故人西辞黄鹤楼，烟花三月下扬州。
孤帆远影碧空尽，唯见长江天际流。

希望我的背诵能够帮助到您。

SI 你能写一首《黄鹤楼送孟浩然之广陵》吗

好的，以下是我为您创作的《黄鹤楼送孟浩然之广陵》：

烟波江上黄鹤楼，故人离去泪难收。
三月扬州花簇锦，远帆孤影渐消愁。
长江流水潺潺响，明月高挂照江洲。
相思别后常念念，明朝又见广陵秋。

希望这首诗能够表达出离别之情和思念之意。

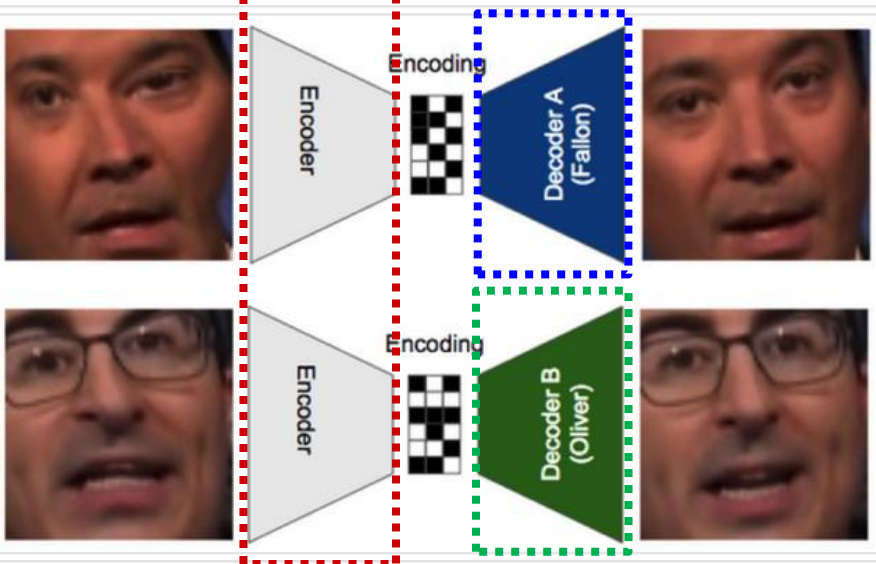
生成对抗网络在视频生成中的应用

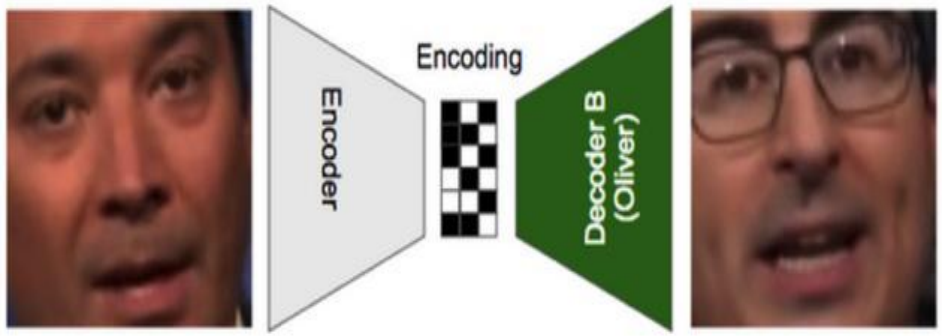
AI换脸术：

DeepFake



共享编码器





生成对抗网络在视频生成中的应用

新闻播报机器人

- 2018年11月7-9日，在乌镇第五届世界互联网大会上，新华社对外宣布：中国首个“人工智能主持人”正式上岗。



生成对抗网络在视频生成中的应用

2019.2.19新华社发布站立式合成主播





邱浩——新小浩　　屈萌——新小萌

THE END

