人工智能导论复习笔记

by dh

1 绪论

1. 1956年正式提出人工智能这个术语，并将其作为一门新兴科学的名称。
2. 20世纪三大科学技术成就：空间技术、原子能技术、人工智能

1.1 人工智能的基本概念

1. 自然界的四大奥秘：物质的本质、宇宙的起源、生命的本质、智能的发生
2. 对智能定义的主要流派

- 思维理论：智能的核心是思维
- 知识阈值理论：智能取决于知识的数量及一般化程度
- 进化理论：

2. 智能是知识和智力的总和

- 知识是一切智能行为的基础
- 智力是获取知识并应用知识求解问题的能力

3. 智能的特征

- 感知能力：通过视觉、听觉、触觉、嗅觉等感觉器官感知外部世界的能力。
    - 80%以上信息通过视觉得到，10%信息通过听觉得到。
- 记忆与思维能力
    - 记忆：存储由感知器官感知到的外部信息以及由思维所产生的知识
    - 思维能力：对记忆的信息进行处理
    - 逻辑思维
    - 形象思维
    - 顿悟思维
- 学习能力
- 行为能力

4. 人工智能

- 人工智能：用人工的方法在机器（计算机）上实现的智能；或者说是人们使机器具有类似于人的智能
- 人工智能学科：一门研究如何构造智能机器（智能计算机）或智能系统，使它能模拟、延伸、扩展人类智能的学科
- 图灵测试：1950年图灵发表的《计算机与智能》中设计了一个测试，用以说明人工智能的概念
    - 即使通过图灵测试也不能说明计算机能思维

试用水印

1.2 人工智能的发展简史

1. 世界上第一台电子计算机“阿塔纳索夫－贝瑞计算机（Atanasoff-Berry Computer，ABC）”
2. 达特莫斯大学 麦卡锡提议采用“人工智能”这一专业术语

   麦卡锡被称为人工智能之父

3. 专用人工智能和通用人工智能

1.3 人工智能研究的基本内容

1. 知识表示

- 知识表示：将人类知识符号化或模型化
- 知识表示方法：符号表示法、连接机制表示法

2. 机器感知

- 使机器（计算机）具有类似于人的感知能力
- 以机器视觉与机器听觉为主

3. 机器思维

- 对通过感知得来的外部信息及机器内部的各种工作信息进行有目的的处理。

4. 机器学习
5. 机器行为

1.4 人工智能的主要研究领域

看看ppt就行，应该不考

2 知识表示与知识图谱

1. 人类的智能活动主要是获得并运用知识。知识是智能的基础。
2. 知识需要用适 当的模式表示出来才能存储到计算机中去

2.1 知识与知识表示的概念

1. 知识：把有关信息关联在一起所形成的信息结构
2. 知识反映了客观世界中事物之间的关系，不同事物或者相同事物间的不同院系形成了不同的知识。
3. 信息关联形式：“如果……，则……”
4. 知识的特性

- 相对正确性： 任何知识都是在一定的条件及环境下产生的，在这种条件及环境下才是正确的。
- 不确定性
  - 随机性引起不确定性
  - 模糊性引起的不确定性
  - 经验性引起的不确定性
  - 不完全性引起的不确定性
- 可表示性与可利用性

试用水印

- 可表示性：知识可以用适当形式表示出来，如用语言、文字、图形、神经网络等。
- 可利用性：知识可以被利用

5. 知识表示：将人类知识形式化或模型化

- 知识表示是对知识的一种描述，或者说是一组约定，一种计算机可以接受的用于描述知识的数据结构
- 选择知识表示方法的原则
  - 充分表示领域知识
  - 有利于对知识的利用
  - 便于对知识的组织、维护和管理
  - 便于理解与实现

2.2 一阶谓词逻辑表示法

1. 命题是一个非真即假的陈述句
2. 命题逻辑：研究命题与命题之间关系的符号逻辑系统
3. 命题逻辑表示法：无法把它所描述的事物的结构及逻辑特征反映出来，也不能把不同事物间的共同特征表述出来。自然语言难以理解。
4. 谓词的一般形式：$P (x_1, x_2,..., x_n)$

- 个体x_1, x_2,..., x_n :某个独立存在的事物或者某个抽象的概念;
- 谓词名 P：刻画个体的性质、状态或个体间的关系
  - 个体是常量：一个或者一组指定的个体
  - 个体是变元（变量）：没有指定的一个或者一组个体
  - 个体是函数：一个个体到另一个个体的映射
  - 个体是谓词

5. 谓词公式

- 连接词（连词）
  - 非、与、或、蕴含、等价
- 量词
  - 全称量词（任意）
  - 存在量词（存在）
  - 量词的运算方式为从左到右进行计算，全称量词和存在量词出现的次序将影响命题的意思。
- 谓词公式

(1) 单个谓词是谓词公式，称为原子谓词公式。
(2) 若A是谓词公式，则¬A也是谓词公式。
(3) 若A，B都是谓词公式，则A∧B，A∨B，A→B，A↔B也都是谓词公式。
(4) 若A是谓词公式，则 $(\forall x)$ A，$(\exists x)$A也是谓词公式。
(5) 有限步应用（1）－（4）生成的公式也是谓词公式。

试用水印

- 连接词的优先级

非、与、或、蕴含、等价

- 量词的辖域
  - 量词的辖域：位于量词后面的单个谓词或者用括弧括起来的谓词公式。
  - 约束变元与自由变元：辖域内与量词中同名的变元称为约束变元，不同名的变元称为自由变元。

例如：

$$(\exists x)(P(x,y)\rightarrow Q(x,y))\vee R(x,y)$$

- $(P(x,y)\rightarrow Q(x,y))$：$(\exists x)$的辖域，辖域内的变元$x$是受$(\exists x)$约束的变元，$R(x,y)$中的$x$是自由变元。
- 公式中的所有y都是自由变元。

6. 谓词公式的性质

- 谓词公式的解释
  - 谓词公式在个体域上的解释：个体域中的实体对谓词演算表达式的每个常量、变量、谓词和函数符号的指派。
  - 对于每一个解释，谓词公式都可求出一个真值（T或F）。
- 永真性
  - 如果谓词公式**P**对个体域**D**上的任何一个解释都 取得真值**T**，则称**P**在**D**上是永真的;如果**P**在每个非空个 体域上均永真，则称**P**永真。
- 永假性
  - 如果谓词公式**P**对个体域**D**上的任何一个解释都 取得真值**F**，则称**P**在**D**上是永假的;如果**P**在每个非空个 体域上均永假，则称**P**永假。
- 满足性与不可满足性
  - 对于谓词公式**P**，如果至少存在一个解释使得**P** 在此解释下的真值为**T**，则称**P**是可满足的，否则，则称**P**是不可满足的
- 等价性
  - 设**P**与**Q**是两个谓词公式，**D**是它们共同的个 体域，若对**D**上的任何一个解释，**P**与**Q**都有相同的真 值，则称公式**P**和**Q**在**D**上是等价的。如果**D**是任意个 体域，则称**P**和**Q**是等价的。
- 永真蕴含
  - 对于谓词公式**P**与**Q**，如果P→Q永真，则称 公式**P**永真蕴含**Q**，且称**Q**为**P**的逻辑结论，称**P**为**Q**的前提
- 谓词逻辑的其他推理规则
  - **P**规则:在推理的任何步骤上都可引入前提，就是直接利用推理中给定的前提。即前提引入。
  - **T**规则:在推理过程中，如果前面步骤中有一个 或多个公式永真蕴含公式**S**，则可把**S**引入推理过 程中。即推理规则。
  - **CP**规则:如果能从任意引入的命题**R**和前提集 合中推出**S**来，则可从前提集合推出**R** → **S**来。 即附加前提引入。

试用水印

- 反证法（结论与前提的反面没有交）

④ 反证法：$P \Rightarrow Q$ 当且仅当 $P \wedge \neg Q \Leftrightarrow F$，即$Q$为$P$的逻辑结论，当且仅当 $P \wedge \neg Q$是不可满足的。

- 定理：Q为 P_1，P_2，…，P_n 的逻辑结论，当且仅当 $(P_1 \wedge P_2 \wedge \cdots \wedge P_n) \wedge \neg Q$是不可满足的。

7. 一阶谓词逻辑知识表示方法

- 定义谓词及个体
- 变元赋值
- 用连接词连接各个谓词，形成谓词公式

8. 一阶谓词逻辑表示法的特点

- 优点
  - 自然醒
  - 精确性
  - 严密性
  - 容易实现
- 局限性
  - 不能表示不确定的知识
  - 组合爆炸
  - 效率低

试用水印

2.3 产生式表示法

1. 产生式通常用于表示事实、规则以及它们的不确定性度量
2. 适合于表示事实性知识和规则性知识
3. 表示方法

1. 确定性规则知识的产生式表示

- 基本形式： IF P THEN Q

  或者： $P \rightarrow Q$

- 例如：

  r_4: IF 动物会飞 AND 会下蛋 THEN 该动物是鸟

2. 不确定性规则知识的产生式表示

- 基本形式： IF P THEN Q (置信度)

  或者： $P \rightarrow Q$ (置信度)

  例如： IF 发烧 THEN 感冒 (0.6)

3. 确定性事实性知识的产生式表示

- 三元组表示： **(对象，属性，值)**

  或者： **(关系，对象1，对象2)**

- 例： 老李年龄是40岁： (*Li*, *age*, 40)

  老李和老王是朋友： (*friend*, *Li*, *Wang*)

4. 不确定性事实性知识的产生式表示

- 四元组表示： **(对象，属性，值，置信度)**

  或者： **(关系，对象1，对象2，置信度)**

- 例：老李年龄很可能是40岁： (*Li*, *age*, 40, 0.8)

  老李和老王不大可能是朋友： (*friend*, *Li*, *Wang*, 0.1)

4. 产生式与谓词逻辑中的蕴含式的区别

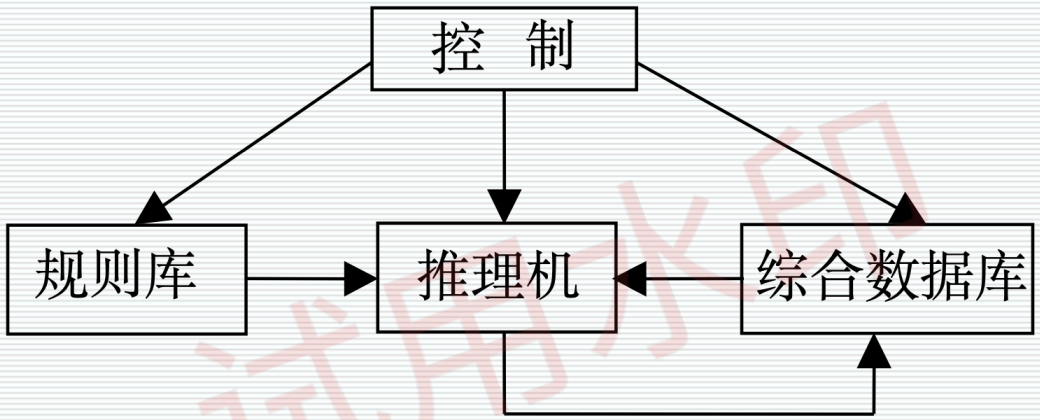
- 除逻辑蕴含外，产生式还包括各种操作、规则、 变换、算子、函数等。
- 蕴含式只能表示精确知识，而产生式不仅可以表、示精确的知识，还可以表示不精确知识。蕴含式的匹配总要求是精确的。产生式匹配可以是精确的， 也可以是不精确的，只要按某种算法求出的相似度落在预先指定的范围内就认为是可匹配的。

5. 产生式的形式描述及语义（巴科斯范式 BNF）

<产生式>::=<前提> → <结论>
<前 提>::=<简单条件>|<复合条件>
<结 论>::=<事实>|<操作>
<复合条件>::=<简单条件>AND<简单条件>[AND<简单条件>…
|<简单条件>OR<简单条件>[OR<简单条件>…
<操 作>::=<操作名>[(<变元>，…)]

符号“::=”表示“定义为”；符号“|”表示“或者是”；符号“[ ]”表示“可缺省”。

6. 产生式系统

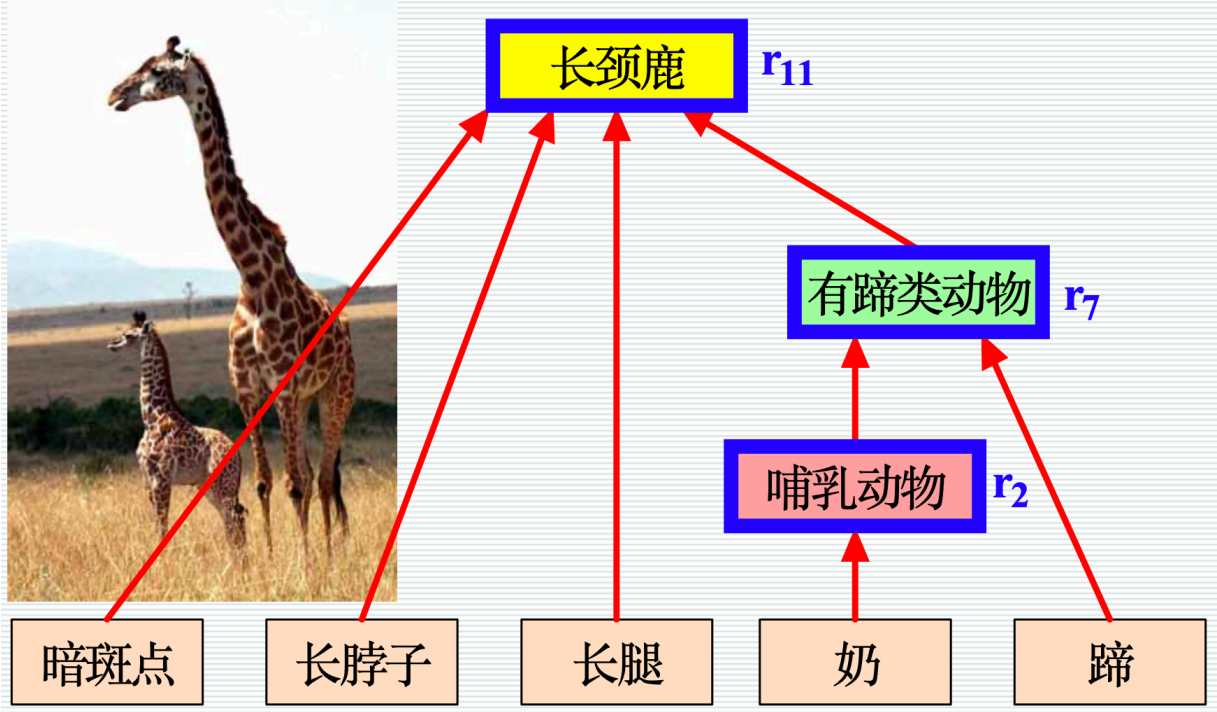


- **规则库**：用于描述相应领域内知识的产生式集合。
- **综合数据库**(事实库、上下文、黑板等)：一个用于存放问题求解过程中各种当前信息的数据结构。
- **控制系统**（推理机构）：由一组程序组成，负责整个产生式系统的运行，实现对问题的求解。

控制系统所做的工作：

- 从规则库中选择与综合数据库中的已知事实进行匹配
- 匹配成功的规则可能不止一条，进行冲突消解
- 执行某一规则时，如果其右部是一个或多个结论，则 把这些结论加入到综合数据库中
  如果其右部是一个或多个操作，则执行这些操作。
- 对于不确定性知识，在执行每一条规则时还要按一定的算法计算结论的不确定性
- 检查综合数据库中是否包含了最终结论，决定是否停止系统的运行

产生系统的例子（动物识别系统）：



7. 产生式表示法的特点

- 优点
  - 自然性
  - 模块性
  - 有效性
  - 清晰性
- 缺点
  - 效率不高
  - 不能表达结构性知识
- 适合产生式表示的知识
  - 领域知识间关系不密切， 不存在结构关系。
  - 经验性及不确定性的知识， 且相关领域中对这些知识没有 严格、统一的理论。
  - 领域问题的求解过程可被表示为一系列相对独立的操作， 且每个操作可被表示为一条或多条产生式规则。

2.4 框架表示法

1. 定义：框架表示法是一种结构化的知识表示方法
2. 框架：一种描述所论对象(一个事物、事件或概念)属性的数据结构。

- 一个框架由若干个被称为“槽”(slot)的结构组成
- 每一个槽又可根据实际情况划分为若干个“侧面” (faced)
- 一个槽用于描述所论对象某一方面的属性
- 一个侧面用于描述相应属性的一个方面
- 槽和侧面所具有的属性值分别被称为槽值和侧面值（属性值与属性值的构成？）

试用水印

<框架名>

槽名1： 侧面名$_{11}$ 侧面值$_{111}$，…，侧面值$_{11P1}$

⋮ ⋮

侧面名$_{1m}$ 侧面值$_{1m1}$，…，侧面值$_{1mPm}$

槽名n： 侧面名$_{n1}$ 侧面值$_{n11}$，…，侧面值$_{n1P1}$

⋮

侧面名$_{nm}$ 侧面值$_{nm1}$，…，侧面值$_{nmPm}$

约束： 约束条件$_1$

⋮

约束条件$_n$

e.g.

框架名：〈教师〉
姓名：单位（姓、名）
年龄：单位（岁）
性别：范围（男、女）
缺省：男
职称：范围（教授，副教授，讲师，助教）
缺省：讲师
部门：单位（系，教研室）
住址：〈住址框架〉
工资：〈工资框架〉
开始工作时间：单位（年、月）
截止时间：单位（年、月）
缺省：现在

试用水印

3. 框架表示法的特点

- 结构性：便于表达结构性知识，能够将知识的内部结构关系及识间的联系表示出来。
- 继承性：框架网络中，下层框架可以继承上层框架的槽值，也可以进行补充和修改。
- 自然性：框架表示法与人在观察事物时的思维活动是一致的。

2.4 知识图谱

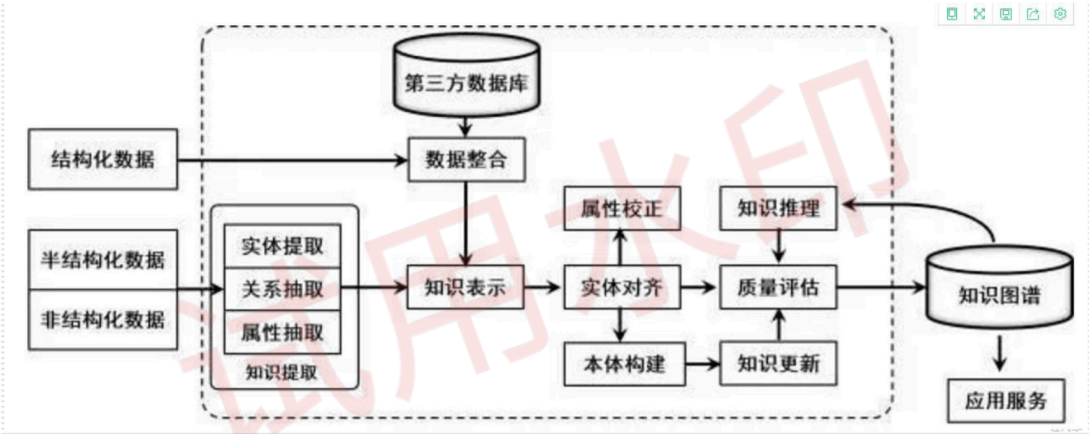
1. 知识图谱是一种互联网环境下的知识表示方法
2. 知识图谱(**Knowledge Graph/Vault**)，又称科学知识图谱，用各种不同的图形等可视化技术描述知识资 源及其载体，挖掘、分析、构建、绘制和显示知识及 它们之间的相互联系。
3. 知识图谱是由一些相互连接的实体及其属性构成的
4. 三元组是知识图谱的一种通用表示方式

- (实体1-关系-实体2):中国-首都-北京
- (实体-属性-属性值):北京-人口-2069万

5. 知识图谱也可被看作是一张图，图中的节点表示实体或概念，而图中的边则由属性或关系构成。
6. 知识图谱的架构

- 逻辑结构：模式层和数据层
- 数据层主要是由一系列的事实组成，而知识以事实为单位进行存储。
- 模式层构建在数据层之上，是知识图谱的核心。

7. 知识图谱的体系结构



8. 获取知识的资源对象

- 结构化数据
  - 知识定义和表示都比较完备的数据。
- 半结构化数据
  - 部分数据是结构化的，但存在大量结构化程度较低的数据。
- 非结构化数据
  - 没有定义和规范约束的“自由”数据。

9. 知识图谱的构建

- 自顶向下指的是先为知识图谱定义好本体与数据 模式，再将实体加入到知识库。
- 自底向上指的是从一些开放链接数据中提取出实体，选择其中置信度较高的加入到知识库，再构建顶层的本体模式。

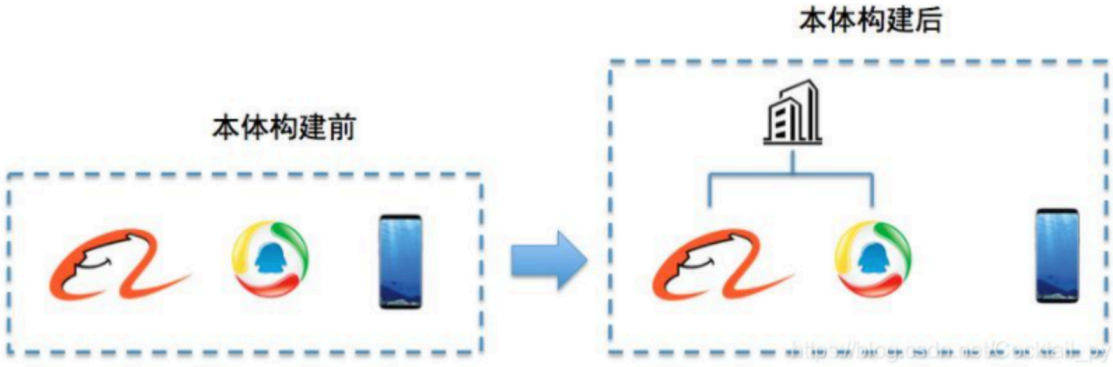
10. 实体和本体

本体（ontology）是指工人的**概念集合**、**概念框架**，如“人”、“事”、“物”等。

比如对下面这个例子，当知识图谱刚得到“阿里巴巴”、“腾讯”、“手机”这三个实体的时候，可能会认为它们三个之间并没有什么差别，但当它去计算三个实体之间的相似度后，就会发现，阿里巴巴和腾讯之间可能更相似，和手机差别更大一些。

这就是第一步的作用，但这样下来，知识图谱实际上还是没有一个上下层的概念，它还是不知道，阿里巴巴和手机，根本就不隶属于一个类型，无法比较。因此我们在实体上下位关系抽取这一步，就需要去完成这样的工作，从而生成第三步的本体。

当三步结束后，这个知识图谱可能就会明白，“阿里巴巴和腾讯，其实都是公司这样一个实体下的细分实体。它们和手机并不是一类。”



3 确定性推理方法

1. 为使计算机具有智能，还必须使它具有思维能力。
2. 推理是求解问题的一种重要方法。

3.1 推理的基本概念

1. 定义

- 根据已知事实（证据）和知识依照某种策略得出的结论

2. 演绎推理、归纳推理、默认推理

- 演绎推理：一般到个别 （三段论）
- 归纳推理：个别到一般
  - 完全归纳推理（必然性推理）
  - 不完全归纳推理（非必然推理）
- 默认推理（缺省推理）
  - 知识不完全的情况下假设某些条件已经具备所进行的推理

3. 确定性推理和不确定性推理

- 确定性推理：推理时所用的知识与证据都是确定的， 推出的结论也是确定的，其真值或者为真或者为假。
- 不确定性推理：推理时所用的知识与证据不都是确定 的，推出的结论也是不确定的。

4. 单调推理和非单调推理

- 单调推理：随着推理向前推进及新知识的加入，推出的结论越来越接近最终目标。
  - 基于经典逻辑的演绎推理

试用水印

- 非单调推理：由于新知识的加入，不仅没有加强已推出的结论，反而要否定它，使推理退回到前面的某一步，重新开始。
    - 默认推理是非单调推理

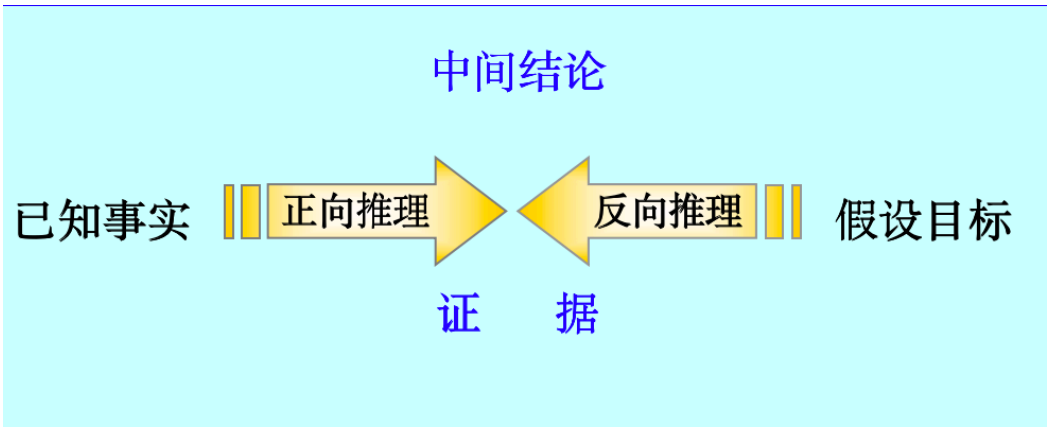
5. 启发式推理和非启发式推理

- 启发式推理：与问题有关且能加快推理过程、提高搜索效率的知识。
- 非启发式推理

6. 推理的方向

- 正向推理（事实驱动推理）已知事实 → 结论
    - 基本思想
        - 从初始已知事实出发，在知识库KB中找出当前可适用的知识，构成可适用知识集KS
        - 按某种冲突消解策略从KS中选出一条知识进行推理，并将推出的新事实加入到数据库DB中作为下一步推理的已知事实，再在KB中选取可适用知识构成KS 。
        - 重复（2），直到求得问题的解或KB中再无可适用的知识。
    - 实现正向推理需要解决的问题
        - 确定匹配（知识与已知事实）的方法
        - 按什么策略搜索知识库
        - 冲突消解策略
    - 正向推理简单，易实现，但目的性不强，效率低。
- 逆向推理（目标驱动推理）以某个假设目标作为出发点
    - 基本思想
        - 选定一个假设目标
        - 寻找支持该假设的证据，若所需的证据都能找到，则原假设成立；若无论如何都找不到所需要的证据，说明原假设不成立的；为此需要另作新的假设
    - 主要优点
        - 不必使用与目标无关的知识，目的性强，同时它还有利于向用户提供解释。
    - 主要缺点
        - 起始目标的选择具有盲目性
    - 逆向推理需要解决的问题
        - 如何判断一个假设是否是证据?
        - 当导出假设的知识有多条时，如何确定先选哪一条?
        - 一条知识的运用条件一般都有多个，当其中的一个经验证成立后，如何自动地换为对另一个的验证?
    - 逆向推理：目的性强，利于向用户提供解释，但选择初始目标时具有盲目性，比正向推理复杂。
- 双向推理
    - 向推理与逆向推理同时进行，且在推理过程中的某一步骤上“碰头”的一种推理。

试用水印



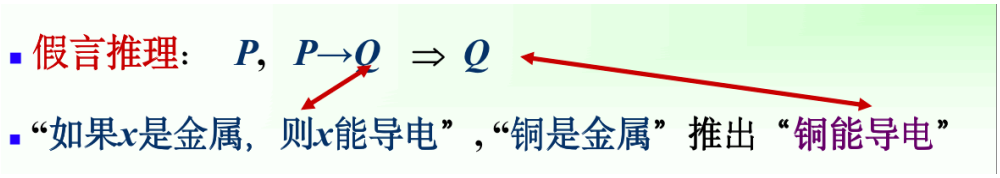
7. 冲突消解策略

- 已知事实与知识的三种匹配情况
  - 恰好匹配成功（一对一）
  - 不能匹配成功
  - 多种匹配成功（一对多、多对一、多对多）
- 多种冲突消解策略
  - 按针对性排序
  - 按已知事实的新鲜性排序
  - 按匹配度排序
  - 按条件个数排序

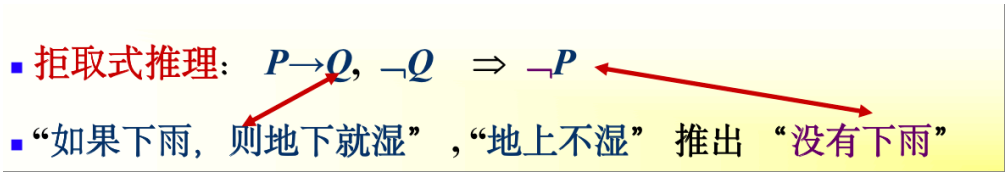
3.2 自然演绎推理

1. 自然演绎推理：从一组已知为真的事实出发，运用经典逻辑的推理规则推出结论的过程。
2. 推理规则：P规则、T规则、假言推理、拒取式推理

- P规则：在推理的任何步骤都可以引入前提。即推理中使用的前提。
- T规则：推理时，如果前面步骤中有一个或者多个公式永真蕴含公式S，则可把S引入推理过程中。
- 假言推理



- 拒取式推理



试用水印

- 错误1——否定前件：$P\rightarrow Q$，$\neg P$ $\not\Rightarrow$ $\neg Q$

  （1） 如果下雨，则地上是湿的（$P\rightarrow Q$）；
  （2）没有下雨（$\neg P$）；
  （3）所以，地上不湿（$\neg Q$）。

- 错误2——肯定后件：$P\rightarrow Q$，Q $\not\Rightarrow$ P

  （1）如果行星系统是以太阳为中心的，则金星会显示出位相变化（$P\rightarrow Q$）；
  （2）金星显示出位相变化（Q）；
  （3）所以，行星系统是以太阳为中心（P）。

3. 例子

- 例3.1 已知事实：

  （1）凡是容易的课程小王(Wang)都喜欢；

  （2）C 班的课程都是容易的；

  （3）ds 是 C 班的一门课程。

- 求证：小王喜欢 ds 这门课程。

试用水印

- 证明：
  - 定义谓词：

    $EASY(x)$：x 是容易的

    $LIKE(x, y)$：x 喜欢 y

    $C(x)$：x 是 C 班的一门课程

  - 已知事实和结论用谓词公式表示：

    $(\forall x)(EASY(x) \rightarrow LIKE(Wang, x))$

    $(\forall x)(C(x) \rightarrow EASY(x))$

    $C(ds)$

    结论：$LIKE(Wang, ds)$

事实

（1）凡是容易的课程小王(Wang)都喜欢；

(2) C 班的课程都是容易的；

(3) ds 是 C 班的一门课程。

- 应用推理规则进行推理：

$(\forall x)(EASY(x) \rightarrow LIKE(Wang, x))$

$EASY(z) \rightarrow LIKE(Wang, z)$　　全称固化

$(\forall x)(C(x) \rightarrow EASY(x))$

$C(y) \rightarrow EASY(y)$　　全称固化

所以 $C(ds), C(y) \rightarrow EASY(y)$

$\Rightarrow EASY(ds)$　　P规则及假言推理

所以 $EASY(ds), EASY(z) \rightarrow LIKE(Wang, z)$

$\Rightarrow LIKE(Wang, ds)$　T规则及假言推理

4. 自然演绎推理的优缺点

- 优点
  - 表达定理证明过程自然、易于理解
  - 拥有丰富的推理规则，推理过程灵活
  - 便于嵌入领域启发式知识
- 缺点

- 易产生组合爆炸，得到的中间结论一般呈指数形式递增

4 不确定性推理方法

4.1 不确定性推理中的基本问题

1. 推理：从已知事实(证据)出发，通过运用相关 知识逐步推出结论或者证明某个假设成立或不成 立的思维过程。
2. 从不确定性的初始证据出发，通 过运用不确定性的知识，最终推出具有一定程度 的不确定性但却是合理或者近乎合理的结论的思 维过程。
3. 不确定性的表示与度量

- 知识不确定性的表示
  - 在专家系统中知识的不确定性一般是由领域专家给出的，通常是一个数值——知识的静态强度
- 证据不确定性的表示（证据的动态强度）
  - 用户在求解问题时提供的初始证据。
  - 在推理中用前面推出的结论作为当前推理的证据。
- 不确定性的量度
  - 能充分表达相应知识及证据不确定性的程度。
  - 度量范围的指定便于领域专家及用户对不确定性的估计。
  - 便于对不确定性的传递进行计算，而且对结论算出的不确定性量度不能超出量度规定的范围。
  - 度量的确定应当是直观的，同时应有相应的理论依据。

4. 不确定性匹配算法及阈值的选择

- 不确定性匹配算法：用来计算匹配双方相似程度的算法。
- 阈值：用来指出相似的“限度”。

5. 组合证据不确定性的算法

- 最大最小方法、Hamacher方法、概率方法、有界方法、Einstein方法等。

6. 不确定性的传递算法

- 在每一步推理中，如何把证据及知识的不确定性传递给结论。
- 在多步推理中，如何把初始证据的不确定性传递给最终结论。

7. 结论不确定性的合成

4.2 可信度方法

1. 可信度：根据经验对一个事物或现象为真的相信程度。

- 可信度带有较大的主观性和经验性，其准确性难以把握。
- C－F模型：基于可信度表示的不确定性推理的基本方法。

2. 知识不确定性的表示

试用水印

- **产生式规则表示:**

$$\text{IF} \quad E \quad \text{THEN} \quad H \quad (CF(H,E))$$

$CF(H,E)$：可信度因子（certainty factor），反映前提条件与结论的联系强度。

- CF（H，E）的取值范围: [-1,1]。
- 若由于相应证据的出现增加结论 H 为真的可信度，则 CF（H，E）> 0，证据的出现越是支持 H 为真，就使 CF（H，E) 的值越大。
- 反之，CF（H，E）< 0，证据的出现越是支持 H 为假，CF（H，E）的值就越小。
- 若证据的出现与否与 H 无关，则 CF（H，E）= 0。

3. 证据不确定性的表示

- CF(E)＝0.6： E的可信度为0.6
- 证据E的可信度取值范围：[-1，1] 。
- 对于初始证据，若所有观察S能肯定它为真，则CF(E)= 1；若肯定它为假，则 CF(E) = –1。
- 若以某种程度为真，则 0 < CF(E) < 1；若以某种程度为假，则 －1 < CF(E) < 0 。
- 若未获得任何相关的观察，则 CF(E) = 0。

- **静态强度**$CF(H, E)$：知识的强度，即当 E 所对应的证据为真时对 H 的影响程度。
- **动态强度** $CF(E)$：证据 E 当前的不确定性程度。

- 知识是静态的，证据是动态的

4. 组合证据不确定性的算法

- 组合证据：多个单一证据的合取

$$E=E_1 \quad \text{AND} \quad E_2 \quad \text{AND} \quad \cdots \quad \text{AND} \quad E_n$$

则 $CF(E)=\min\{CF(E_1),CF(E_2),...,CF(E_n)\}$

- 组合证据：多个单一证据的析取

$$E=E_1 \quad \text{OR} \quad E_2 \quad \text{OR} \quad \cdots \quad \text{OR} \quad E_n$$

则 $CF(E)=\max\{CF(E_1),CF(E_2),\cdots,CF(E_n)\}$

5. 不确定性的传递算法

- C－F模型中的不确定性推理：从不确定的初始证据出发，通过运用相关的不确定性知识，最终推出结论并求出结论的可信度值。

试用水印

结论 H 的可信度由下式计算:

- $$CF(H)=CF(H,E)\times\max\{0,CF(E)\}$$

当 $CF(E)<0$时， 则 $CF(H)=0$

当 $CF(E)=1$时， 则 $CF(H)=CF(H,E)$

6. 结论不确定性的合成算法

- 设知识:

$$\text{IF}\quad E_1\ \text{THEN}\ H\qquad (CF(H,E_1))$$

$$\text{IF}\quad E_2\ \text{THEN}\ H\qquad (CF(H,E_2))$$

(1) 分别对每一条知识求出$CF(H)$:

$$CF_1(H)=CF(H,E_1)\times\max\{0,CF(E_1)\}$$

$$CF_2(H)=CF(H,E_2)\times\max\{0,CF(E_2)\}$$

(2) 求出E_1与E_2对H的综合影响所形成的可信度 $CF_{1,2}(H)$:

$$CF_{1,2}(H)=\begin{cases}CF_1(H)+CF_2(H)-CF_1(H)CF_2(H) & \text{若}CF_1(H)\geq 0,\quad CF_2(H)\geq 0\\ CF_1(H)+CF_2(H)+CF_1(H)CF_2(H) & \text{若}CF_1(H)<0,\quad CF_2(H)<0\\ \dfrac{CF_1(H)+CF_2(H)}{1-\min\{|CF_1(H)|,|CF_2(H)|\}} & \text{若}CF_1(H)\text{与}\quad CF_2(H)\text{异号}\end{cases}$$

4.3 证据理论

1. 概率分配函数

- 设 D 是变量 x 所有可能取值的集合，且 D 中的元素是互斥的，在任一时刻 x 都取且只能取 D 中的某一个元素为值，则称 D 为 x 的样本空间。
- 在证据理论中，D 的任何一个子集 A 都对应于一个关于 x 的命题，称该命题为“ x 的值是在 A 中”。

▪ 设D为样本空间，领域内的命题都用D的子集表示，则概率分配函数（basic probability assignment function）定义如下：

定义4.1 设函数 $M: 2^D \to [0,1]$，（对任何一个属于D的子集A，命它对应一个数$M \in [0, 1]$） 且满足

$$M(\Phi) = 0$$

$$\sum_{A \subseteq D} M(A) = 1$$

则 M是 2^D上的基本概率分配函数，$M(A)$是 A的基本概率数。

几点说明：

（1）设样本空间D中有n个元素，则D中子集的个数为 2^n个。

2^D： D的所有子集。

（2）概率分配函数：把D的任意一个子集A都映射为[0，1]上的一个数M（A）。

（3）概率分配函数与概率不同。

试用水印

2. 信任函数

定义4.2 命题的信任函数（belief function）Bel：

$$2^D \to [0,1] \text{ 且 } Bel(A) = \sum_{B \subseteq A} M(B) \quad \forall A \subseteq D$$

$Bel(A)$：对命题A为真的总的信任程度。

- 由信任函数及概率分配函数的定义推出：

$$Bel(\Phi) = M(\Phi) = 0$$

$$Bel(D) = \sum_{B \subseteq D} M(B) = 1$$

3. 似然函数

- 似然函数（plansibility function）：不可驳斥函数或上限函数。

定义4.3 似然函数 $Pl: 2^D \to [0,1]$ 且

$$Pl(A) = 1 - Bel(\neg A) \qquad \forall A \subseteq D$$

- 设 D ={红，黄，蓝}

M（{红}）=0.3，M（{黄}）=0，M（{红，黄}）=0.2，

$$Bel(\{红,黄\}) = M(\{红\}) + M(\{黄\}) + M(\{红,黄\})$$
$$= 0.3 + 0.2 = 0.5$$
$$Pl(\{蓝\}) = 1 - Bel(\neg\{蓝\}) = 1 - Bel(\{红，黄\}) = 1 - 0.5 = 0.5$$

4. 概率分配函数的正交和

定义4.4 设 M_1 和 M_2是两个概率分配函数；则其正交和 $M=M_1\oplus M_2$ ： $M(\Phi)=0$

$$M(A)=K^{-1}\sum_{x\cap y=\Phi}M_1(x)M_2(y)$$

其中： $K=1-\sum_{x\cap y=\Phi}M_1(x)M_2(y)=\sum_{x\cap y\neq\Phi}M_1(x)M_2(y)$

如果 $K\neq 0$，则正交和 M也是一个概率分配函数；

如果 $K=0$，则不存在正交和 M，即没有可能存在概率函数，称M_1 与M_2 矛盾。

错误修正： $M(A)=K^{-1}\sum_{x\cap y=A}M_1(x)M_2(y)$

5. 基于证据理论的不确定性推理

- 基于证据理论的不确定性推理的步骤：
  (1) 建立问题的样本空间D。
  (2) 由经验给出，或者由随机性规则和事实的信度度量算基本概率分配函数。
  (3) 计算所关心的子集的信任函数值、似然函数值。
  (4) 由信任函数值、似然函数值得出结论。

试用水印

简化不确定性的推理模型，这里给出一个具体的概率分配函数。设样本空间，领域内的命题都用D的子集表示，则定义上的概率分配函数M(x)满足如下条件：

$$(1)\,M(\{S_i\}) \geq 0, \text{对任何} \{S_i\} \in 2^D$$

$$(2)\sum_{i=1}^{n} M(\{S_i\}) \leq 1$$

$$(3)\,M(D) = 1 - \sum_{i=1}^{n} M(\{S_i\})$$

$$(4)\text{当} A \subset D \text{且} |A| > 1 \text{或} |A| = 0 \text{时，} M(A) = 0$$

其中$|A|$表示命题A对应的集合中所包含的元素的个数

4.4 模糊推理方法

1. 模糊集合的定义

- 论域：所讨论的全体对象，用 U 等表示。
- 元素：论域中的每个对象，常用a,b,c,x,y,z表示。
- 集合：论域中具有某种相同属性的确定的、可以彼此区别的元素的全体，常用A，B等表示。
- 元素a和集合A的关系：a属于A或a不属于A，即只有两个真值“真”和“假”。
- 模糊逻辑给集合中每一个元素赋予一个介于0和1之间的实数，描述其属于一个集合的强度，该实数称为元素属于一个集合的隶属度。集合中所有元素的隶属度全体构成集合的隶属函数。

2. 模糊集合的表示方法

当论域中元素数目有限时，模糊集合 A的数学描述为

$$A = \{(x, \mu_A(x)), x \in X\}$$

$\mu_A(x)$：元素 x 属于模糊集 A 的隶属度，X 是元素 x 的论域。

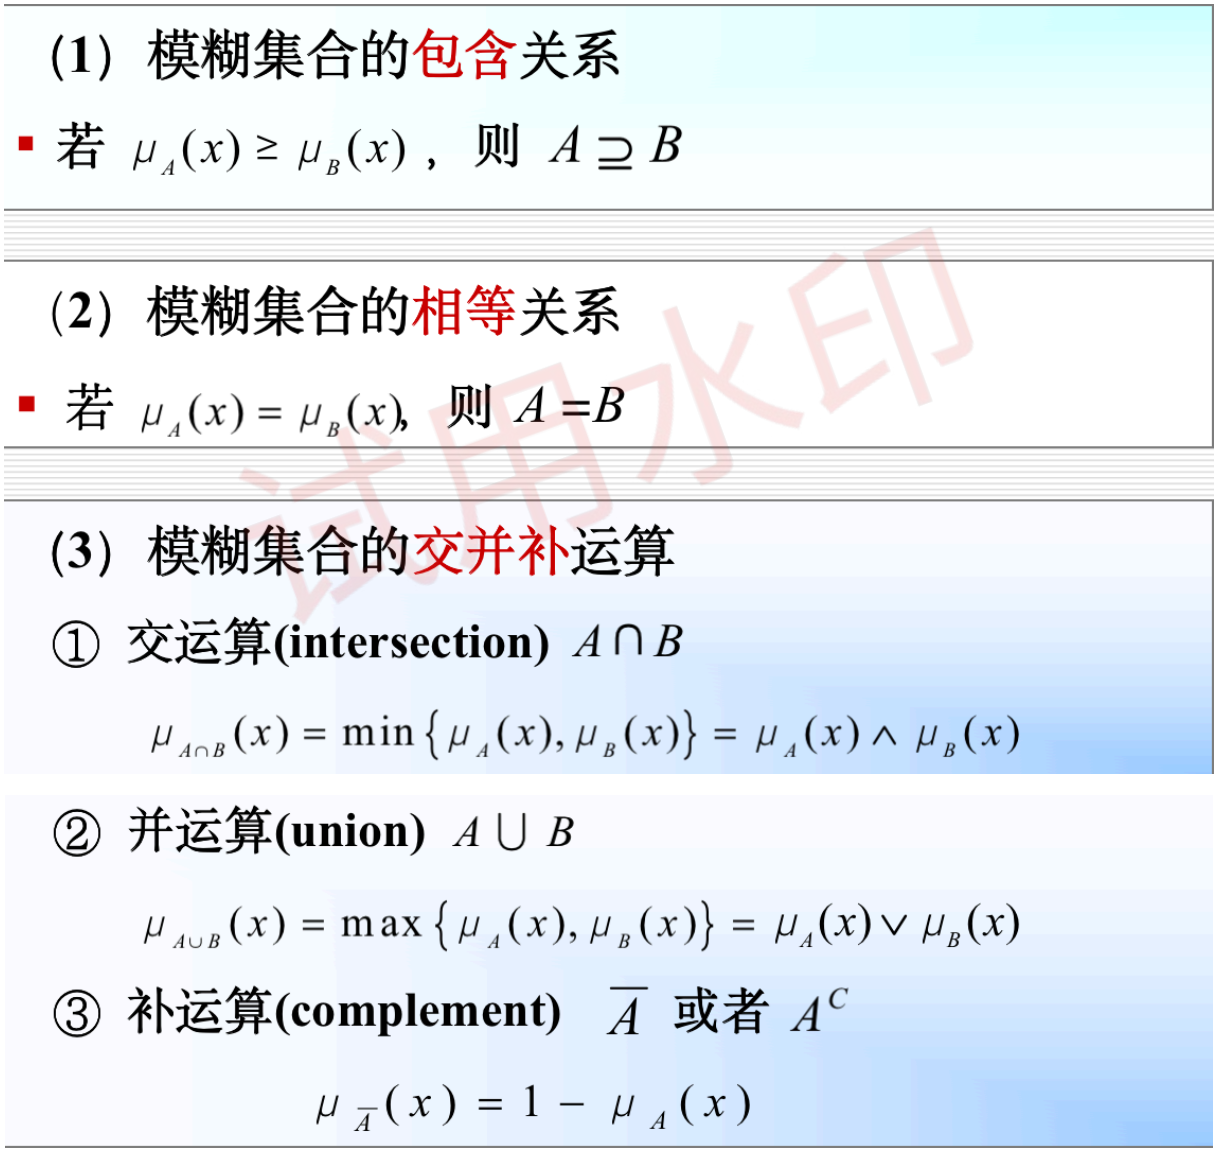
试用水印

- Zadeh表示法
- 序偶表示法
- 向量表示法

3. 隶属函数

- 常见的隶属函数有正态分布、三角分布、梯形分布等。
- 隶属函数确定方法
  - 模糊统计法
  - 专家经验法
  - 二元对比排序法
  - 基本概念扩充法

4. 模糊集合的运算



5. 模糊集合的代数运算

① 代数积： $\mu_{AB}(x) = \mu_A(x)\mu_B(x)$

② 代数和： $\mu_{A+B}(x) = \mu_A(x) + \mu_B(x) - \mu_{AB}(x)$

③ 有界和：

$$\mu_{A\oplus B}(x) = \min\{1, \mu_A(x) + \mu_B(x)\} = 1 \wedge [\mu_A(x) + \mu_B(x)]$$

④ 有界积：

$$\mu_{A\otimes B}(x) = \max\{0, \mu_A(x) + \mu_B(x) - 1\} = 0 \vee [\mu_A(x) + \mu_B(x) - 1]$$

6. 模糊关系与模糊关系的合成

- 模糊关系
  - 普通关系：两个集合中的元素之间是否有关联
  - 模糊关系：两个模糊集合中的元素之间关联程度的多少
- 模糊关系的合成
  - ***A***、***B***：模糊集合，模糊关系用叉积(cartesian product)表示：

$$R : A \times B \rightarrow [0,1]$$

  - 叉积常用最小算子运算：

$$\mu_{A\times B}(a,b) = \min\{\mu_A(a), \mu_B(b)\}$$

  - ***A***、***B***：离散模糊集，其隶属函数分别为：

$$\mu_A = [\mu_A(a_1), \mu_A(a_2), \cdots, \mu_A(a_n)], \quad \mu_B = [\mu_B(b_1), \mu_B(b_2), \cdots, \mu_B(b_n)]$$

则其叉积运算： $\mu_{A\times B}(a,b) = \mu_A^T \circ \mu_B$

模糊关系的合成 叉乘运算取较小值 min 加法为并运算取较大值max

7. 模糊推理

- 模糊知识的表示
  - 人类思维判断的基本形式：如果 （条件） → 则 （结论）
  - 模糊规则：从条件论域到结论论域的模糊关系矩阵 R。通过条件模糊向量与模糊关系 R 的合成进行模糊推理，得到结论的模糊向量，然后采用“清晰化”方法将模糊结论转换为精确量。
- 对 IF A THEN B 类型的模糊规则的推理

试用水印

- 若已知输入为 A，则输出为 B ；若现在已知输入为 A'，则输出 B' 用合成规则求取 $B' = A' \circ R$

其中模糊关系R：$\mu_R(x,y) = \min[\mu_A(x), \mu_B(y)]$

- 控制规则库的N条规则有N个模糊关系：$R_1, R_2, \cdots, R_n$

对于整个系统的全部控制规则所对应的模糊关系R：

$$R = R_1 \bigcup R_2 \bigcup \cdots \bigcup R_n = \bigcup_{i=1}^{n} R_i$$

8. 模糊决策

由模糊推理得到的结论或者操作是一个模糊向量，转化为确定值的过程。

- 最大隶属度法
- 加权平均决判法

$$U = \frac{\sum_{i=1}^{n} \mu(u_i) u_i}{\sum_{i=1}^{n} \mu(u_i)}$$

- 中位数法

- 例如

$$U' = 0.1/-4 + 0.5/-3 + 0.1/-2 + 0.0/-1 + 0.1/0 + 0.2/1 + 0.4/2 + 0.5/3 + 0.1/4$$

$u^* = u_6$时，$\sum_{u_1}^{u_6} \mu(u_i) = \sum_{u_7}^{u_9} \mu(u_i) = 1$

所以中位数$u^* = u_6$，则$U = 1$

试用水印

- 例如

$$U' = 0.1/-4 + 0.5/-3 + 0.3/-2 + 0.1/-1 + 0.1/0 + 0.4/1 + 0.5/2 + 0.1/3 + 0.2/4$$

$$u^* = u_5 + \Delta u$$

实际应用中可直接取u_5或者u_6，不用很精确

9. 开门风度的例子 ppt

5 搜索求解策略

5.1 搜索的概念

1. 搜索中需要解决的基本问题

- 是否一定能找到一个解
- 找到的解是否是最佳解
- 时间与空间复杂性如何
- 是否终止运行或是否会陷入一个死循环

2. 搜索的主要过程

- 从初始或目的状态出发，并将它作为当前状态。
- 扫描操作算子集，将适用当前状态的一些操作算子作用于当前状态而得到新的状态，并建立指向其父结点的指针 。
- 检查所生成的新状态是否满足结束状态，如果满足，则得到问题的一个解，并可沿着有关指针从结束状态反向到达开始状态，给出一解答路径；否则，将新状态作为当前状态，返回第(2)步再进行搜索。

3. 搜索策略

- 数据驱动
  - 从初始状态出发的正向搜索
  - 正向搜素：从问题给出的条件出发
- 目的驱动
  - 从目的状态出发的逆向搜索
  - 逆向搜索：从想达到的目的入手，看哪些操作算子能产生该目的以及应用这些操作算子产生目的时需要哪些条件。
- 双向搜索

试用水印

- 双向搜索：从开始状态出发作正向搜索，同时又从目的状态出发作逆向搜索，直到两条路径在中间的某处汇合为止。

4. 盲目搜索与启发式搜索

- 盲目搜索
  - 在不具有对特定问题的任何有关信息的条件下，按固定的步骤（依次或随机调用操作算子）进行的搜索。
- 启发式搜索
  - 考虑特定问题领域可应用的知识，动态地确定调用操作算子的步骤，优先选择较适合的操作算子，尽量减少不必要的搜索，以求尽快地到达结束状态。

5.2 状态空间的搜索策略

1. 基本概念

- **状态**：表示系统状态、事实等叙述型知识的一组变量或数组：

$$Q = [q_1, q_2, \cdots, q_n]^{\mathrm{T}}$$

- **操作**：表示引起状态变化的过程型知识的一组关系或函数：

$$F = \{f_1, f_2, \cdots, f_m\}$$

- **状态空间**：利用状态变量和操作符号，表示系统或问题的有关知识的符号体系，状态空间是一个四元组：

$$(S, O, S_0, G)$$

S：状态集合。
O：操作算子的集合。
S_0：包含问题的初始状态是 S 的非空子集。
G：若干具体状态或满足某些性质的路径信息描述。

试用水印

- **求解路径**：从 S_0 结点到 G 结点的路径。
- **状态空间解**：一个有限的操作算子序列。

$$S_0 \xrightarrow{O_1} S_1 \xrightarrow{O_2} S_2 \xrightarrow{O_3} \cdots \xrightarrow{O_k} G$$

$O_1, \cdots, O_k$ ： 状态空间的一个解。

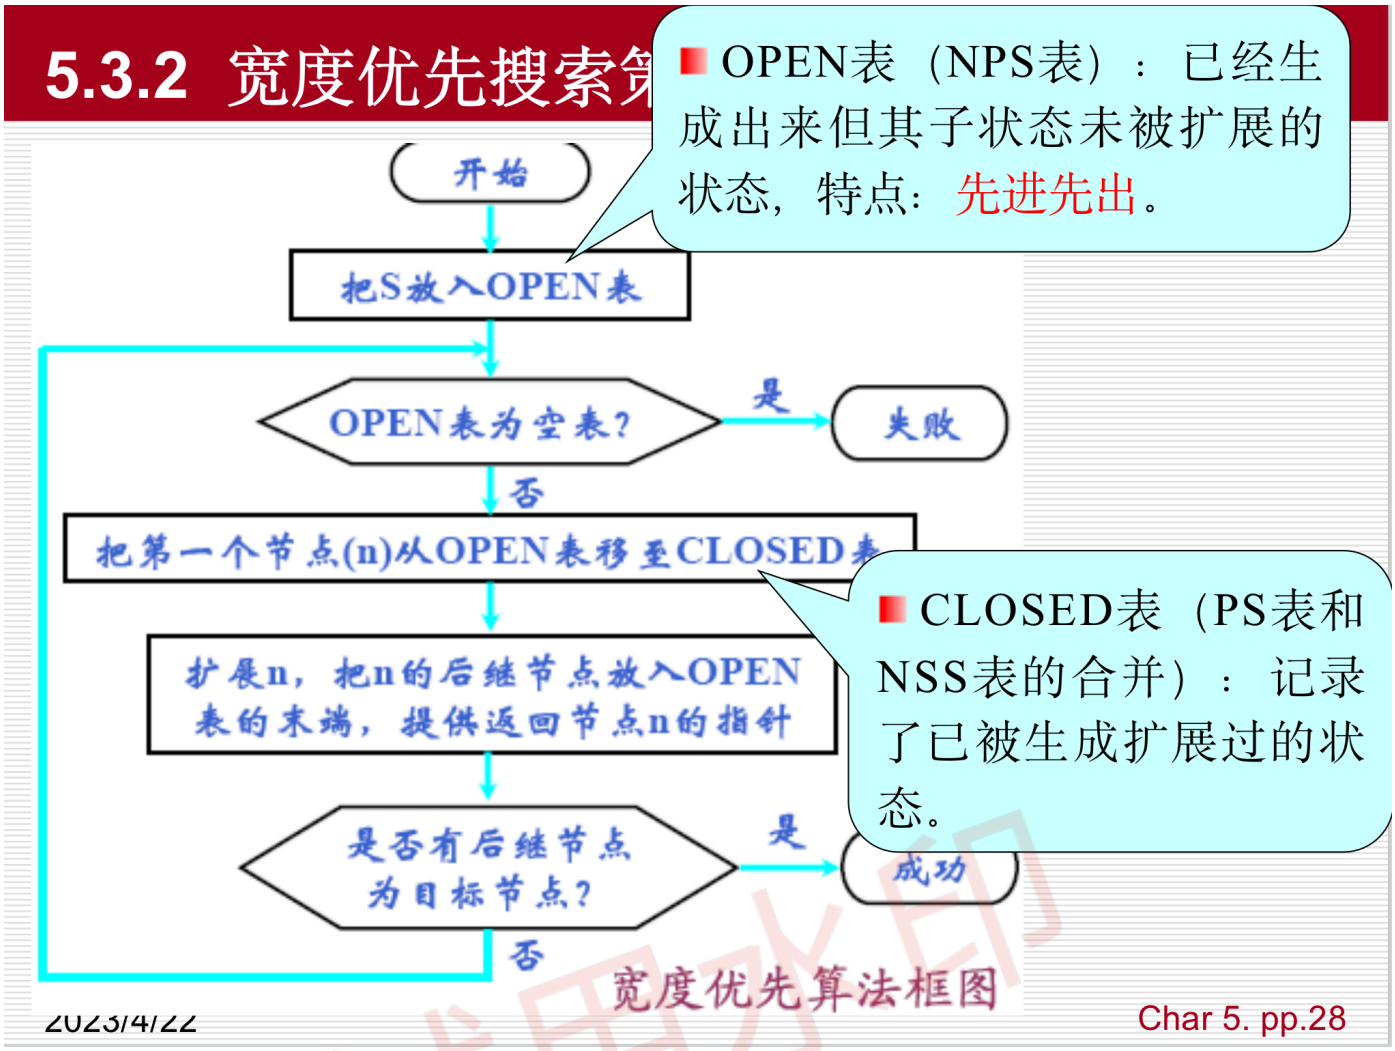
5.3 盲目的图搜索策略

1. 回溯策略

- 基本思想
  - 从初始状态出发，不停地、试探性地寻找路径，直到它到达目的或“不可解结点”，即“死胡同”为止。
  - 若它遇到不可解结点就回溯到路径中最近的父结点上，查看该结点是否还有其他的子结点未被扩展。若有，则沿这些子结点继续搜索；如果找到目标，就成功退出搜索，返回解题路径。
- 涉及到的表格信息
  - PS表：保存当前搜索路径上的状态。如果找到了目的，PS就是解路径上的状态有序集
  - NPS表：新的路径状态表。它包含了等待搜索的状态，其后裔状态还未被搜索到，即未被生成扩展 。
  - NSS表：不可解状态集，列出了找不到解题路径的状态。如果在搜索中扩展出的状态是它的元素，则可立即将之排除，不必沿该状态继续搜索。
- 图搜索算法的回溯思想
  - 用未处理状态表（NPS）使算法能返回（回溯）到其中任一状态。
  - 用一张“死胡同”状态表（NSS）来避免算法重新搜索无解的路径。
  - 在PS 表中记录当前搜索路径的状态，当满足目的时可以将它作为结果返回
  - 为避免陷入死循环必须对新生成的子状态进行检查，看它是否在该三张表中

2. 宽度优先搜索策略

- 基本思想：以接近起始节点的程度（深度）为依据，进行逐层扩展的节点搜索方法。
- 特点
  - 每次选择深度最浅的节点首先扩展，搜索是逐层进行的
  - 一种高价搜索，但若有解存在，则必能找到它
- open表（NPS表）：已经生成出来但其子状态未被搜索的状态。
- closed表（ PS表和NSS表的合并）：记录了已被生成扩展过的状态。
- 队列



3. 深度优先搜索

- 基本思想：首先扩展最新产生的节点，深度相等的节点按生成次序的盲目搜索
- 特点：扩展最深的节点的结果使得搜索沿着状态空间某条单一的路径从起始节点向下进行下去；仅当搜索到达一个没有后裔的状态时，才考虑另一条替代的路径
- 算法设计要点
  - 防止搜索过程沿着无益的路径扩展下去，往往给出一个节点扩展的最大深度——深度界限；
  - 与宽度优先搜索算法最根本的不同：将扩展的后继节点放在OPEN表的前端。
  - 深度优先搜索算法的OPEN表后进先出。
  - 深度优先搜索采用的是栈的结构
- 注意点
  - 在深度优先搜索中，当搜索到某一个状态时，它所有的子状态以及子状态的后裔状态都必须先于该状态的兄弟状态被搜索。
  - 为了保证找到解，应选择合适的深度限制值，或采取不断加大深度限制值的办法，反复搜索，直到找到解。
  - 深度优先搜索并不能保证第一次搜索到的某个状态时的路径是到这个状态的最短路径。
  - 对任何状态而言，以后的搜索有可能找到另一条通向它的路径。如果路径的长度对解题很关键的话，当算法多次搜索到同一个状态时，它应该保留最短路径。（考虑进行剪枝操作）

试用水印

5.4 启发式图搜索策略

1. 启发式信息

- 用来简化搜索过程有关具体问题领域的特性的信息叫做启发信息。

2. 启发式图搜索策略（利用启发信息的搜索方法）的特点

- 重排OPEN表，选择最有希望的节点加以扩展。
- 算法的种类：A/A*

3. 运用启发式策略的两种基本情况

- 一个问题由于存在问题陈述和数据获取的模糊性，可能会使它没有一个确定的解。
- 虽然一个问题可能有确定解，但是其状态空间特别大，搜索中生成扩展的状态数会随着搜索的深度呈指数级增长。

3. 一字棋的例子 见ppt
4. 基本信息

- 启发信息：在具体求解中，能够利用与该问题有关的信息来简化搜索过程
- 启发式搜索：利用启发信息的搜索过程
- 求解问题中能利用的大多是非完备的启发信息
    - 求解问题系统不可能知道与实际问题有关的全部信息，因而无法知道该问题的全部状态空间，也不可能用一套算法来求解所有的问题。
    - 有些问题在理论上虽然存在着求解算法，但是在工程实践中，这些算法不是效率太低，就是根本无法实现。

5. 启发信息的分类

- 按运用的方法分类
    - 陈述性启发信息：用于更准确、更精炼地描述状态
    - 过程性启发信息：用于构造操作算子
    - 控制性启发信息：表示控制策略的知识
- 按作用分类
    - 用于扩展节点的选择，即用于决定应先扩展哪一个节点，以免盲目扩展
    - 用于生成节点的选择，即用于决定要生成哪些后继节点，以免盲目生成过多无用的节点
    - 用于删除节点的选择，即用于决定删除哪些无用节点，以免造成进一步的时空浪费

6. 估价函数

- 估价函数：估算节点“希望”程度的量度。
- 估价函数值 f(n)：从初始节点经过 n节点到达目标节点的路径的最小代价估计值，其一般形式是 f (n) = g(n) + h(n)
    - g(n)：从初始节点 S0 到节点 n 的实际代价；
    - h(n)：从节点 n 到目标节点 Sg 的最优路径的估计代价，称为启发函数。
- h(n) 比重大：降低搜索工作量，但可能导致找不到最优解；
- h(n) 比重小：一般导致工作量加大，极限情况下变为盲目搜索，但可能可以找到最优解。

7. A搜索算法

试用水印

- A 搜索算法：使用了估价函数 f 的最佳优先搜索。
- 估价函数 f(n) = g(n) +h(n)
- 如何寻找并设计启发函数 h(n) ，然后以 f(n) 的大小来排列OPEN表中待扩展状态的次序，每次选择 f(n) 值最小者进行扩展。
    - 估价函数（价格）—> 选数值小的
- A搜索算法能不能保证找到最优解（路径最短的解）？
    - g(n)：从初始节点 S 到节点 n 的实际代价 ；
    - h(n)：对状态n与目标节点接近程度的某种启发式估计
    - A搜索算法不能保证找到最优解
- A*搜索算法
    - 定义h*(n)为状态n到目的状态的最优路径的代价，则当A搜索算法的启发函数h(n)小于等于h*(n)时，即h(n)≤h*(n)，则被称为A*算法。
    - 如果某一问题有解，那么利用A*搜索算法对该问题进行搜索则一定能搜索到解，并且一定能搜索到最优的解而结束。

8. A*算法的特性分析

- 可采纳性
    - 当一个搜索算法在最短路径存在时能保证找到它，就称该算法是可采纳的
    - A*搜索算法是可采纳的
    - A*搜索算法(h(n)=0) 等价于宽度优先搜索
- 单调性
    - A*搜索算法并不要求g(n)=g*(n)，则可能会沿着一条非最佳路径搜索到某一中间状态
    - 如果对启发函数h(n)加上单调性的限制，就可以总从祖先状态沿着最佳路径到达任一状态。
    - 如果某一启发函数h(n)满足以下条件，则称h(n)是单调的。
        - 对所有状态ni和nj，其中nj是ni的后裔，满足h(ni)-h(nj)<=cost(ni, nj)，其中cost(ni, nj)是从ni到nj的实际代价。
        - 目的状态的启发函数值为0。
    - A*搜索算法中采用单调性启发函数，可以减少比较代价和调整路径的工作量，从而减少搜索代价。
- 信息性
    - 在两个A*启发策略的h1和h2中，如果对搜索空间中的任一状态n都有h1(n) ≤ h2(n)，就称策略h2比h1具有更多的信息性。
    - 如果某一搜索策略的h(n)越大，则A*算法搜索的信息性越多，所搜索的状态越少。
    - 但更多的信息性需要更多的计算时间，可能抵消减少搜索空间所带来的益处。
    - eg. h=0 bfs 需要搜索的状态数很多 但是h=0 不需要进行计算

9. A*算法的核心步骤

- 构造启发式函数h(n)，并满足h(n)≤h*(n)
- 对当前状态计算f(n)=g(n)+h(n)，从候选项中取最小值的选项继续迭代
- 若有相同的最小值选项，取h(n)较小者。若h(n)也相等，则随机选择一个

10. h(n)构造示例

- 具体内容见ppt
- 每个节点（或者状态）State 都有一个H值，这个值相当于对“从该点出发到终点的距离”的一个大概的估计。

试用水印

- 这个启发值不能够大于实际值
- 注意点：终点的启发函数值为0！

6 智能计算及其应用

智能优化方法通常包括进化计算和群智能等两大类方法，是一种典型的元启发式随机优化方法。

6.1 进化算法的产生与发展

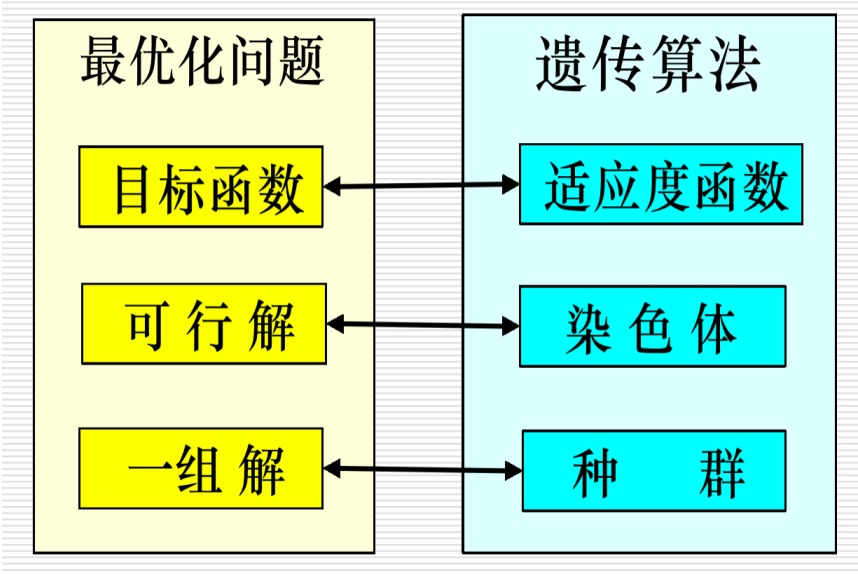
1. 基本概念

- 进化算法是基于自然选择和自然遗传等生物进化机制的一种搜索算法
- 进化算法则主要通过选择、重组和变异这三种操作实现优化问题的求解
- 进化算法是一个“算法簇”，包括遗传算法(GA)、遗传规划、进化策略和进化规划等。
- 进化算法的基本框架是遗传算法所描述的框架

2. 进化算法的生物学背景：适者生存
3. 进化算法的设计原则：

- 适用性原则
  - 一个算法的适用性是指该算法所能适用的问题种类，它取决于算法所需的限制与假定。
- 可靠性原则
  - 算法的可靠性是指算法对于所设计的问题，以适当的精度求解其中大多数问题的能力。
- 收敛性原则
  - 指算法能否收敛到全局最优。在收敛的前提下，希望算法具有较快的收敛速度
- 稳定性原则
  - 指算法对其控制参数及问题的数据的敏感度
- 生物类比原则
  - 生物界有效方法及操作可以通过类比的方法引入到算法中，有时会带来较好的结果

6.2 基本遗传算法

1. 

2. 遗传算法的基本思想

试用水印

- 在求解问题时从多个解开始
- 然后通过一定的法则进行逐步迭代以产生新的解

3. 编码

- 位串编码

  一维染色体编码方法：将问题空间的参数编码为一维排列的染色体的方法。

  - 二进制编码

    用若干二进制数表示一个个体，将原问题的解空间映射到位串空间 B={0，1}上，然后在位串空间上进行遗传操作。

    - 优点：类似于生物染色体的组成，算法易于用生物遗传理论解释，遗传操作如交叉、变异等易实现；算法处理的模式数最多。
    - 缺点：相邻整数的二进制编码可能具有较大的Hamming距离，降低了遗传算子的搜索效率；要先给出求解的精度，即编码长度。优化中难以调整；求解高维问题时，二进制编码串很长，算法的搜索效率低

  - Gary编码

    将二进制编码通过一个变换进行转换得到的编码

    二进制串 $< \beta_1\beta_2\ldots\beta_n >$ Gray $< \gamma_1\gamma_2\cdots\gamma_n >$

    二进制编码 → Gray编码 Gray编码 → 二进制编码

    $$\gamma_k = \begin{cases} \beta_1 & k=1 \\ \beta_{k-1} \oplus \beta_k & k>1 \end{cases} \qquad \beta_k = \sum_{i=1}^{k} \gamma_i \pmod 2$$

    对2取模的加法

- 实数编码：采用实数表达法不必进行数制转换，可直接在解的表现型上进行遗传操作
- 多参数映射编码的基本思想
  - 把每个参数先进行二进制编码得到子串，再把这些子串连成一个完整的染色体
  - 多参数映射编码中的每个子串对应各自的编码参数（多参数映射编码中的每个子串对应各自的编码参数）

3. 群体设定

- 初始种群的产生
  - 随机产生群体规模数目的个体作为初始群体
  - 随机产生一定数目的个体，从中挑选最好的个体加到初始群体中。这种过程不断迭代，直到初始群体中个体数目达到了预先确定的规模
  - 根据问题固有知识，把握最优解所占空间在整个问题空间中的分布范围，然后，在此分布范围内设定初始群体。
- 种群规模的确定
  - 群体规模太小，遗传算法的优化性能不太好，易陷入局部最优解
  - 群体规模太大，计算复杂

试用水印

-

> **模式定理**表明：若群体规模为M，则遗传操作可从这M个个体中生成和检测M^3个模式，并在此基础上能够不断形成和优化积木块，直到找到最优解。

4. 适应度函数

- 将目标函数映射成适应度函数的方法

（函数变形或者转化为求最大值的问题）

- 若目标函数为**最大化**问题，则 $Fit(f(x)) = f(x)$
- 若目标函数为**最小化**问题，则 $Fit(f(x)) = \frac{1}{f(x)}$

将目标函数转换为求最大值的形式,且保证函数值非负!

- 若目标函数为**最大化**问题，则

$$Fit(f(x)) = \begin{cases} f(x) - C_{\min} & f(x) > C_{\min} \\ 0 & \text{其他情况} \end{cases}$$

- 若目标函数为**最小化**问题，则

$$Fit(f(x)) = \begin{cases} C_{\max} - f(x) & f(x) < C_{\max} \\ 0 & \text{其他情况} \end{cases}$$

试用水印

- 适应度函数的尺度变换
  - 欺骗问题：在遗传算法中，将所有妨碍适应度值高的个体产生，从而影响遗传算法正常工作的问题统称为欺骗问题
    - 过早收敛：缩小这些个体的适应度，以降低这些超级个体的竞争力
    - 停滞现象：改变原始适应值的比例关系，以提高个体之间的竞争力
    - 尺度变换或定标：对适应度函数值域的某种映射变换。

5. 选择

- 个体选择概率分配方法
  - 选择操作也称为复制（reproduction）操作：从当前群体中按照一定概率选出优良的个体，使它们有机会作为父代繁殖下一代子孙。
  - 判断个体优良与否的准则是各个个体的适应度值：个体适应度越高，其被选择的机会就越多。

- 适应度比例方法/蒙特卡洛法
  - 各个个体被选择的概率和其适应度值成比例。
  - 个体 被选择的概率为
  - $$p_{si}=\frac{f_i}{\sum_{i=1}^{M} f_i}$$
- 排序方法
  - 线性排序

> ➢ 群体成员按适应值大小从好到坏依次排列：$x_1, x_2, \cdots, x_M$
>
> ➢ 个体 x_i分配选择概率 p_i
>
> $$p_i=\frac{a-bi}{M(M+1)}$$
>
> ➢ 按转盘式选择的方式选择父体

  - 非线性排序

> ● 将群体成员按适应值从好到坏依次排列，并按下式分配选择概率：
>
> $$p_i=\begin{cases} q(1-q)^{i-1} & i=1,2,\cdots,M-1 \\ (1-q)^{M-1} & i=M \end{cases}$$
>
> ● 可用其他非线性函数来分配选择概率，只要满足以下条件：
>
> (1) 若 $P=\{x_1, x_2 \cdots, x_M\}$ 且 $f(x_1)\geq f(x_2)\geq \ldots \geq f(x_M)$, 则$p_i$满足
>
> $$p_1 \geq p_2 \geq \cdots \geq p_M$$
>
> (2) $\sum_{i=1}^{M} p_i = 1$

- 选择个体方法
  - 轮盘赌选择
    - 按个体的选择概率产生一个轮盘，轮盘每个区的角度与个体的选择概率成比例
    - 产生一个随机数，它落入转盘的哪个区域就选择相应的个体交叉
  - 锦标赛选择方法

试用水印

（2）锦标赛选择方法（tournament selection model）

● **锦标赛选择方法：**从群体中随机选择个个体（有放回），将其中适应度最高的个体保存到下一代。这一过程反复执行，直到保存到下一代的个体数达到预先设定的数量为止。

● **随机竞争方法**（stochastic tournament）：每次按轮盘赌选择方法选取一对个体，然后让这两个个体进行竞争，适应度高者获胜。如此反复，直到选满为止。

- 最佳个体保存方法

● **最佳个体（elitist model）保存方法：**把群体中适应度最高的个体不进行交叉而直接复制到下一代中，保证遗传算法终止时得到的最后结果一定是历代出现过的最高适应度的个体。

6. 交叉

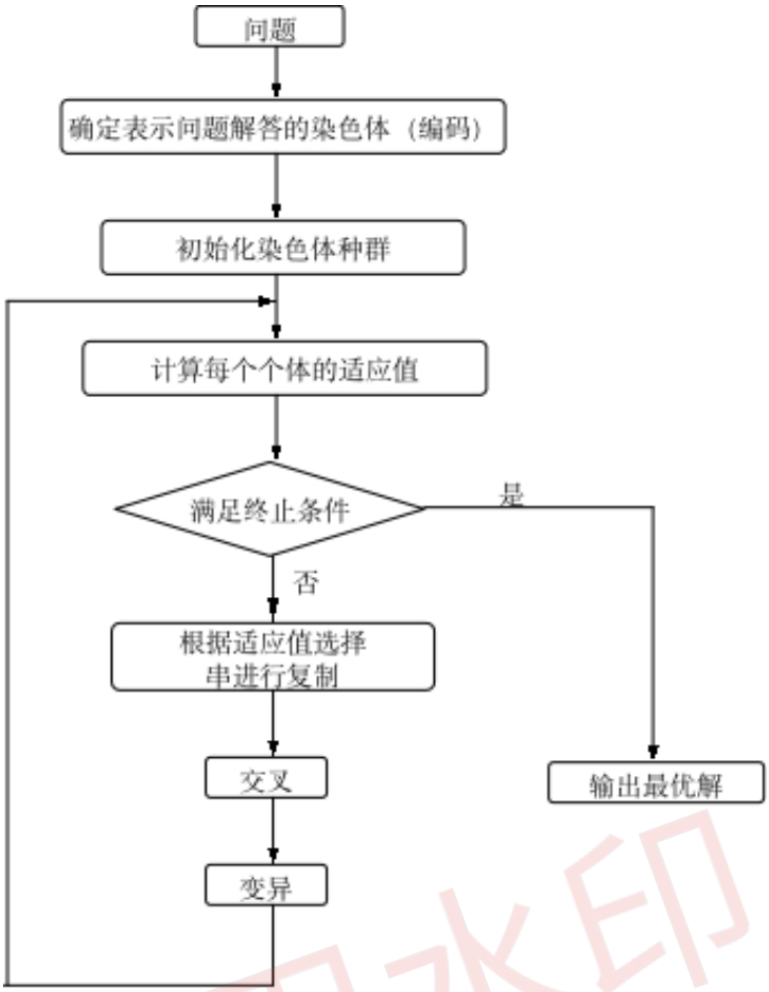
- 基本的交叉算子
  - 一点交叉：在个体串中随机设定一个交叉点，实行交叉时，该点前或后的两个个体的部分结构进行互换，并生成两个新的个体。
  - 二点交叉：随机设置两个交叉点，将两个交叉点之间的码串相互交换。
  - 修正的交叉方法：部分匹配交叉PMX

7. 变异

- 位点变异：群体中的个体码串，随机挑选一个或多个基因座，并对这些基因座的基因值以变异概率作变动。
- 逆转变异：在个体码串中随机选择两点（逆转点），然后将两点之间的基因值以逆向排序插入到原位置中。
- 插入变异：在个体码串中随机选择一个码，然后将此码插入随机选择的插入点中间。
- 互换变异：随机选取染色体的两个基因进行简单互换。
- 移动变异：随机选取一个基因，向左或者向右移动一个随机位数。

8. 遗传算法的一般步骤

试用水印



试用水印

9. 遗传算法的特点

- 一种全局优化概率算法
- 遗传算法对所求解的优化问题没有太多的数学要求，由于进化特性，搜素过程中不需要问题的内在性质，可直接对结构对象进行操作。
- 利用随机技术指导对一个被编码的参数空间进行高效率搜索
- 采用群体搜索策略，易于并行化。
- 仅用适应度函数值来评估个体，并在此基础上进行遗传操作，使种群中个体之间进行信息交换。
- 遗传算法能够非常有效地进行概率意义的全局搜素。

6.3 遗传算法的改进算法

1. 双倍体遗传算法

- 基本思想
  - 双倍体遗传算法采用显性和隐性两个染色体同时进行进化，提供了一种记忆以前有用的基因块的功能
  - 双倍体遗传算法采用显性遗传
  - 双倍体遗传延长了有用基因块的寿命，提高了算法的收敛能力，在变异概率低的情况下能保持一定水平的多样性
- 双倍体遗传的算法设计

(1) 编码/解码：两个染色体（显性、隐性）

(2) 复制算子：计算显性染色体的适应度，按照显性染色体的复制概率将个体复制到下一代群体中。

(3) 交叉算子：两个个体的显性染色体交叉、隐性染色体也同时交叉。

(4) 变异算子：个体的显性染色体按正常的变异概率变异；隐性染色体按较大的变异概率变异。

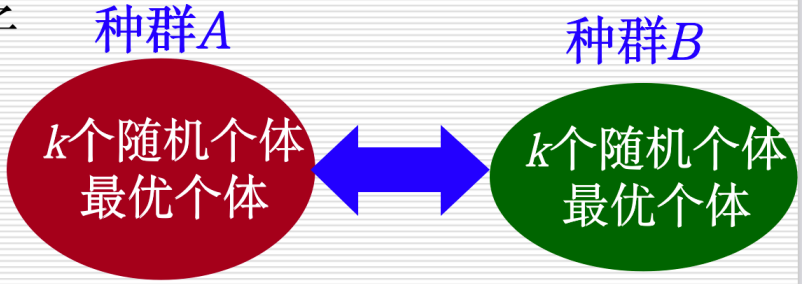
(5) 双倍体遗传算法显/隐性重排算子：个体中适应值较大的染色体设为显性染色体，适应值较小的染色体设为隐性染色体。

2. 双种群遗传算法

- 基本算法
  - 在遗传算法中使用多种群同时进化，并交换种群之间优秀个体所携带的遗传信息，以打破种群内的平衡态达到更高的平衡态，有利于算法跳出局部最优。
  - 建立两个遗传算法群体，分别独立地运行复制、交叉、变异操作，同时当每一代运行结束以后，选择两个种群中的随机个体及最优个体分别交换
- 算法设计

试用水印

- 编码/解码设计
- 交叉算子、变异算子
- 杂交算子



设种群A与种群B，当A与B种群都完成了选择、交叉、变异算子后，产生一个随机数num，随机选择A中num个个体与A中最优个体，随机选择B中num个个体与B中最优个体，交换两者，以打破平衡态。

3. 自适应遗传算法

- 基本思想

- 交叉概率Pc和变异概率 Pm能随适应度自动改变。
- 当种群各个体适应度趋于一致或者趋于局部最优时，使Pc和Pm增加，以跳出局部最优；而当群体适应度比较分散时，使Pc和Pm减少，以利于优良个体的生存。
  - 安稳增大使其变化，变化减小使其安稳
- 对于适应度高于群体平均适应值的个体，选择较低的Pc和Pm，使得该解得以保护进入下一代；对低于平均适应值的个体，选择较高的Pc和Pm值，使该解被淘汰。
  - 通过控制变化因子大小，对某些个体进行保留或者淘汰

- 算法步骤

(1) 编码/解码设计。

(2) 初始种群产生：N（N 是偶数）个候选解，组成初始解集。

(3) 定义适应度函数，计算适应度 f_i。

(4) 按轮盘赌规则选择N 个个体，计算 f_{avg}和$f_{\max}$。

(5) 将群体中的各个个体随机搭配成对，共组成$N/2$对，对每一对个体，按照自适应公式计算自适应交叉概率 P_c，随机产生$R(0,1)$，如果$R< P_c$则对该对染色体进行交叉操作。

(6) 对于群体中的所有个体，共N个，按照自适应变异公式计算自适应变异概率 P_m，随机产生 $R(0,1)$，如果 $R < P_m$ 则对该染色体进行变异操作。

(7) 计算由交叉和变异生成新个体的适应度，新个体与父代一起构成新群体。

(8) 判断是否达到预定的迭代次数，是则结束；否则转(4)。

普通自适应算法中，当个体适应度值越接近最大适应度值时，交叉概率与变异概率就越小；当等于最大适应度值时，交叉概率和变异概率为零。

6.4 遗传算法的应用

ppt

7 专家系统

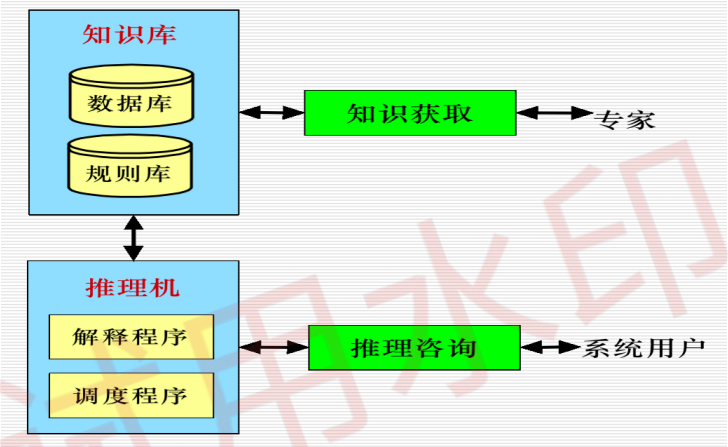
专家系统已逐渐成为人工智能的一个重要分支

7.1 专家系统的产生和发展

ppt

7.2 专家系统的概念

1. 定义：一类包含知识和推理的智能计算机程序
2. 专家系统的基本组成：知识库、推理机、专家、系统用户



3. 专家系统的特点

- 具有专家水平的专业知识
- 能进行有效的推理
- 具有启发性
- 具有灵活性
- 具有透明性
- 具有交互性

4. 专家系统与传统程序的比较

- 编程思想
    - 传统程序 = 数据结构+算法
    - 专家系统 = 知识+推理
- 知识
    - 传统程序：关于问题求解的知识隐含于程序中
    - 专家系统：知识单独组成数据库，与推理机分离
- 处理对象
    - 传统程序：数值计算与数据处理
    - 专家系统：符号处理
- 解释功能

    - 传统程序：不具有解释功能
    - 专家系统：具有解释功能
- 答案
    - 传统程序：产生正确的答案
    - 专家系统：通常产生正确的答案，有时产生错误的答案
- 体系结构
    - 系统的体系结构不同

5. 专家系统的类型

   ppt

6. 专家系统的应用

   ppt

7.3 专家系统的工作原理

1. 专家系统的一般结构

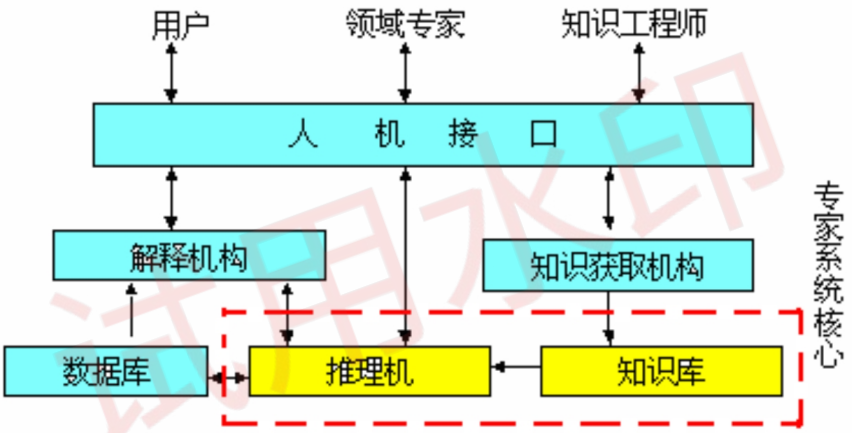
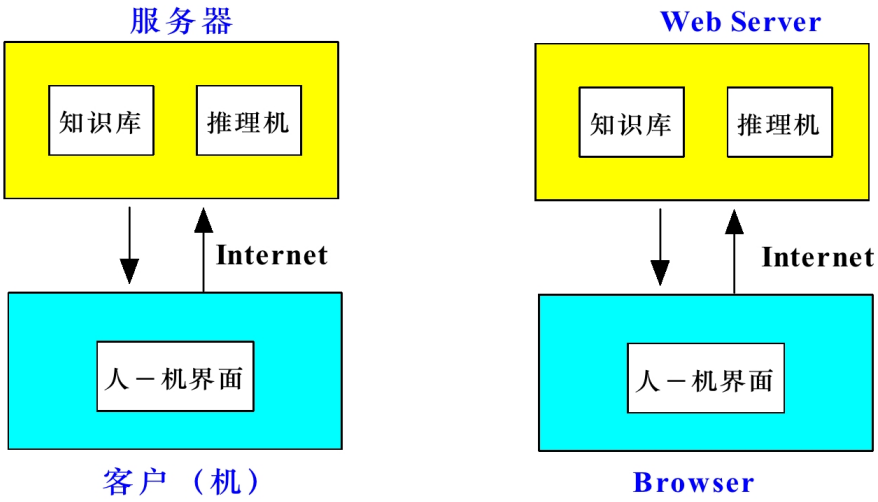


图6.1 专家系统的一般结构

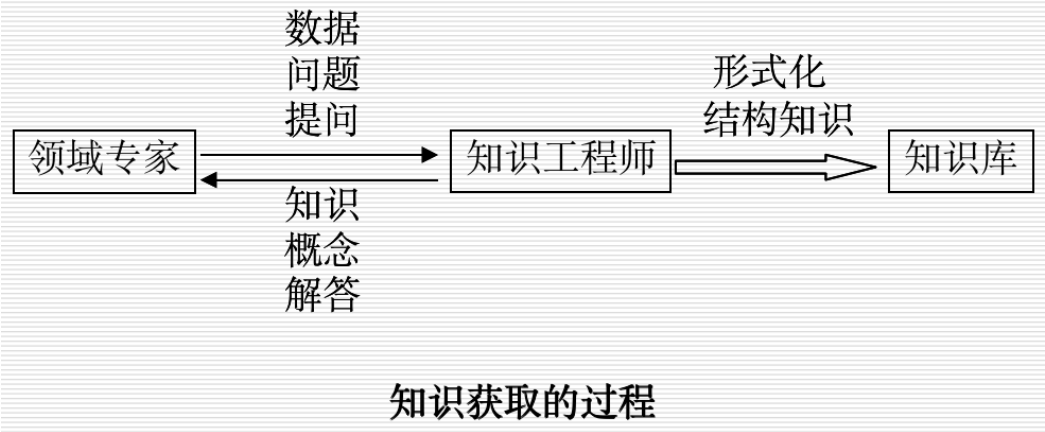
2. 网络环境下的专家系统结构



7.4 知识获取的主要过程与模式

1. 知识获取的过程

- 抽取知识
- 知识的转换
- 知识的输入
- 知识的检测



知识获取的过程

2. 知识获取的模式

- 非自动知识获取
- 自动知识获取
- 半自动知识获取

8 模式识别系统

8.1 基本概念

1. 模式：通过对具体的个别事物进行观测所得到的具有一定时间或空间分布的信息。

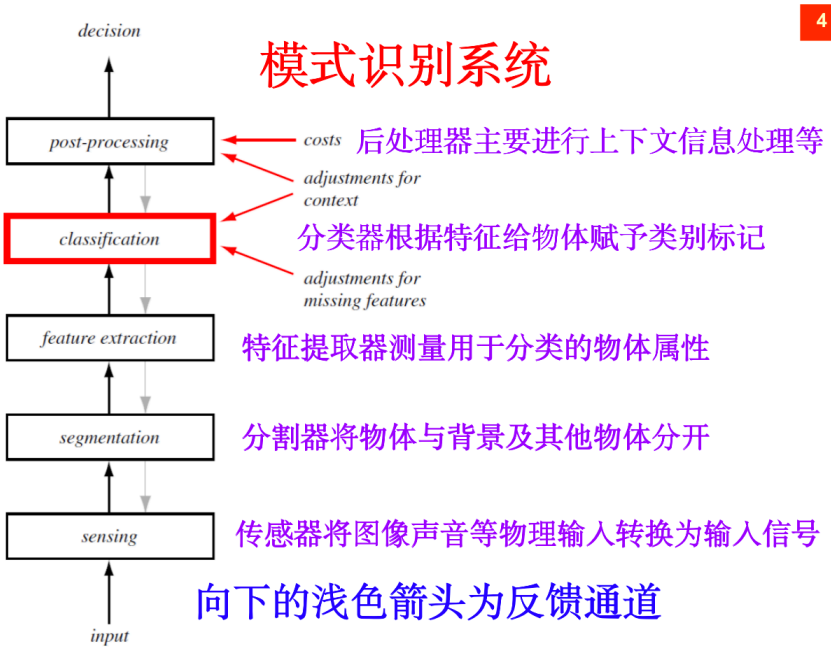
- 模式不等于事物本身，而是从事物中获得的某些信息，同一事物可以产生不同的模式。
- 模式的表示：向量、矩阵、几何表示、链码、树、时间序列、图等

2. 模式识别：是指计算机将某一模式进行分类、聚类或回归分析；
3. 模式类：模式所属的类别或者同一类中模式的总体。

8.2 模式识别系统组成

1. 模式识别系统

试用水印



模式识别系统

后处理器主要进行上下文信息处理等

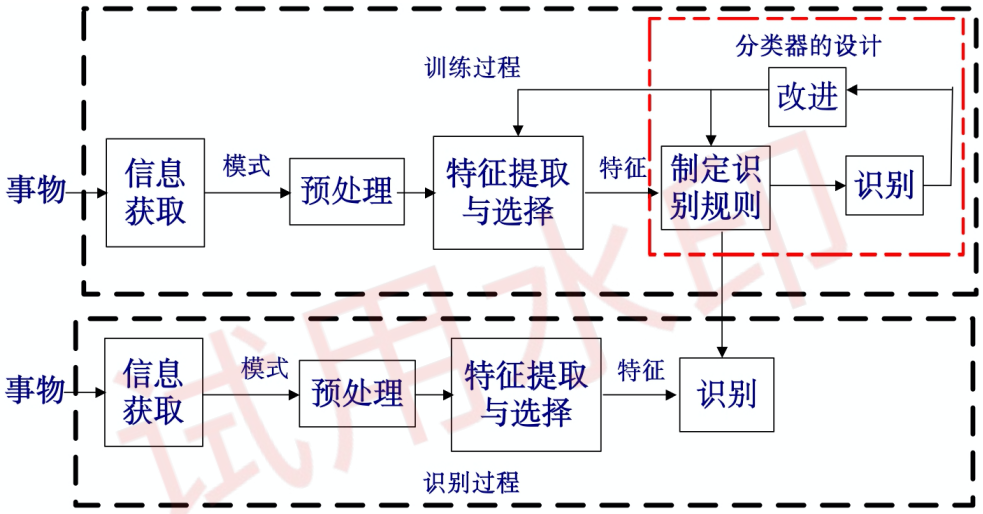
分类器根据特征给物体赋予类别标记

特征提取器测量用于分类的物体属性

分割器将物体与背景及其他物体分开

传感器将图像声音等物理输入转换为输入信号

向下的浅色箭头为反馈通道



- 信息获取：从具体事物获取原始信息。
- 预处理：对信息进行分割、增强、复原、去噪等操作。
- 特征提取与选择：提取最能反映分类本质的特征，同时压缩数据量。
  - (1) 测量空间：原始数据所组成的空间；
  - (2) 特征空间：特征数据所组成的空间。
- 分类器的设计(训练)：根据训练样本集，在特征空间中确定某种判决规则，通常，该规则的确定是一个反复调整的过程，最后所得到的规则即为分类器。
- 分类决策(识别)：在特征空间中，用所设计的分类器将待识别模式归为某一模式类。
  - 统计模式识别：指用统计学的方法来分析所输入的模式，进而进行识别的方法。
  - 句法模式识别：指通过分析模式的结构来进行识别的方法。
  - 目前主流方法仍然是统计模式识别方法。

2. 模式识别系统设计

- 数据采集
- 特征选择
- 模型选择
- 训练和评估

3. 学习和适应

- 有监督学习
  - 存在一个教师信号，对每个输入样本能提供类别标记和分类代价
- 无监督学习
  - 没有显式的教师，系统对输入样本自动形成聚类或自然的组织
- 强化学习
  - 智能体（Agent）以“试错”的方式进行学习，通过与环境进行交互获得的奖赏指导行为，目标是使智能体获得最大的奖赏。最终结果会有标签，但单次分类无标签。

8.3 困难与挑战

1. 决策边界与代价

- 在确定决策边界时，要考虑到误差的代价
- 避免用户反感

2. 特征

- 单一特征难以达到理想的分类效果
- 寻求多种特征的组合

3. 复杂?

- 过分复杂的模型导致复杂的判决曲线，从而影响泛化能力
- 模型泛化能力与复杂度的折中

4. 困难

- 模式类的类内变化
- 模式类的类间变化

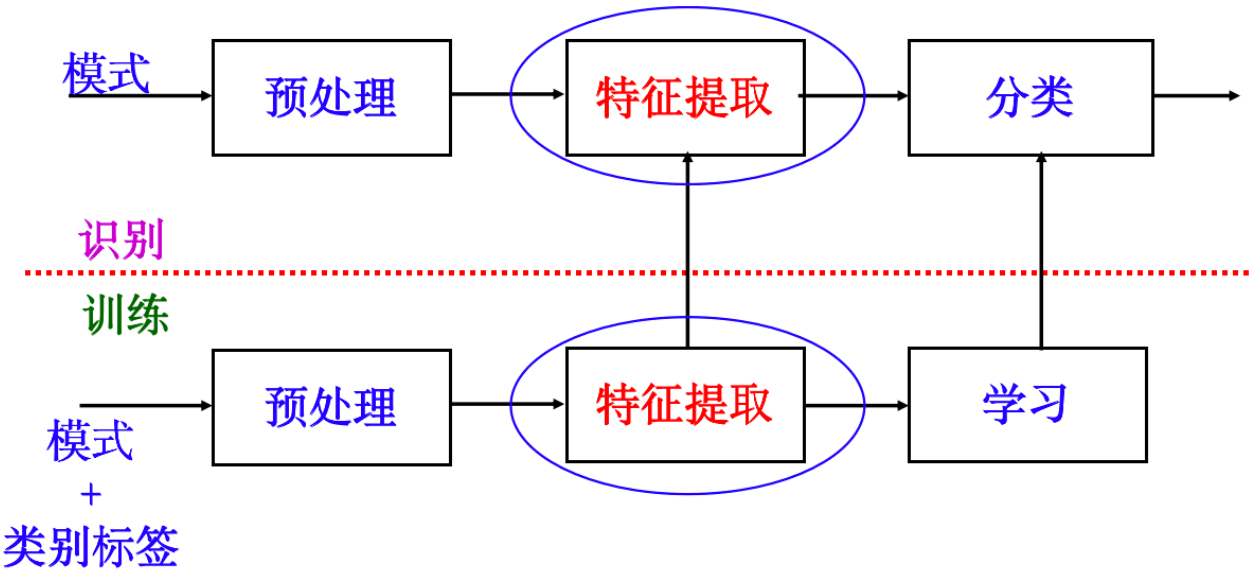
8.4 主要研究方向

ppt

8.5 应用

1. 特征选择和特征提取

试用水印



2. 特征选择

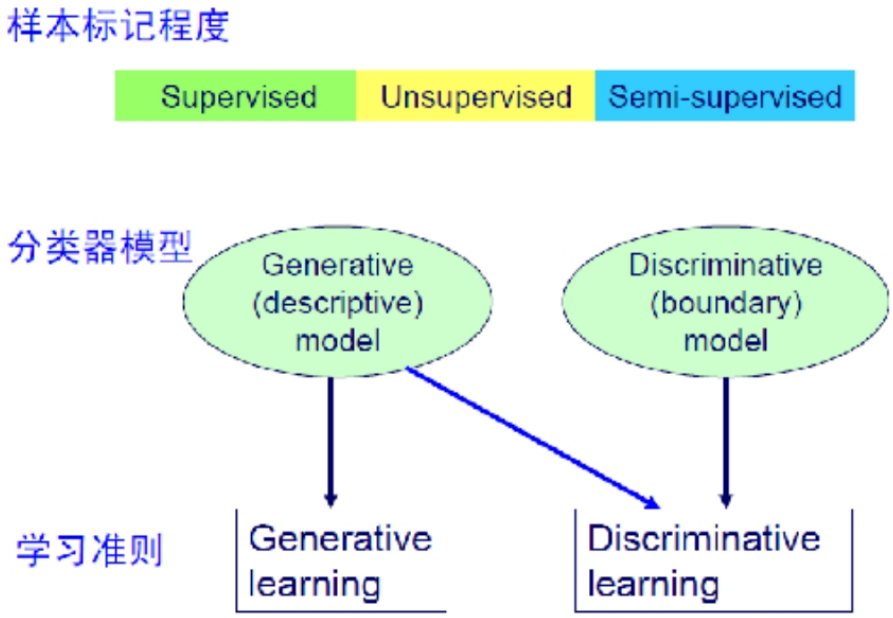
- 去除冗余特征，提高识别性能
- 减少特征数目，提高识别速度
- 降低系统成本

3. 维数约简
4. 分类器设计
5. 学习理论

- 建模变量间的关联与因果关系
- 经验风险最小化（减小样本误差率为目标）
- 结构化风险最小化（兼顾简化模型复杂度）
- 贝叶斯决策（理论基石，最优分类器）
- 人工神经网络
- 支持向量机
- 集成学习
- 深度学习

6. 学习方法分类

试用水印



7. 集成学习
8. 小结

- 模式识别
  - 对模式分布规律的分析和利用
- 方法
  - 特征选择、特征提取
  - 分类、聚类、回归分析
- 理论
  - 贝叶斯决策：先验 · 似然 = 后验
  - 计算学习理论

9 模型评估

9.1 机器学习定理

1. 没有免费的午餐：没有天生优越的分类器
2. 丑小鸭定理：没有天生优越的特征
3. 奥卡姆剃刀原理：不要选用比“必要”更复杂的模型

9.2 经验误差和过拟合

1. 误差

- 经验误差：模型在训练集上的误差
- 泛化误差：模型在测试集上的误差

试用水印

9.3 模型评估方法

1. 模型评估方法

- 在模型投放使用之前，需要先对其性能进行评估
- 需要有一个测试集来测试模型对新样本的泛化能力
- 以测试集上的测试误差作为泛化误差的近似
- 假设测试集是从样本真实分布中独立采样获得，训练集样本和测试集样本要尽量互斥

2. 留出法

- 直接将数据集划分为两个互斥集合
- 测试/训练集划分要尽可能保持数据分布的一致性
- 一般若干次随机划分、重复实验取平均值
- 测试/训练样本比例通常为2:1-4:1

3. 交叉验证法

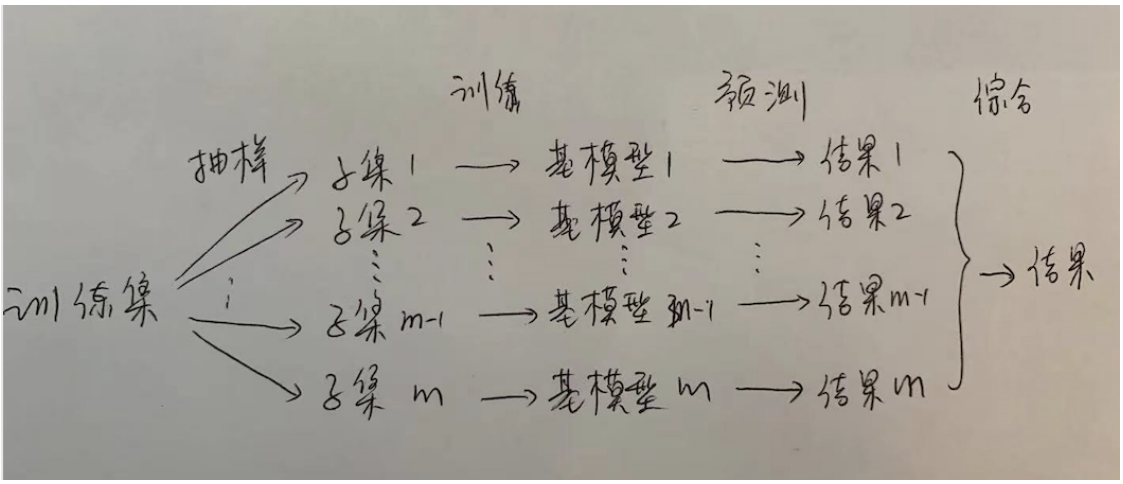
- 将数据集分层采样划分为k个大小相似的互斥子集，每次用k-1个子集的并集作为训练集，余下的子集作为测试集，最终返回k个测试结果的均值，k最常用的取值是10。
- 将数据集D划分为k个子集同样存在多和划分方式，为了减小因样本划分不同而引入的差别，k折交叉验证通常随机使用不同的划分重复p次，最终的评估结果是这p次k折交叉验证结果的均值
- 假设数据集D包含m个样本，若令k=m，则得到留一法 （每次一个数据样本作为测试集）
    - 不受随机样本划分方式的影响
    - 结果往往比较准确
    - 当数据集比较大时，计算开销难以忍受

4. 自助法

- 操作方式
    - 以自助采样法为基础
    - 对数据集D有放回采样m次得到训练集 D
    - D\D用做测试集
- 评价
    - 实际模型与预期模型都使用m个训练样本
    - 约有1/3的样本没在训练集中出现，用作测试集
    - 从初始数据集中产生多个不同的训练集，对集成学习有很大的好处
    - 自助法在数据集较小、难以有效划分训练/测试集时很有用;由于改变了数据集分布可能引入估计偏差在数据量足够时，留出法和交叉验证法更常用。

为什么有利于集成学习？（辅助理解）

试用水印



5. 模型评估三大原则

- 奥卡姆剃刀
  - 在性能得到满足的情况下，模型越简单越好
- 数据集划分时的样本采样原则
  - 训练集、测试集和验证集的分布应尽量一致
- 测试集使用原则
  - 训练阶段不要以任何理由偷看测试集
  - 对测试集的反复评估也是一种隐蔽地偷看行为

9.4 模型性能度量

1. 准确率与错误率

- 准确率：分类结果正确的样本数量占总样本数量的比例
- 错误率：分类结果错误的样本数量占总样本数量的比例
- 特点
  - 准确率 + 错误率 = 1
  - 每个样本在统计时的权重相同
  - 适用于类样本平衡的数据集

2. 查准率与查全率

- 类样本不平衡：稀有样本类别为正类，其余样本为负类。
- 查准率
  - 分类结果为正类的样本中，实际结果为正类的比例
  - P=TP / (TP + FP)
- 查全率
  - 实际结果为正类的样本中，分类结果为正类的比例
  - R=TP / (TP +FN)
- 平衡点
  - P与R往往是矛盾的
  - P = R
- F1度量

试用水印

- 比平衡点更高效
- F1=2*P*R / (P + R)

比F1更一般的形式 F_β，

$$F_\beta = \frac{(1+\beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

$\beta = 1$：标准的F1
$\beta > 1$：偏重查全率
$\beta < 1$：偏重查准率

10 机器学习模型类型

10.1 有监督学习KNN

1. 基本思路：如果一个待分类样本在特征空间中的k个最相似(即特征空间中K近邻)的样本中的大多数属于某一个类别，则该样本也属于这个类别。
2. KNN需要样本标签的支持，是一种有监督学习算法。

- 数据集：即必须存在一个样本数据集，也称作训练集，样本数据集中每个样本是有标签的，即我们知道样本数据集中每一个样本的标签。
- 样本的向量表示：即不管是当前已知的样本数据集，还是将来可能出现的待分类样本，都必须可以用向量的形式加以表征。向量的每一个维度，刻画样本的一个特征，必须是量化的，可比较的。
- 样本间距离的计算方法：欧氏距离、余弦距离、海明距离、曼哈顿距离等等。

3. k值的选取：k的取值会影响待分类样本的分类结果

- k值较小：K值的减小就意味着更复杂的决策边界，每个训练样本都会形成一个决策模型，容易发生过拟合
- k值较大：K值的增大就意味着整体的模型变得简单，会导致偏差变大。比如k为总的训练样本数量，那么每次投票肯定都是训练数据中多的类别获胜

4. KNN的优缺点

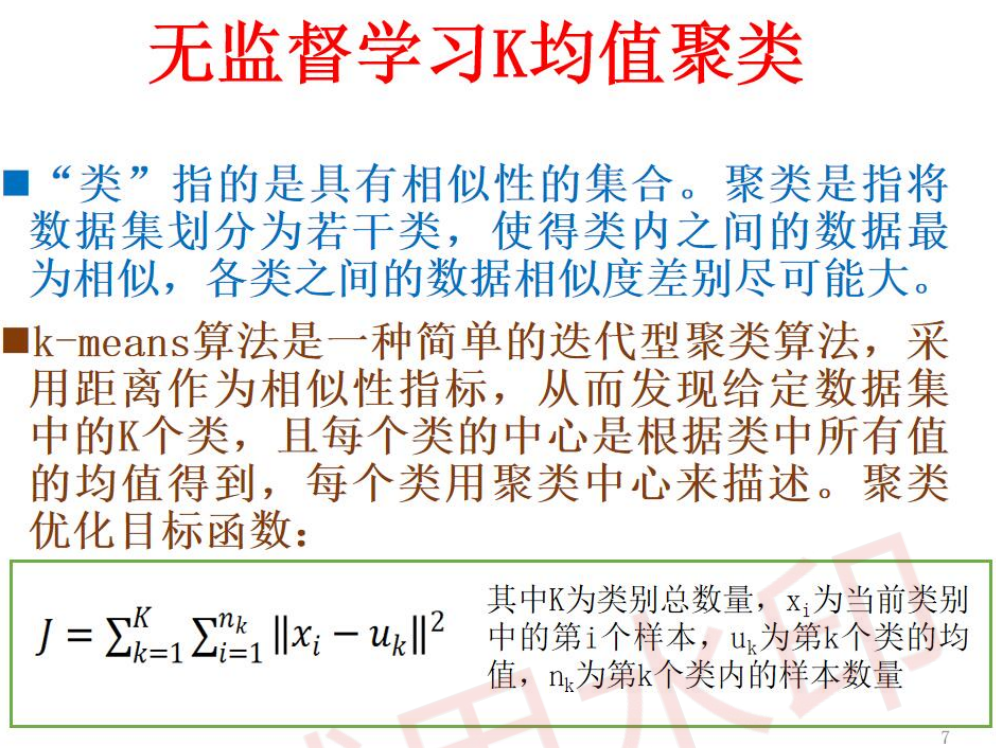
- 优点
  - 简单，易于理解，易于实现，无需参数估计，无需训练
  - 对异常值不敏感（个别噪音数据对结果的影响不是很大）
  - 适合对稀有事件进行分类
  - 适合于多分类问题
- 缺点
  - 计算量大，内存开销大
  - 可解释性差。无法告诉你哪个样本更重要
  - K值的选择。当样本不平衡时会导致错误
  - KNN是一种消极学习方法、懒惰算法

试用水印

10.2 无监督学习 K-means 聚类

1. 基本概念

- “类”指的是具有相似性的集合。
- 聚类是指将数据集划分为若干类，使得类内之间的数据最为相似，各类之间的数据相似度差别尽可能大。



2. k-means聚类的算法步骤

- 选取数据空间中的K个对象作为初始中心，每个对象代表一个聚类中心；
- 对于样本中的数据对象，根据它们与这些聚类中心的欧氏距离，按距离最近的准则将它们分到距离它们最近的聚类中心（最相似）所对应的类；
- 更新聚类中心：将每个类别中所有对象所对应的均值作为该类别的聚类中心，计算目标函数的值；
- 判断聚类中心和目标函数的值是否发生改变，若不变，则输出结果，若改变，则返回2）

10.3 半监督学习

1. 只有少量样本带标签
2. 更符合实际需求

10.4 强化学习

1. 特点：

- 单步没有标签
- 流程走完时有标签
- 常用于游戏等人工智能应用中

2. 强化学习的基本模式

试用水印



- observation、action、reward、environment、agent

10.5 自监督学习

自我打标签、自我分类

11 线性模型与非线性扩展

11.1 引言

1. 回归与分类

- 回归问题的输出是连续值
- 分类问题的输出是离散值
- 区别：模型最后一层的设计方式不同

2. Different types of Functions

- opions or scalars

11.2 线性回归

1. 定义

试用水印

- 给定由m个属性描述的样本$\boldsymbol{x}=(x_1;x_2;\ldots;x_m)$，其中$x_i$是$\boldsymbol{x}$在第$i$个属性上的取值，线性回归（linear regression）试图学得一个通过属性值的线性组合来进行预测的函数：

$$f(\boldsymbol{x})=w_1x_1+w_2x_2+\ldots+w_mx_m+b$$

- 一般用向量的形式写成：

$$f(\boldsymbol{x})=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b$$

其中$\boldsymbol{w}=(w_1;w_2;\ldots;w_m)$。

求解线性回归的参数，最小二乘法

2. 最小二乘法

- 基于预测值和真实值的均方差最小化的方法来估计参数
- $$(w^*,b^*)=\arg\min_{(w,b)}\sum_{i=1}^{n}(f(x_i)-y_i)^2$$
$$=\arg\min_{(w,b)}\sum_{i=1}^{n}(y_i-wx_i-b)^2$$
- 最小二乘法的求解方式
  - 最小化均方误差

$$E_{(w,b)}=\sum_{i=1}^{n}(y_i-wx_i-b)^2$$

  - 分别对w和b求偏导，可得

$$\frac{\partial E_{(w,b)}}{\partial w}=2\left(w\sum_{i=1}^{n}x_i^2-\sum_{i=1}^{n}(y_i-b)x_i\right)$$

$$\frac{\partial E_{(w,b)}}{\partial b}=2\left(nb-\sum_{i=1}^{n}(y_i-wx_i)\right)$$

试用水印

- 令上两式为零可得到 w 和 b 最优解的闭式(closed-form）解：

$$w = \frac{\sum_{i=1}^{n} y_i (x_i - \bar{x})}{\sum_{i=1}^{n} x_i^2 - \frac{1}{n}\left(\sum_{i=1}^{n} x_i\right)^2}$$

$$b = \frac{1}{n}\sum_{i=1}^{n} (y_i - w x_i)$$

其中，$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$

实际应用中一般不采用显式求解的方法，往往通过优化方法来进行迭代寻找最优参数。比如梯度下降法

11.3 线性回归实例

1. 机器学习步骤

- 定义一个带未知参数的函数（模型）
- 定义损失函数
- 基于优化方法得到最优参数

2. 李宏毅2021/2022春机器学习课程 https://www.bilibili.com/video/BV1Wv411h7kN

11.4 线性模型的非线性拓展

李宏毅2021/2022春机器学习课程 https://www.bilibili.com/video/BV1Wv411h7kN

11.5 通用的多分类器

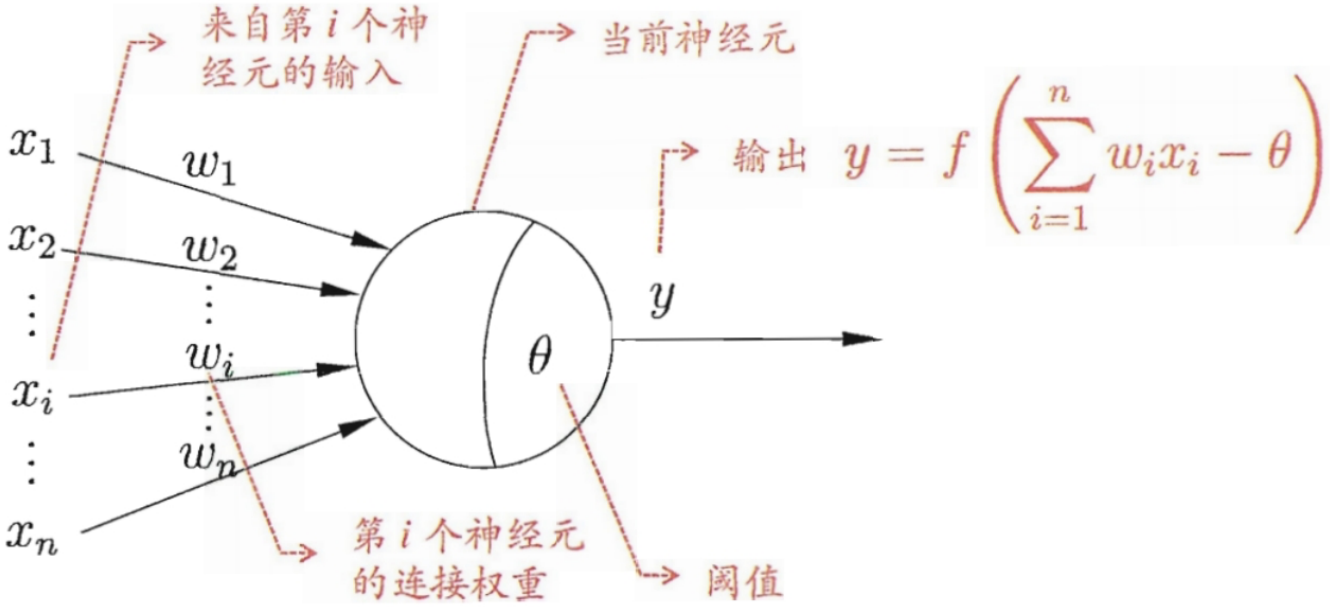
https://blog.csdn.net/peaunt1/article/details/125155068

12 人工神经网络及其应用

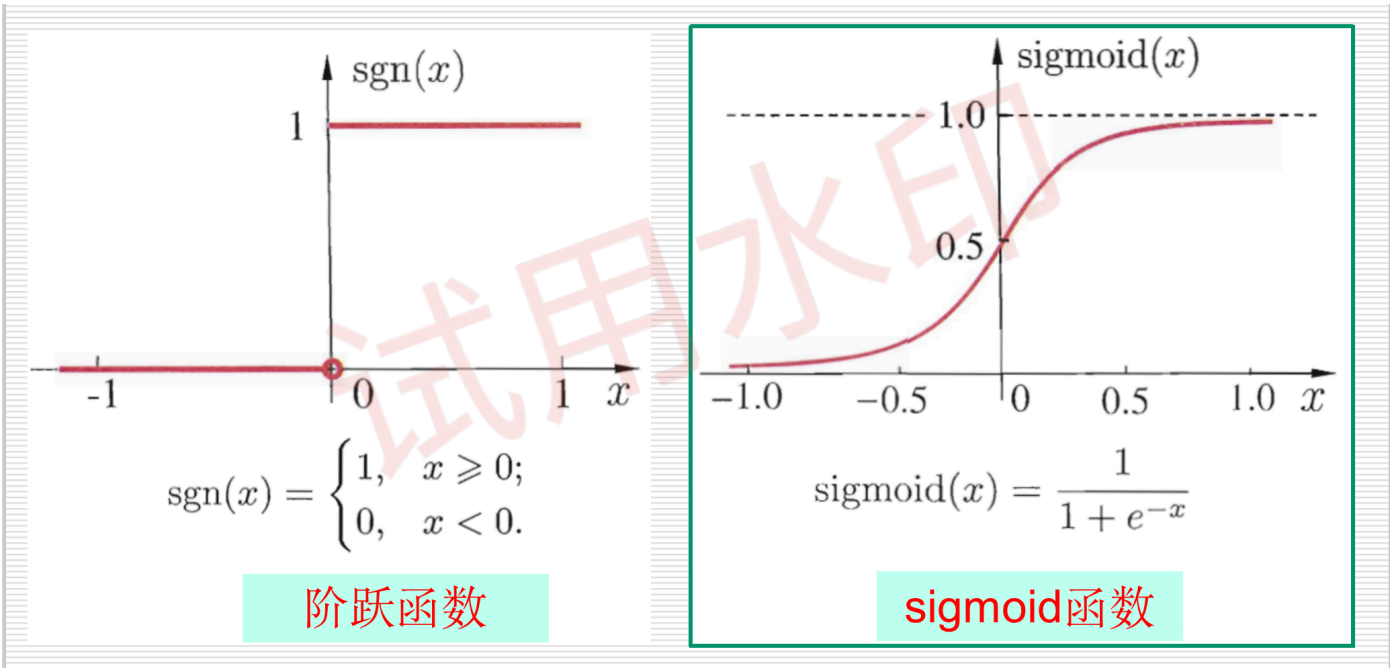
12.1 神经元与神经网络

1. 神经元结构

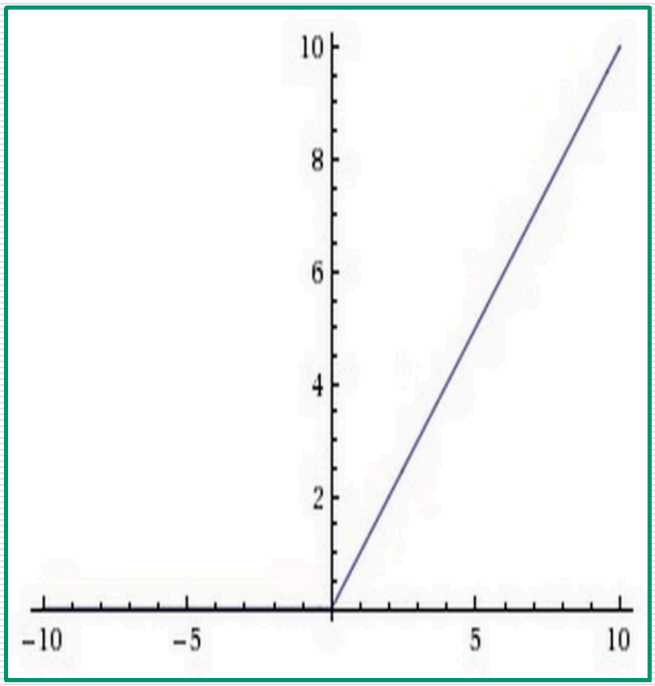
试用水印


来自第 i 个神经元的输入
当前神经元
输出 $y = f\left(\sum_{i=1}^{n} w_i x_i - \theta\right)$
x_1
x_2
x_i
x_n
w_1
w_2
w_i
w_n
θ
y
第 i 个神经元的连接权重
阈值

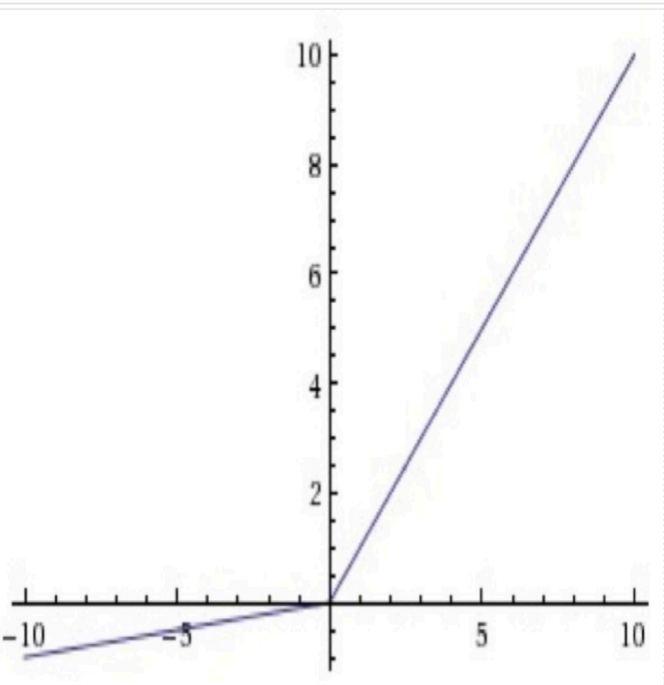
2. 激活函数


$\mathrm{sgn}(x)$
1
-1
0
1
x
$\mathrm{sgn}(x) = \begin{cases} 1, & x \geqslant 0; \\ 0, & x < 0. \end{cases}$
阶跃函数
$\mathrm{sigmoid}(x)$
1.0
0.5
−1.0
−0.5
0
0.5
1.0
x
$\mathrm{sigmoid}(x) = \frac{1}{1+e^{-x}}$
sigmoid函数

试用水印



Rectified Linear Unit (ReLU)



Leaky ReLU

3. 决定人工神经网络性能的三大要素

- 神经元的特性
- 神经元之间相互连接的形式——拓扑结构
- 为适应环境而改善性能的学习规则

4. 感知机模型

- 单层感知机的权重调整规则
- 单层感知机只能解决线性可分问题
- 如果需要解决非线性可分问题，需要使用多层功能神经元
    - eg. 二层感知机，输入层与输出层之间的一层神经元，被称为隐含层，隐含层和输出层神经元都是拥有激活函数的功能神经元

5. 神经网络的结构与工作方式

- 神经网络结构
    - 前馈型（前向型）
    - 反馈型
    - 注：2层网络只能实现线性判决边界，3层网络能实现任意的判决边界
- 神经网络的工作方式
    - 同步（并行）方式

      任一时刻神经网络中所有神经元同时调整状态
    - 异步（串行）方式

      任一时刻只有一个神经元调整状态，而其它神经元的状态保持不变
- 神经网络的工作过程

试用水印

    - 从各输入端接收输入信号
    - 根据连接权值求出所有输入的加权和
    - 用非线性激励函数进行转换，得到输出

6. 神经网络的学习

- 神经网络方法是一种知识表示方法和推理方法
- 神经网络知识表示是一种隐式的表示方法
- Hebb学习规则：当某一突触两端的神经元同时处于兴奋状态，那么该连接的权值应该增强

12.2 BP神经网络及其学习算法

1. BP网络的结构：输入层、隐藏层、输出层
2. sigmoid函数
3. BP神经网络的工作过程

- 网络训练阶段：对网络的连接权进行学习和调整，以使该网络实现给定样本的输入输出映射关系
- 工作阶段：把实验数据或实际数据输入到网络，网络在误差范围内预测计算出结果

4. BP学习算法

- 是否存在一个BP神经网络能够逼近给定的样本或者函数。
    - 三层以上的BP神经网络可以逼近任何函数
- 如何调整BP神经网络的连接权，使网络的输入与输出与给定的样本相同
    - BP学习算法

5. 反向传播

- 为了使得梯度的计算更有效率
- https://www.bilibili.com/video/BV1Wv411h7kN?p=14

6. bp学习算法

- 正向传播：输入信息由输入层传至隐层，最终在输出层输出。
- 反向传播：修改各层神经元的权值，使误差信号最小

7. bp算法的设计

- 隐层数及隐层神经元数的确定
- 初始权值的设置
- 训练数据预处理
- 后处理过程

8. BP算法的计算机实现流程

- 初始化：对所有连接权和阈值赋以随机任意小值；
- 从 N 组输入输出样本中取一个样本：将样本特征向量及其对应的类别标签输入到BP网络中。
- 正向传播：计算各层节点的输出
- 计算网络的实际输出与期望输出的误差
- 反向传播：从输出层方向计算到第一个隐层，按连接权值修正公式向减小误差方向调整网络的各个连接权值
- 让t+1→t，取出另一个样本重复（2）－（5），直到 N 个样本的训练误差达到要求时为止。

9. BP算法的特点

试用水印

- BP网络：多层前向网络（输入层、隐藏层、输出层）
- 链接权值：通过Delta学习算法进行修正
- 神经元激活函数：S形函数
- 学习算法：正向传播、反向传播
- 层与层的连接是单向的，信息的传播是双向的

10.
11.
12. BP算法的优缺点

- 优点
    - 很好的逼近特性
    - 具有较强的泛化能力
    - 具有较好的容错性
- 缺点
    - 收敛速度慢
    - 局部极值
    - 难以确定隐层和隐层结点的数目

12.3 BP神经网络在模式识别中的应用

- 设计一个三层BP网络对数字0至9进行分类（ppt）

12.4 Hopfield神经网络及其改进

1. 离散型Hopfield神经网络模型

说实话 没看太懂 简单记几个觉得可能考的点（x）

- 输入输出关系
    - x计算方式
    - f计算方式
- 同步工作方式和异步工作方式
- 特点：联想记忆
- 稳定性

试用水印

■ 稳定性定义：

• 若从某一时刻开始，网络中所有神经元的状态不再改变，即 $x = f(w_x - \theta)$ ， 则称该网络是稳定的，x为网络的稳定点或吸引子 。

• Hopfield神经网络是高维非线性系统，可能有许多稳定优态。从任何初始状态开始运动，总可以到某个稳定状态。这些稳定状态可以通过改变网络参数得到。

- 稳定性定理
  - 串行稳定性：对称阵
  - 并行稳定性：非负定对称阵

12.5 Hopfield神经网络的应用

Hopfield神经网络在联想记忆中的应用

- 网络能够通过联想来输出和输入模式最为相似的样本模式。

1. 具体怎样实现联想记忆

- 设计DHNN结构
- 设计连接权矩阵
- 测试

2. 看不懂 放弃了：）

12.6 卷积神经网络与深度学习

1. 卷积神经网络的结构

- cnn是一个多层的神经网络，每层由多个二维平面组成，而每个平面由多个独立神经元组成
- C层为特征提取层（卷积层），一个卷积模板（滤波器）产生一个特征图
- S层是特征映射层（池化层Pooling/下采样层）
- CNN中的每一个C层一般都紧跟着一个S层。
- 特征提取层（卷积层）
  - 大部分的特征提取都依赖于卷积运算
  - 利用卷积算子对图像进行滤波，可以得到显著的边缘特征
  - 卷积运算

试用水印

2. 卷积神经网络的关键技术

- 局部链接
- 参数共享
- 多卷积核
- 池化
    - 通过卷积获得了特征之后，如果直接利用这些特征训练分类器，计算量是非常大的。
    - 对不同位置的特征进行聚合统计,称为池化 (pooling)。
    - 池化常用方法：平均池化、最大池化
    - 卷积神经网络在池化层丢失大量的信息，从而降低了空间分辨率，导致了对于输入微小的变化，其输出几乎是不变的。
- 卷积层参数：卷积核大小、步长、填充

3. CNN的结构：卷积-池化

- 模型通过重复的卷积层自底向上地捕捉图像特征，并根据特征进行分类。其中，池化层用于降低采样数，将一个邻域的极值（一般是最大值）取出用于代表区域特征

4. CNN的缺陷

- CNN中没有可用的空间信息

  CNN不会识别特征之间的相互关系。没有学习到一种正确的特征间相位置对关系
- 池化操作导致信息严重丢失

  如最大池化，只保留最为活跃的神经元，传递到下一层，导致有价值的空间信息丢失

5. 胶囊网络

- 胶囊是一个包含多个神经元的载体，每个神经元表示了图像中出现的特定实体的各种属性。
- 胶囊不是传统神经网络中的一个神经元，而是一组神经元
- 胶囊里封装的检测特征的相关信息是以向量的形式存在的，胶囊的输入是一个向量，是用一组神经元来表示多个特征。

6. 胶囊网络的优点

试用水印

- 使用胶囊神经网络需要的训练数据量，远小于卷积神经网络，它采用动态路由协议算法，仅使用三层网络便可表现出很出色的性能，能够与深度卷积神经网络相当。
- 胶囊网络解决了卷积神经网络存在的信息丢失、视角变化等问题。
- 由于胶囊网络具有分别处理不同属性的能力，相比于CNN可以提高对图像变换的鲁棒性，在图像分割中也会有出色的表现。
- 胶囊网络相对于卷积网络的工作机理更接近人脑的工作方式。

12.7 生成对抗网络及其应用

1. 基本原理

- 使用对抗训练机制对两个神经网络进行训练

2. 应用

ppt（主要作用就是实现了一个生成器）

试用水印

13 自然语言处理及其应用

13.1 自然语言理解的概念与发展历史

1. 微观角度：从自然语言到机器内部的一个映射
2. 宏观角度：使机器能够执行人类所期望的某种语言功能

13.2 语言处理过程的层次

语音分析、词法分析、句法分析、语义分析和语用分析

13.3 机器翻译

13.4 语音识别

1. 语言识别的流程：分帧、状态、音素
2. 语音识别的主要流程：语音信号采集、语音信号预处理、语音信号的特征参数提取、向量量化、识别
3. 隐马尔可夫模型

- 隐马尔可夫模型： 表示序列可能出现的一种方法（条件概率）

- 解决三个基本问题
    - 输出概率计算问题
    - 状态序列解码问题
    - 模型参数估计问题

试用水印